

基于改进 Mask R-CNN 模型的植物叶片分割方法

袁 山¹, 汤 浩², 郭 亚^{1*}

(1. 江南大学物联网工程学院, 无锡 214122; 2. 绿视芯科技(无锡)有限公司, 无锡 214124)

摘 要: 通过图像处理对植物叶片进行分割是研究植物表型性状的基础, 但叶片间相互遮挡、叶片边缘特征不明显以及幼叶目标过小会对叶片分割效果造成很大的障碍。针对上述问题, 该研究提出了一种基于改进 Mask R-CNN 模型的植物叶片分割方法, 通过引入级联检测模块对模型检测分支进行改进, 以提高遮挡叶片检测质量; 利用注意力机制和一个 2 层 3×3 卷积模块对模型分割分支进行优化, 以提高边缘特征表达能力; 在模型测试过程中采用多尺度叶片分割策略, 利用多个尺度上的最优目标以分割幼叶。测试结果表明, 在 CVPPP 叶片分割挑战数据集中的对称最佳 Dice 得分 Symmetric Best Dice (SBD) 为 90.3%, 相比于利用域随机化数据增强策略并采用 Mask R-CNN 模型进行叶片实例分割的方法提高了 2.3 个百分点, 叶片分割效果有显著提升。该研究提出的方法可以有效解决植物叶片分割效果不佳的问题, 为植物表型研究提供技术支持。

关键词: 模型; 图像处理; Mask R-CNN; 植物叶片; 注意力机制; 多尺度分割

doi: 10.11975/j.issn.1002-6819.2022.01.024

中图分类号: TP391

文献标志码: A

文章编号: 1002-6819(2022)-01-0212-09

袁山, 汤浩, 郭亚. 基于改进 Mask R-CNN 模型的植物叶片分割方法[J]. 农业工程学报, 2022, 38(1): 212-220.

doi: 10.11975/j.issn.1002-6819.2022.01.024 <http://www.tcsae.org>

Yuan Shan, Tang Hao, Guo Ya. Segmentation method for plant leaves using an improved Mask R-CNN model[J]. Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE), 2022, 38(1): 212-220. (in Chinese with English abstract) doi: 10.11975/j.issn.1002-6819.2022.01.024 <http://www.tcsae.org>

0 引 言

采用非接触方法获取植物表型信息是学者们关注的热点问题^[1]。叶片是植物表型研究的重要组成部分, 对其进行分割是植物表型信息获取中至关重要的一个环节^[2]。自动叶片实例分割可以准确提取叶片形状, 是植物表型探索的一个热点研究方向^[3], 也是农业实践中的一项基本任务^[4]。

现有二维叶片分割数据集主要分为一幅图片中含有一个目标叶片^[5]或多个目标叶片^[6]两种情况。针对前者, 采用非深度学习的经典图像处理方式通常会取得比较好的结果^[7], 但是实际叶片分割中往往一幅图中有多个叶片, 描绘每一幅图片中出现的不同叶片, 并计算出每一片叶片的掩码属于实例分割的范畴, 这给经典图像处理带来挑战。叶片实例分割的代表数据集是植物表型中的计算机视觉问题 (Computer Vision Problems in Plant Phenotyping, CVPPP) 发布的莲座丛植物顶视图数据集, 该数据集包含拟南芥和烟草花两个物种^[8-9]。拟南芥作为莲座丛植物的代表, 具有生长速度快^[10]、基因组简单等特点^[11], 被广泛应用于遗传学与植物表型相结合的研究^[12]。烟草花的叶片生长速度较快, 被应用于昼夜节律等相关

的研究^[13]。因此选取莲座丛植物进行研究, 可以加速表型数据更新获取, 促进表型研究的进展。但由于莲座丛植物存在叶片间相互遮挡以及叶片边缘特征不明显等问题, 给叶片实例分割造成困难, 因此亟需研究一种能够提高植物叶片分割效果的方法。

近年来, 国内外学者对叶片实例分割开展了大量的研究, 其中 CVPPP 是非常重要的数据集, 学者们基于该数据集研究了很多叶片实例分割策略。Pape 等^[14]提出一种使用叶片颜色和纹理特征并基于预测模型进行实例分割方法, Viaud 等^[15]提出一种使用分水岭方法的叶片实例分割方式。Yin 等^[16]提出一种基于倒角匹配并将多叶对齐和跟踪框架扩展到实例分割的方法。上述基于经典图像处理的叶片分割方法分割准确性普遍较低。随着深度学习的发展, 一些深度学习模型开始应用到叶片实例分割领域。Xu 等^[17]将 Mask R-CNN 模型应用于叶片实例分割领域, 相比于经典图像处理方法提升了叶片分割的准确性, 但未进行数据增强与模型优化, 分割准确性有待进一步提高。Ward 等^[18]探索了使用合成数据进行植物成像, 通过域随机化合成 3D 植物模型, 渲染合成数据样本, 并使用 Mask R-CNN 模型对人工合成后的数据集进行训练。Kuznichov 等^[19]基于 Mask R-CNN 模型提出一种保留数据几何结构的复制粘贴数据增强算法, 使数据集的物理外观尽可能接近真实农业场景中的图像植物。虽然上述两种方法可以进一步提高叶片分割的准确性, 但是所涉及的图像增强方法需要大量图像预处理工作。Mask R-CNN 模型^[20]作为现有叶片实例分割的基准模型具有较好的叶

收稿日期: 2021-08-16 修订日期: 2021-12-19

基金项目: 国家自然科学基金项目 (51961125102; 31771680)

作者简介: 袁山, 研究方向为农业物联网系统搭建。

Email: qdlcys@163.com

*通信作者: 郭亚, 教授, 博士生导师, 研究方向为传感器仪器与物联网。

Email: guoy@jiangnan.edu.cn

片分割效果。但由于叶片遮挡现象的存在，训练单阈值对提案框进行正负样本选取容易造成误选和漏选等现象，导致有遮挡现象的叶片分割错误。由于叶片边缘特征不明显，分割分支会受到无关信息的影响，导致叶片边缘不清晰，无法对边缘不清晰的叶片进行分割。叶片图像中存在小尺度的幼叶，如果将测试集放在同一个尺度进行测试，不易分割出小尺度叶片。因此从模型角度分析，采用基准模型 Mask R-CNN 并通过复杂数据增强来提高叶片分割效果的方法存在一定的缺陷。随着深度学习的发展与计算力的提升，对深度学习模型本身提出改进有望提升叶片分割准确性。

本研究基于深度学习模型本身，通过引入级联检测模块，提高遮挡叶片的分割效果。将注意力机制思想加入到分割分支中，改善叶片边缘分割效果不佳的问题。采用多尺度分割策略，解决小尺度叶片分割困难的问题。最后在 CVPPP 数据集的试验结果中证明所提出改进方法的准确性，为叶片实例分割研究提供参考。

1 试验数据与评价指标

1.1 CVPPP 数据集

CVPPP 植物叶片分割数据集由 5 个不同的子数据集组成，分别为 A1、A2、A3、A4 和 A5，其中 A1~A4 数据集包含不同物种与尺寸的图像，A5 数据集为 A1~A4 数据集的总和。本研究选取 A5 数据集的所有数据（训练集数量为 810 张，测试集数量为 275 张）进行研究，并通过 A5 测试数据集的分割结果来说明 A1~A4 所有数据集的平均分割效果。表 1 给出了原始数据集的详细介绍，图 1 中给出了 A1~A4 数据集的部分待分割图像。

表 1 CVPPP (A1-A4) 数据集属性
Table 1 Data set attributes of CVPPP (A1-A4)

数据集 Data set	图像尺寸 Image size/像素	训练图像数 Training image number	测试图像数 Test image number	植物物种 Plant species
A1	500×530	128	33	拟南芥
A2	530×565	31	9	拟南芥
A3	2 448×2 048	27	65	烟草花
A4	441×441	624	168	拟南芥




图 1 A1-A4 数据集中的部分待分割叶片图像

Fig.1 Images of some plant leaves to be segmented in the A1-A4 data sets

1.2 叶片分割评估指标

针对冠层植物而言，CVPPP 给出的该数据集分割准确性的评价标准为对称最佳 Dice 得分（Symmetric Best Dice, SBD）与叶片数量误差绝对值|DiC|。SBD 表示模型预测出的叶片分割结果与真实叶片分割结果的接近程度，该值越大代表叶片实例分割结果越准确；|DiC|表示模型预测出的叶片数量减去真实叶片数量的绝对值，该值越小代表计数结果与实际越相近。采用 SBD 与|DiC|作为叶片分割的评价指标相比于其他指标能够捕获更多的叶分割错误^[21]。同时由于 CVPPP 中测试数据集标签对公众不可见，测试结果需要在 CVPPP 规定的平台中进行提交，该平台指定了叶片分割评价指标为 SBD 与|DiC|，为了与采用 CVPPP 数据集进行叶片实例分割的文献进行效果对比，必须选取 SBD 与|DiC|作为叶片分割的评价指标。

计算 SBD 之前需要计算最佳 Dice 得分（Best Dice, BD），BD 计算方式如下：

$$BD(L^a, L^b) = \frac{1}{M} \sum_{i=1}^M \max_{1 \leq j \leq N} \frac{2|L_i^a \cap L_j^b|}{|L_i^a| + |L_j^b|} \quad (1)$$

式中 $| \cdot |$ 表示求叶片的像素数量， $L_i^a (1 \leq i \leq M)$ 是图像 L^a 的所有叶片分割区域； $L_j^b (1 \leq j \leq N)$ 是图像 L^b 的所有叶片分割区域。BD 的计算过程如下：取 L_1^a 为图像 L^a 的第一个叶片分割区域，首先遍历 L^b 中的所有分割区域，从中找到一个与 L_1^a 交并比最大的分割区域作为 L_1^a 的 BD 得分；然后计算 L_2^a 的 BD 得分，直到计算完所有 M 个叶片的 BD 得分，将 L^a 中所有叶片的 BD 得分取平均值，得到图像 L^a 的平均 BD 得分。此时如果 L^a 与 L^b 的分割结果完全相同，则 BD 得分为 100%，但通过模型得到的叶片分割结果与真实情况可能存在一定不同（如叶片数量多于或少于真实情况以及分割错误的情况），此时需要利用 SBD 指标来确定叶片分割的准确性。SBD 的计算分为两步：第一步对图片的模型预测结果与真实标签进行匹配得到 $BD(L^{ar}, L^{st})$ ；第二步对图片的真实标签与模型预测结果进行匹配得到 $BD(L^{st}, L^{ar})$ ，两个计算步骤相互独立，SBD 得分取两步的最小值，其计算方式如下：

$$SBD(L^{ar}, L^{st}) = \min \{ BD(L^{ar}, L^{st}), BD(L^{st}, L^{ar}) \} \quad (2)$$

式中 L^{st} 是真值标签， L^{ar} 是模型预测出的分割结果。

模型计算复杂度利用每秒浮点计算数（Floating Point Operations Per Second, FLOPS）^[22]、训练时间与测试时间进行描述。FLOPS 值越小代表模型复杂度越低^[23]，训练时间表示训练一轮模型所需要的时间，测试时间表示测试一张图片需要的时间。

2 基于改进 Mask R-CNN 模型的植物叶片实例分割方法

2.1 数据预处理

使用卷积神经网络（Convolutional Neural Networks, CNN）进行实例分割的主要挑战是收集并标注足够多的训练样本^[24]，由于本研究所采用的试验数据集 A5 总共只


有 810 张图片, 难以满足深度学习要求的图像数目, 从而造成过拟合现象。在数据增强方面, 采用 Augmentor 函数库^[25]对原始数据集进行随机镜像、随机旋转、随机放大以及尺寸调整方式进行图像增强, 最终将 810 张训练图像扩充到 3 000 张图像。为了平衡各个数据集的数量, 将 A1 扩展到 600 张, A2 扩展到 150 张, A3 扩展到 150 张, A4 扩展到 2 100 张。为了保持输入图像尺寸的一致性, 将图像尺寸进行了统一, 通常尺度大的图像所含信息量更加丰富, 但是受到显卡内存大小的影响, 本研究将训练数据集图像尺寸统一为 550×550 像素。

2.2 检测与分割分支优化

本研究针对 Mask R-CNN 模型进行改进, 其中 Mask R-CNN 模型、改进的 Mask R-CNN 模型和分割分支中注意力机制模块如图 2 所示。Mask R-CNN 模型由 4 部分组成, 如图 2a 所示, 分别为特征提取网络(Backbone 网络)、区域建议网络(Region Proposal Network, RPN)、感兴趣区域对齐网络(Region of Interest Align, ROIAlign)以及各个功能输出网络。Backbone 网络主要负责对输入图像进行特征提取, 常用的如 ResNet^[26]系列与 ResNeXt^[27]系列网络。RPN 网络用于提取候选框, 训练阶段通过与真实标签的交并比选出正负样本, 然后采用非极大值抑制方法筛选出与预选边界框相同目标的最优锚点, 得到初始提案框。ROIAlign 网络负责对 RPN 选取的不同大小的特征图进行尺度统一。功能输出网络 Head 对 ROIAlign 网络的输出进行分类、目标检测与分割。

考虑到 Cascade R-CNN 模型^[28-30]与注意力机制模块^[31-32]在叶片分割领域的潜在作用, 本研究对 Mask R-CNN 模型的改进方式如图 2b 所示。

针对叶片分割领域存在的叶片遮挡问题, Mask R-CNN 模型对 Head 网络采用单阈值进行正负样本选取易造成多选或漏选的检测结果。本研究引入 Cascade R-CNN 网络到叶片分割领域(见图 2b 中虚线框), 采用级联的思想对检测分支进行优化, 逐步提升 Head 网络的阈值, 以解决正负样本不均衡的问题, 得到高质量的提案框与多数量的正样本, 减少一个提案框中包含多个叶片的可能性, 从而解决叶片相互遮挡时造成的检测错误。利用 Backbone 网络提取图像特征, 由 RPN 生成一系列初始提案框。为了进行级联选择从而提高正样本的质量, 本研究根据 Cai 等^[28]的研究, 将级联阈值分别设置为 0.5、0.6 和 0.7, 采用的级联方式在训练阶段流程如下: 将初始提案框输入到 Cascade R-CNN 模型中, 首先输入到阈值为 0.5 的 Head1 卷积网络中进行训练, 得到 C1 分类结果、S1 分割结果、B1 检测结果并计算损失调整模型参数; 再将检测结果输入到阈值为 0.6 的 Head2 卷积网络中进行训练, 得到 C2 分类结果、S2 分割结果、B2 检测结果并计算损失调整模型参数; 最后将检测结果输入阈值为 0.7 的 Head3 卷积网络中, 得到 C3 分类结果、S3 分割结果、B3 检测结果并计算损失调整模型参数。利用 3 个级联网络逐步提升阈值, 使得前一个网络的输出能适用于下一个网络的更高阈值, 提高了正样本的数量与质量。



注: RPN 为区域建议网络; Backbone 为特征提取网络; ROIAlign 为感兴趣区域对齐网络; Head 为正负样本选取网络; C 为分类结果; S 为实例分割结果; B 为目标检测结果; Cascade R-CNN 是级联分割模块; FCN 是全卷积层; SeNet 是注意力机制模块; ReLu 和 Sigmoid 是卷积网络激活函数; c 的取值为 256, t 的取值为 16, 下同。

Note: RPN is the Region Proposal Network; Backbone is the feature extraction network; ROIAlign is the Region of Interest Align network; Head is the positive and negative sample selection network; C is the classification result; S is the instance segmentation result; B is the target detection result; Cascade R-CNN is the cascaded segmentation module; FCN is the fully convolutional layer; SeNet is the attention mechanism module; ReLu and Sigmoid are convolutional network activation functions; the value of c is 256, and the value of t is 16, the same below.

图 2 Mask R-CNN 模型与改进的 Mask R-CNN 模型

Fig.2 Mask R-CNN model and improved Mask R-CNN model


针对叶片分割领域中叶片边缘特性不明显的情况,导致 Mask R-CNN 的分割分支受到其他特征信息的影响,从而为边缘特征分配更少的权重。本研究引入注意力机制模块来对分割分支进行改进,利用该模块对分割分支的特征进行加权,增强叶片边缘特征信息,提高对叶片边缘的分割效果。为了对分割分支特征图进行优化,引入一个 2 层的 3×3 卷积模块,将 SeNet 与卷积模块添加到 Cascade R-CNN 模型的每一个分割分支中。以图 2b 中的一个分割分支为例,其流程如图 2c 所示,首先通过 4 层 3×3 全卷积层 (Fully Convolutional Networks, FCN) 以充分提取叶片特征;然后输入到 SeNet 注意力机制模块,对特征进行空间维度的调整,使其具有全局感受视野,从而对叶片特征图边缘进行全局有效感知;最后经过 2 层 3×3 卷积模块,进一步提取叶片边缘特征,提高叶片边缘分割的质量。本研究根据 ROIAlign 的 256 维输出,将注意力机制参数 c 设置为 256 以确保正确的维度压缩;根据 Hu 等^[33]的研究,将注意力机制参数 t 设置为 16 以保证模型准确性与复杂度之间的平衡。

2.3 测试模式优化

植物叶片图像中可能存在幼叶目标过小的问题,由于幼叶所占比例在所有叶片中较少,模型在学习过程中倾向于大多数的非幼叶样本,导致模型无法对幼叶进行

有效检测与分割。为了解决上述问题,一种可行性的方法是在模型训练阶段加入不同尺度的图像进行训练^[34],但是该方法本质仍然为数据增强策略,并且会占用更多的计算资源。

本研究针对幼叶分割效果不佳的问题,在应用中引入多尺度分割的策略进行改善,在模型训练完成后的测试阶段将原始图像与放大后的图像同时输入模型中进行分割,通过非极大值抑制 (Non-Maximum Suppression, NMS) 选取多尺度上的最优分割结果。以 3 个不同尺度进行分割为例,测试阶段的叶片分割流程如图 3 所示。当在 3 个尺度进行测试时,不同尺度大小的图片在经过 RPN 网络会产生大小不同的提案框,所以需要先对提案框进行尺度上的统一,将其统一到 550×550 像素对应的提案框大小,然后合并到一起做 NMS 以去掉任务重复的提案框,生成多尺度的提案框。将多尺度提案框输入 Cascade R-CNN 前需要把多尺度提案框分别统一到 650×650 像素和 750×750 像素的尺度,再通过 Cascade R-CNN 网络进行叶片分割并得到 3 个尺度的分割结果,将结果统一到 550×550 像素尺度上一起做 NMS 以去掉任务重复的分割叶片,最后输出最终的分割结果。在多个尺度进行叶片分割,利用不同尺度的特征进行融合,增强对小样本的检测与分割结果。



注: NMS 为非极大值抑制。 Note: NMS is Non-Maximum Suppression.

图 3 3 个尺度进行测试的流程

Fig.3 Flowchart of testing on the three scales

2.4 计算环境设置

本研究模型的训练与测试在配备 8 核 CPU、3.50 GHz 运行频率、32 GB RAM、Nvidia GTX2080Ti GPU 和 Ubuntu 16.04 操作系统的计算机上执行,使用 GTX2080Ti GPU 进行加速。本研究中叶片分割模型基于开源框架 mmdetection^[35]和 pytorch^[36]进行部署,配置安装 Python3.7 环境、Cuda11.0 计算架构与 Cudnn7.6 加速库。所有测试结果都是在 CodaLab^[37]服务器上提交并评估获得。

3 结果与分析

3.1 Backbone 网络分割结果与分析

Mask R-CNN 采用不同的 Backbone 网络针对不同任

务通常会得到不同的试验结果。为了验证并找出一种更适合叶片分割的 Backbone 网络以用于本研究提出的改进方法,在原始 Mask R-CNN 模型上执行几个常用的 Backbone 网络: ResNet50、ResNet101、ResNeXt50、ResNeXt101 和 ResNeXt152 网络,并在测试集中计算的 SBD 得分,结果如表 2 所示。试验结果表明,对于总数据集 A5 在相同网络层数的基础上,采用 ResNeXt 比 ResNet 的 SBD 得分要高 0.3~0.5 个百分点,分割效果更好。选用 ResNeXt101 网络作为 Backbone 网络可以获得最佳的叶片分割效果,其相比于 ResNeXt50 的特征提取能力更强。ResNeXt101 相比于 ResNeXt152,其网络深度 101 层比 152 层要浅,特征提取能力理论上会较弱,但是深层

网络可能会带来潜在的梯度消退问题。考虑到叶片分割图片的背景中只有植物土壤与花盆等可控因素，因此选择 ResNeXt101 网络作为 Backbone 网络来提取特征，其 SBD 得分比 ResNeXt50 和 ResNeXt152 均高了 0.3 个百分点。

表 2 不同 Backbone 网络下 SBD 得分
Table 2 SBD (Symmetric Best Dice) for different Backbone networks

骨干网络 Backbone	数据集 Data set				
	A1	A2	A3	A4	A5
ResNet50	88.4	86.3	80.8	87.9	86.3
ResNet101	88.5	87.5	82.6	88.0	86.8
ResNeXt50	88.5	86.8	83.8	87.6	86.8
ResNeXt101	89.2	88.6	84.3	87.7	87.1
ResNeXt152	88.0	87.0	83.8	87.6	86.8

3.2 改进 Mask R-CNN 模型结果与分析

在选取 Backbone 网络为 ResNeXt101 的基础上，分别对比本研究中提出的不同策略在叶片分割效果方面的

准确性。在 Mask R-CNN 模型的基础上进行改进，逐步加入 Cascade mask R-CNN 模型、改进的分割分支与多尺度叶片分割策略。上述分割结果如表 3 所示，从测试数据集中选取典型分割类型进行展示，分别为相互遮挡、叶片边缘不清晰、叶柄过细（属于边缘不清晰的一种）、叶片尺寸过小 4 种类型，结果如图 4 所示。

表 3 不同改进策略下的 SBD 得分
Table 3 SBD for different improvement strategies

方法 Method	数据集 Data set				
	A1	A2	A3	A4	A5
Mask R-CNN	89.2	88.6	84.3	87.7	87.1
Cascade mask R-CNN	90.2	88.6	84.5	89.0	88.1
Cascade mask R-CNN +改进的分割分支	90.5	89.2	86.4	89.6	88.9
Improved segmentation branch Cascade mask R-CNN +改进的分割分支	90.6	89.1	89.8	89.5	89.7
Improved segmentation branch +多尺度测试 Multi-scale testing					



图 4 4 种典型场景下的分割结果图
Fig.4 Segmentation results of four typical segmentation scenarios

从表 3 中可以看出，对于总数据集 A5 采用 Cascade mask R-CNN 模型比 Mask R-CNN 模型的 SBD 值高了 1 个百分点。准确性的提升主要在一些高度重叠的叶片分割改善，在对提案框采用单阈值进行训练时，由于选取了过多的正样本，容易将两片重叠的叶片视为一片叶片，从而造成检测方面的错误，如图 4a 高度重叠的分割结果。

加入改进的分割分支后，相对于 Mask R-CNN 模型，SBD 提高了 1.8 个百分点，准确性的提升主要来自对边缘以及叶柄的有效分割。如图 4b 边缘不清晰情况，可见红框中两个叶片大叶的叶柄重叠在小叶的叶片上，由于颜色相近导致边缘不清晰，从左下角热力图可以看出，加入注意力机制后边缘特征更加明显；对于图 4c 中叶柄过细情

况, 从左下角热力图可以看出, 红框叶片在加入注意力机制后特征分布更加均匀, 有效实现对叶柄的分割。最后加入多尺度测试后 SBD 提升了 2.6 个百分点。从 A3 数据集分割结果中可以看出, 加入多尺度测试对结果的准确性提升了 5.5 个百分点, 然而在未使用多尺度测试的时候, 没有检测出 A3 数据集中的一些小尺度叶片。图 4d 叶片尺寸过小的情况下, 红框中的叶片由于所占像素比例极小, 采用单尺度测试的情况下不易检测出, 造成分割准确性大幅下降, 而多尺度测试将图片与放大后的同时输入模型进行测试, 得到更多的图像信息, 从而有效检测出小尺度叶片。

现有文献研究了分割性能与叶片计数性能之间的关系, 受到评价指标计算方式的影响, 该数据集 SBD 指标的性能提升主要是以叶计数性能下降为代价^[38]。表 4 给出将 0.5 和 0.7 (即模型预测为叶片的概率为大于 0.5 或 0.7 时才计算分割掩码) 设置为预测概率时 SBD 指标和 |DiC| 指标。

从表 4 中可以看出, 对于总数据集 A5 将预测概率从 0.5 增加到 0.7, 会去除掉一些低概率预测为叶片的分割掩码, 从而对分割结果产生 0.6 个百分点的提升, 但是会造成每一张图像预测出的叶片数量与真实叶片数量绝对值之差增加 0.086, 因此权衡叶片分割与计数的效果, 本研究将预测概率设置为 0.7。

表 4 预测概率为 0.5 和 0.7 时的 SBD 与 |DiC|

Table 4 SBD and |DiC| with 0.5 and 0.7 as predicted probabilities

数据集 Data set	0.5		0.7	
	SBD/%	DiC	SBD/%	DiC
A1	90.6	0.940	91.8	1.15
A2	89.1	0.666	89.4	0.777
A3	89.8	1.125	90.1	1.214
A4	89.5	0.672	90.2	0.762
A5	89.7	0.791	90.3	0.877

注: |DiC|为模型预测出的叶片数量减去真实叶片数量的绝对值。

Note: |DiC| is the absolute value of the number of leaves predicted by the model minus the actual number of leaves.

3.3 模型与文献方法对比分析

与文献上最先进的基于 Mask R-CNN 的分割模型相比, 本研究提出的叶片分割模型表现出最佳的效果, 相关结果如表 5 所示。

表 5 本研究方法与不同现有叶片分割方法的 SBD 对比

Table 5 SBD comparison between our method and different existing leaf segmentation methods

方法 Methods	数据集 Data set				
	A1	A2	A3	A4	A5
Xu 等 ^[17]	-	-	-	-	76.3
Ward 等 ^[39]	90.0	81.0	51.0	88.0	82.0
Kuznichov 等 ^[19]	88.7	84.8	83.3	88.6	86.4
Ward 等 ^[18]	90.0	88.0	86.0	88.0	88.0
本研究 Ours	91.8	89.4	90.1	90.2	90.3

从表 5 中可以看出, 本研究提出的改进策略, 在 CVPPP A5 总数据集中的 SBD 指标为 90.3%, 相比于 Ward 等^[18]利用域随机化数据增强策略并采用 Mask R-CNN 模型进行叶片实例分割的方法提高了 2.3 个百分点, 说明本

研究提出的方法可以有效对叶片分割准确性进行提升。

3.4 模型复杂度分析

为了对比本研究模型与现有模型的复杂度, 选取 Backbone 网络为 ResNeXt101, 训练次数为 12 轮(epoch), 输入图像尺寸为 550×550 像素, 对比 Mask R-CNN 模型与本研究提出改进方法的每秒浮点计算数 (FLOPS)、训练时间以及测试时间, 结果如表 6 所示。

从表 6 中可以看出, 由于 Cascade R-CNN 训练了 3 个 Head 网络进行级联选择, 提高了遮挡叶片的检测效果, 但导致模型复杂度上升。同时由于在分割分支中引入注意力机制与一个 2 层的 3×3 卷积模块, 获得了更精细的叶片边缘特征, 也引入额外的模型复杂度。训练一个 epoch 约增加 5 min, 测试一张图片约增加 0.18 s。但是相比于分割准确性的大幅提升, 增加的训练与测试时间在可接受的范围内。同时随着计算机技术的快速发展, 模型的训练与测试时间会越来越短, 因此速度性能的微弱下降不影响本研究方法的综合性能。

表 6 Mask R-CNN 与本研究提出方法的模型计算复杂度对比

Table 6 Model computational complexity for Mask R-CNN and proposed methods

方法 Method	每秒浮点计算数 Floating point operations per second	每轮训练时间 Training time per epoch/min	测试时间 Testing time/ (s·帧 ⁻¹)
Mask R-CNN	2.41×10^{11}	19.2	0.383
Cascade Mask R-CNN	3.25×10^{11}	24.1	0.387
Cascade Mask R-CNN + 改进 的分割分支	3.95×10^{11}	24.8	0.387
Cascade Mask R-CNN + 改进 的分割分支+多尺度测试	3.95×10^{11}	24.8	0.562

4 讨 论

为了解决叶片分割中存在的叶片遮挡、边缘不清晰以及小尺度叶片难以分割的现象, 本研究考虑现有模型本身应用于叶片分割领域潜在的一些问题并对模型进行改进。文献[19]中通过一种保留数据对象几何结构的方法扩充了训练数据集, 实现了 86.4% 的分割准确性; 在此基础上, 文献[18]采用域随机化, 更好地实现了合成数据集的分布, 但也仅将分割准确性提升了 1.6 个百分点。而本研究在文献[18]的基础上又将分割准确性提高了 2.3 个百分点, 将分割准确性超越 90%, 考虑到随着分割准确性的提高分割性能提高愈加困难, 以及受图像分辨率影响一些叶片即使通过人眼也不容易检测, 说明本研究对模型一系列改进具有重要价值, 可以为图像处理领域存在的目标遮挡、边缘不清晰以及小尺度检测问题的解决方案提供参考, 促进农业领域获取更为准确的叶片性状及农业物联网的集成与发展^[40]。

在研究中通过表 4 可以发现, 现有评估指标无法同时保证分割准确性与计数准确性。虽然采用更高的预测概率会获得更好的分割准确性, 但会导致一些被低概率判断为叶片的分割掩码被删除。在未来工作中需要探究一种更好的叶片分割准确性评价方式, 以充分发挥深度学习在叶片分割领域的作用。

5 结 论

本研究提出一种改进 Mask R-CNN 模型对植物叶片进行实例分割。以 CVPPP 给出的叶片分割数据集为例, 采用随机镜像、随机旋转、随机放大以及尺寸调整等方式进行数据增强。针对数据集中叶片间相互遮挡的情况, 引入目标检测领域 Cascade R-CNN, 并采用逐步级联的思想减少一个提案框中包含多个叶片的可能性, 从而解决叶片相互遮挡时造成的检测错误。在模型分割分支中利用注意力机制以提高边缘特征表达能力, 来解决叶片边缘特征不明显的问题。采用多尺度分割策略在多个尺度选取目标叶片, 实现小尺寸幼叶的分割。通过对比选取 ReXt101 为 Backbone 网络以充分提取叶片特征。测试结果显示, 相比于以 Mask R-CNN 为基准叶片分割模型并采用域随机化数据增强策略的方法, 本研究所提出的改进模型将叶片分割准确性从 88.0% 提高到了 90.3%, 表明对神经网络模型本身提出改进可以有效应用于叶片分割领域以解决植物叶片分割效果不佳的问题, 为基于图像处理的植物表型研究提供更为准确的叶片分割模型与改进思路, 在植物叶片表型研究领域具有很高的应用价值。

[参 考 文 献]

- [1] Pieruschka R, Schurr U. Plant phenotyping: past, present, and future[J]. Plant Phenomics, 2019, 2019: 1-6.
- [2] Nikbakhsh N, Baleghi Y, Agahi H. A novel approach for unsupervised image segmentation fusion of plant leaves based on G-mutual information[J]. Machine Vision and Applications, 2021, 32(5): 1-12.
- [3] Fiorani F, Schurr U. Future scenarios for plant phenotyping[J]. Annual Review of Plant Biology, 2013, 64: 267-291.
- [4] Xia C, Wang L, Chung B K, et al. In situ 3D segmentation of individual plant leaves using a RGB-D camera for agricultural automation[J]. Sensors, 2015, 15(8): 20463-20479.
- [5] Grand-Brochier M, Vacavant A, Cerutti G, et al. Tree leaves extraction in natural images: Comparative study of preprocessing tools and segmentation methods[J]. IEEE Transactions on Image Processing, 2015, 24(5): 1549-1560.
- [6] Liu X, Hu C, Li P. Automatic segmentation of overlapped poplar seedling leaves combining Mask R-CNN and DBSCAN[J]. Computers and Electronics in Agriculture, 2020, 178: 105753.
- [7] Brindha G J, Gopi E S. An hierarchical approach for automatic segmentation of leaf images with similar background using kernel smoothing based Gaussian process regression[J]. Ecological Informatics, 2021, 63: 101323.
- [8] Minervini M, Fischbach A, Scharr H, et al. Finely-grained annotated datasets for image-based plant phenotyping[J]. Pattern Recognition Letters, 2015, 81: 80-89.
- [9] Scharr H, Minervini M, Fischbach A, et al. Annotated image datasets of rosette plants[C]//European Conference on Computer Vision, Zürich, Switzerland: Academia, 2014: 6-12.
- [10] Hühner P, Schandry N, Jandrasits K, et al. ARADEEPOPSIS, an automated workflow for top-view plant phenomics using semantic segmentation of leaf states[J]. The Plant Cell, 2020, 32(12): 3674-3688.
- [11] Koornneef M, Meinke D. The development of Arabidopsis as a model plant[J]. The Plant Journal : For Cell and Molecular Biology, 2010, 61(6): 909-921.
- [12] Alonso-Blanco C, Andrade J, Becker C, et al. 1,135 genomes reveal the global pattern of polymorphism in *Arabidopsis thaliana*[J]. Cell, 2016, 166(2): 481-491.
- [13] Dellen B, Scharr H, Torras C. Growth signatures of rosette plants from time-lapse video[J]. IEEE-ACM Transactions on Computational Biology and Bioinformatics, 2015, 12(6): 1470-1478.
- [14] Pape J M, Klukas C. Utilizing machine learning approaches to improve the prediction of leaf counts and individual leaf segmentation of rosette plant images[J]. Proceedings of the Computer Vision Problems in Plant Phenotyping (CVPPP), 2015, 3: 1-12.
- [15] Viaud G, Loudet O, Cournède P H. Leaf segmentation and tracking in *Arabidopsis thaliana* combined to an organ-scale plant model for genotypic differentiation[J]. Frontiers in Plant Science, 2017, 7: 2057.
- [16] Yin X, Liu X, Chen J, et al. Multi-leaf alignment from fluorescence plant images[C]//IEEE Winter Conference on Applications of Computer Vision, Colorado, USA: IEEE, 2014: 437-444.
- [17] Xu L, Li Y, Sun Y, et al. Leaf instance segmentation and counting based on deep object detection and segmentation networks[C]//2018 Joint 10th International Conference on Soft Computing and Intelligent Systems (SCIS) and 19th International Symposium on Advanced Intelligent Systems (ISIS), Toyama, Japan: IEEE, 2018: 180-185.
- [18] Ward D, Moghadam P. Scalable learning for bridging the species gap in image-based plant phenotyping[J]. Computer Vision and Image Understanding, 2020, 197: 103009.
- [19] Kuznichenov D, Zvirin A, Honen Y, et al. Data augmentation for leaf segmentation and counting tasks in rosette plants[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops, California, USA: IEEE, 2019: 1-10.
- [20] He K, Gkioxari G, Dollár P, et al. Mask R-CNN[C]//Proceedings of the IEEE International Conference on Computer Vision, Venice, Italy: IEEE, 2017: 2961-2969.
- [21] Scharr H, Minervini M, French A P, et al. Leaf segmentation in plant phenotyping: A collation study[J]. Machine Vision

- and Applications, 2016, 27(4): 585-606.
- [22] Giusti A, Cireşan D C, Masci J, et al. Fast image scanning with deep max-pooling convolutional neural networks[C]// 2013 IEEE International Conference on Image Processing, Melbourne, Australia: IEEE, 2013: 4034-4038.
- [23] 赵辉, 乔艳军, 王红君, 等. 基于改进 YOLOv3 的果园复杂环境下苹果果实识别[J]. 农业工程学报, 2021, 37(16): 127-135.
Zhao Hui, Qiao Yanjun, Wang Hongjun, et al. Apple fruit recognition in complex orchard environment based on improved YOLOv3[J]. Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE), 2021, 37(16): 127-135. (in Chinese with English abstract)
- [24] Dvornik N, Mairal J, Schmid C. On the importance of visual context for data augmentation in scene understanding[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2019, 43(6): 2014-2028.
- [25] Bloice M D, Stocker C, Holzinger A. Augmentor: An image augmentation library for machine learning[J/OL]. Computer Vision and Pattern Recognition, 2017, [2017-08-11]. <https://arxiv.org/abs/1708.04680>.
- [26] He K, Zhang X, Ren S, et al. Deep residual learning for image recognition[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, Las Vegas, USA: IEEE, 2016: 770-778.
- [27] Xie S, Girshick R, Dollár P, et al. Aggregated residual transformations for deep neural networks[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, Hawaii, USA: IEEE, 2017: 1492-1500.
- [28] Cai Z, Vasconcelos N. Cascade R-CNN: Delving into high quality object detection[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, Salt Lake City, USA: IEEE, 2018: 6154-6162.
- [29] 燕红文, 刘振宇, 崔清亮, 等. 基于特征金字塔注意力与深度卷积网络的多目标生猪检测[J]. 农业工程学报, 2020, 36(11): 192-202.
Yan Hongwen, Liu Zhenyu, Cui Qingliang, et al. Multi-target detection based on feature pyramid attention and deep convolution network for pigs[J]. Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE), 2020, 36(11): 192-202. (in Chinese with English abstract)
- [30] 邓颖, 吴华瑞, 朱华吉. 基于实例分割的柑橘花朵识别及花量统计[J]. 农业工程学报, 2020, 36(7): 200-207.
Deng Ying, Wu Huarui, Zhu Huaji. Recognition and counting of citrus flowers based on instance segmentation[J]. Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE), 2020, 36(7): 200-207. (in Chinese with English abstract)
- [31] 方鹏, 郝宏运, 李腾飞, 等. 基于注意力机制和可变形卷积的鸡只图像实例分割提取[J]. 农业机械学报, 2021, 52(4): 257-265.
Fang Peng, Hao Hongyun, Li Tengfei, et al. Instance segmentation of broiler image based on attention mechanism and deformable convolution[J]. Transactions of the Chinese Society for Agricultural Machinery, 2021, 52(4): 257-265. (in Chinese with English abstract)
- [32] 曹锦纲, 杨国田, 杨锡运. 基于注意力机制的深度学习路面裂缝检测[J]. 计算机辅助设计与图形学学报, 2020, 32(8): 1324-1333.
Cao Jingang, Yang Guotian, Yang Xiyun. Pavement crack detection with deep learning based on attention mechanism[J]. Journal of Computer-Aided Design & Computer Graphics, 2020, 32(8): 1324-1333. (in Chinese with English abstract)
- [33] Hu J, Shen L, Sun G. Squeeze-and-excitation networks[C]// Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, Salt Lake City, USA: IEEE, 2018: 7132-7141.
- [34] Li R, Wang R, Zhang J, et al. An effective data augmentation strategy for CNN-based pest localization and recognition in the field[J]. IEEE Access, 2019, 7: 160274-160283.
- [35] Chen K, Wang J, Pang J, et al. MMDetection: Open mmlab detection toolbox and benchmark[J/OL]. Computer Vision and Pattern Recognition, 2019, [2019-06-17]. <https://arxiv.org/abs/1906.07155>.
- [36] Paszke A, Gross S, Massa F, et al. Pytorch: An imperative style, high-performance deep learning library[J]. Advances in Neural Information Processing Systems, 2019, 32: 8026-8037.
- [37] Scharr H. LSC as of CVPPP2017: evaluation of the testing data[EB/OL]. 2018, [2018-02-23]. <https://competitions.codalab.org/competitions/18405>.
- [38] Gomes D P S, Zheng L. Leaf segmentation and counting with deep learning: on model certainty, test-time augmentation, trade-offs[J/OL]. Computer Vision and Pattern Recognition, 2020, [2020-12-21]. <https://arxiv.org/abs/2012.11486>.
- [39] Ward D, Moghadam P, Hudson N. Deep leaf segmentation using synthetic data[J/OL]. Computer Vision and Pattern Recognition, 2019, [2019-03-21]. <https://arxiv.org/abs/1807.10931>.
- [40] 王志强, 钮丹丹, 王佳兴, 等. 大规模用水节点的灌溉物联网监控系统设计[J]. 排灌机械工程学报, 2021, 39(10): 1062-1067.
Wang Zhiqiang, Niu Dandan, Wang Jiaxing, et al. Design of IOT irrigation management system with large-scale nodes[J]. Journal of Drainage and Irrigation Machinery Engineering, 2021, 39(10): 1062-1067. (in Chinese with English abstract)

Segmentation method for plant leaves using an improved Mask R-CNN model

Yuan Shan¹, Tang Hao², Guo Ya^{1*}

(1. *Department of Internet of Things, Jiangnan University, Wuxi 214122, China;*

2. *Lushixin Sci. & Tec. (Wuxi) Co. Ltd., Wuxi 214124, China)*

Abstract: Extracting the leaves has been one of the most fundamental researches for the phenotypic traits of plants. However, it is difficult to further improve the accuracy of leaves segmentation, due to the mutual occlusion between leaves in rosette plants. It is still lacking in the leaf edge characteristics, particularly for the small target of young leaves. In this study, an improved instance segmentation benchmark Mask R-CNN model was proposed to realize an accurate segmentation for the plant leaves. The Cascade R-CNN was also introduced to generate the selection of the proposal boxes for the region proposal network. The boxes were first sent into the Head1 convolutional network with a threshold of 0.5, and then the detection was input into the Head 2 convolutional network with a threshold of 0.6, and finally, the detection was fed into the Head 3 convolutional network with a threshold of 0.7. Three cascaded networks were used to gradually increase the threshold, where the output of the previous network was applied to the higher threshold of the next network, indicating the high quality of the detection branch. After the segmentation branch full convolutional layer (FCN), an attention mechanism (SeNet) and a two-layer 3×3 convolution module were added to weigh the features of the segmentation branch, and further to extract the leaf edge segmentation. The segmentation of multi-scale leaves was also adopted for the leaves of different sizes in an image in the test process. The original and enlarged images were input into the model at the same time for the leaves segmentation. The optimal target on multiple scales was achieved using Non-Maximum Suppression (NMS). The ResNeXt101 was selected as the backbone network to extract the characteristics of leaves. An improved model of deep learning was also utilized at the same time. The image enhancement included random mirroring, rotation, enlargement, and size adjustment. There was no longer requiring for the special function library support, indicating the simplified data enhancement. The improved model had effectively reduced the blade occlusion, edge blur, and small target in the blade segmentation. Correspondingly, the Symmetric Best Dice (SBD) was 90.3% in the CVPPP Leaf Segmentation Challenge (LSC), which was 2.3 percentage points higher than that in Mask R-CNN, particularly than 1 percentage points than before. The improved neural network model was suitable for the leaf segmentation. The finding can provide a more accurate leaf segmentation for the plant phenotype using image processing, indicating a high application value in the research field of plant leaves.

Keywords: models; image processing; Mask R-CNN; plant leaves; attention mechanism; multi-scale segmentation