

基于改进 Mask R-CNN 的黄瓜叶面积测量模型

章永龙¹, 解亚玲¹, 徐向英¹, 缪旻珉^{2,3,4*}

(1. 扬州大学信息工程学院, 扬州 225000; 2. 扬州大学园艺与植物保护学院, 扬州 225000; 3. 教育部农业与农产品安全国际联合实验室, 扬州 225000; 4. 教育部植物功能基因组学重点实验室/江苏省作物基因组学与分子育种重点实验室, 扬州 225000)

摘要: 植物叶面积可以反映出植物的生长速率、养分吸收以及光合作用能力, 针对锯齿状边缘的黄瓜叶片分割精度较低, 叶面积测量误差较大等问题。该研究提出一种深度卷积网络模型 Marm, 在 Mask R-CNN 的基础上利用 Sobel 算子进行边缘检测, 使模型生成的掩膜更接近叶片的边缘。另外, 引入边缘损失以提升叶片边缘的分割精度。借助参照物标签, 利用模型输出的掩膜图像进行面积计算, 获得黄瓜叶片在不同生长周期的叶面积。试验结果表明, Marm 模型精确率、召回率和交并比达到 99.1%、94.87% 和 92.18%, 比原始的 Mask R-CNN 分别提高 1.28 个百分点、1.13 个百分点和 1.05 个百分点, 面积误差率下降 1.43 个百分点。当图像中存在叶片遮挡和阴影等多种影响, 黄瓜叶片的面积误差率仍然能保持在 5.45% 左右。该研究有效解决了锯齿状边缘的叶片分割问题, 将为植物表型研究提供技术支撑。

关键词: 图像分割; 深度学习; Mask R-CNN; 植物表型; 实例分割; 黄瓜

doi: 10.11975/j.issn.1002-6819.202303149

中图分类号: S24

文献标志码: A

文章编号: 1002-6819(2023)-17-0182-08

章永龙, 解亚玲, 徐向英, 等. 基于改进 Mask R-CNN 的黄瓜叶面积测量模型[J]. 农业工程学报, 2023, 39(17): 182-189. doi: 10.11975/j.issn.1002-6819.202303149 <http://www.tcsae.org>

ZHANG Yonglong, XIE Yaling, XU Xiangying, et al. Measuring the cucumber leaf area using improved Mask R-CNN[J]. Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE), 2023, 39(17): 182-189. (in Chinese with English abstract) doi: 10.11975/j.issn.1002-6819.202303149 <http://www.tcsae.org>

0 引言

黄瓜是一种重要的栽培蔬菜^[1], 叶片大小(面积)是生长速率、产量预测和品种特性的重要指标^[2-3]。区域卷积神经网络(region-based convolutional neural network, R-CNN)、数字红外热像、近红外和高光谱成像等技术已被用于识别黄瓜叶片的光合作用、病害和营养状况^[4-6], 但对黄瓜叶面积数字化、自动化评估研究甚少。因此亟需研究一种能够自动、精确测量黄瓜叶面积的方法。

随着人工智能技术的发展, 利用计算机视觉研究植物表型已成为当前的研究热点^[7-9]。计算机视觉通过摄像机和电脑模拟人类视觉, 对植物进行识别、跟踪、测量等操作, 并通过识别和分析做进一步的图形处理。许多学者在这方面已做了大量的工作, 如: 张帅^[10]提出了 CNN+SVM 和 CNN+Softmax 分类器识别方法, 分别对单一背景叶片图像的精确率为 91.11% 和 90.90%, 但识别复杂背景叶片图像精确率却分别只有 15.38% 和 34.38%; 朱永宁等^[11]利用 Faster R-CNN 对开花期和果实成熟期的枸杞进行识别判定, 识别结果的平均精确率为 74%; 王梁等^[12]以自然场景下的油茶果为研究对象, 考虑树叶遮

挡、果实重叠、不同背景、果实色度、光照等影响因素, 利用 Mask R-CNN 模型对油茶果进行检测识别, 平均检测精确率为 89.42%; 龙洁花等^[13]对温室环境下不同成熟番茄果实进行实例分割研究, 通过融合 Mask R-CNN 模型中的残差网络与跨阶段局部网络, 平均精确率达到 95.45%。但处理遮挡严重、光照较弱样本时, 模型精确率有所下降; 袁山等^[14]提出一种改进的 Mask R-CNN 模型对公开数据集 CVPPP(拟南芥和烟草花)进行实例分割。采用注意力机制、卷积模块、级联检测模块及多尺度分割策略解决叶片遮挡、幼叶过小叶片分割效果差的问题, 精确率达到 90.3%; 郭奕等^[15]在 Mask R-CNN 基础上融合 SimAM 注意力机制, 在具有真实养殖环境特点的自建数据集上进行性能测试, 精确率达到 96.16%。上述研究工作主要改进现有的卷积神经网络对光滑边缘物体进行识别与分割, 进一步提升精确度和鲁棒性。而对于那些不规则边缘的物体, 相关研究较少。然而, 在现实生态和农业环境中, 很多植物结构具有复杂的形态和边缘特征, 如叶片的锯齿状边缘、果实表面凹凸不平等等。这些不规则特征给植物表型研究带来了额外的挑战。针对上述存在的问题, 本文提出了一种改进的 Mask R-CNN 模型。以边缘呈锯齿状的黄瓜叶片作为研究对象, 利用 Sobel 算子进行边缘检测, 提高了分割精确率。

在叶面积测量方面, 主要有叶面积仪测量法、方格纸法、称重法和 Matlab 软件计算等。张鑫等^[16]使用 CI-203 手持式激光叶面积仪分别测量两个品种的大豆叶片, 记录各个叶片的面积值。试验发现叶面积仪的测定结果较准确, 但需要破坏作物群体结构, 而且所用的仪器设

收稿日期: 2023-03-21 修订日期: 2023-08-14

基金项目: 江苏研究与试验发展(R&D)基金(BE2022425); 扬州市市校合作专项(YZ2021150, YZ2022179)

作者简介: 章永龙, 博士, 硕士生导师, 研究方向为知识推荐、机制设计及计算机视觉。Email: ylzhang@yzu.edu.cn

*通信作者: 缪旻珉, 教授, 博士生导师, 研究方向为蔬菜栽培及表型研究, Email: mmmiao@yzu.edu.cn

备比较昂贵,其测量范围也比较小;李秀启等^[17]利用方格纸法测得叶面积,将采集的叶片压在坐标纸上,用细铅笔把黄瓜叶片轮廓细心而准确地描在坐标纸上,然后统计叶轮廓所占的小方格数。但方格纸法存在操作耗时费工的问题,而且准确度较低。王雪晴等^[18]借助 MATLAB 丰富的图像处理功能对叶片图像进行了一系列的图像处理,计算出乔木叶片的面积,与真实叶面积的平均误差值为 0.564%;于守超等^[19]运用 Photoshop CS5 软件自动化提取广玉兰叶面积,具有更高的准确性、稳定性。马丽等^[20]以杨树叶片为试验对象,通过灰度化、二值化和开运算等预处理提取边框,利用几何校正去除叶柄求出叶面积。图像处理法^[21]以操作简单、效率高等优点成为主流的叶面积测量方法。然而,上述试验需要将叶片采摘下来,从而给植物自然生长带来影响,而本文提出一种在自然场景下对黄瓜叶面积进行测量的方法。

1 标材料与与方法

1.1 图像采集

2022 年 9 - 11 月,利用华为 mate30 5G 手机设备采集扬州大学蔬菜基地温室大棚(32.29°N, 119.48°E)内的幼苗期到结果期(图 1 所示)的黄瓜图像。考虑到光照和阴影的影响,数据集包含背光和阳光直射条件下的样本。图像中的标签(图 1a 方框内)作为叶面积计算的参照物。

为确保叶面积计算的准确性,如图 2 所示,首先使用支撑物(直尺)来稳定叶片,防止其倾斜并确保叶片与标签处于同一水平面上。其次,控制拍摄距离范围在 0.7 m 左右,调整摄像头与叶片表面的倾斜角度为 30°,以尽可能减少形变和畸变影响。另外,为了降低训练的复杂性,将图像大小统一调整为 512 像素×512 像素。





图 1 黄瓜叶片图像样本
Fig.1 Samples of cucumber leaf images



1.黄瓜植株 2.三脚架
1.Cucumber plant 2.Tripod

图 2 图像采集示意图
Fig.2 Diagram of image acquisition

1.2 数据预处理

本文采用亮度增强、对比度增强、旋转图像、翻转图像、仿射变化扩充图像、错切变化扩充图像和 HSV 数

据增强^[22]等 7 种增强方式(如图 3 所示)对图像数据集进行扩增。




图 3 图像数据增强
Fig.3 Data Augmentation

经过数据增强的图像中选取 1 025 张图像作为本研究的数据集,并按照 8:2 的比例分为训练集和测试集,其中训练集图像 820 张,测试集图像 205 张。使用开源工具 Labelme 对训练集进行人工标注,标注出叶片和标签边缘从而确定目标区域。虽然 Labelme 与 EISeg 等半自动图像标注工具相比耗时,但是标注精度较高,能够得到标注图像及对应的 Json 文件。然后将标注好的 Json 文件转换成网络训练所用的 COCO 数据集格式。

由于图像是在自然场景下采集,可能会存在叶片遮挡、强烈光照和光线不足等影响因素。将测试集的图像分类为单影响因素图像和多影响因素图像,其中单影响因素图像是指图像只存在上述影响因素中的一个,如遮挡;多影响因素图像是指图像存在两个及以上的影响因素。

验证集包含单影响因素的图像 105 张,多影响因素的图像 100 张。在图 4a 中,只含有阴影单因素,阴影(方框处)使得这部分的叶片图像呈黑色,模型容易识别不出这部分叶片,导致精确率较低。在图 4b 中存在叶片遮挡和阴影的情况,叶片遮挡易导致下层叶面积计算出现误差。




图 4 测试集样本
Fig.4 Samples of test set

1.3 Marm 模型

1.3.1 Mask R-CNN 基本结构

Mask R-CNN^[23]是一种在 Faster RCNN 的基础上拓展的实例分割框架(如图 5 所示),其具有较高的目标定位精度、高质量的像素掩模,可用于像素级别的分割任务,获得形状、面积和轮廓等几何属性。Mask R-CNN 模型主要包括 4 个部分:主干网络、RPN(区域推荐网络)、ROI Align(感兴趣区域校正)和输出分支。




图 5 Mask R-CNN 基本结构
Fig.5 The basic structure of Mask R-CNN

主干网络主要是由 ResNet^[24] 和 FPN (特征金字塔网络) 组成, 通过若干残差块构成的残差网络 ResNet34/50/101 进行特征提取实现跨层连接, 并构建恒等映射 (identity mapping) 来解决网络退化问题。FPN 将从每个阶段提取的特征图再进行特征融合, 每一层特征图融合了不同分辨率和语义强度的特征, 进而能够在多个尺度上更好地表征目标。RPN 利用滑动窗口对特征图进行扫描寻找存在目标的区域, 以推荐感兴趣的区域。每个滑动窗口生成一组 3 种不同长宽比 (1:1, 1:2, 2:1)、大小 (128, 256, 512) 的锚框。对每个锚框进行两个分支处理, 其中一个分支利用 softmax 进行二分类, 判断锚框中目标的类别是前景还是背景并以分数的形式输出, 若锚框中有目标物体, 则判定为前景, 否则为背景; 另一个分支对锚框位置和尺寸进行调整, 贴近目标物体并输出坐标。Proposal 层利用非极大值抑制 (NMS) 和设置阈值等方法对锚框进行筛选得到 ROI。ROI Align 对特征图的四个边界点进行双线性插值, 固定这四个点坐标的像素值。通过 ROI Align 操作, 使得具有不同特征大小的输入区域, 均可以得到相同大小输出特征。最后, Mask R-CNN 模型输出分类、定位回归、掩膜分割。

1.3.2 Mask R-CNN 改进优化

Mask R-CNN 应用于叶片边缘呈锯齿状的黄瓜叶片, 存在分割精度较低的问题。其原因是叶片边缘与背景交界处像素值的波动幅度较大, 使得模型对叶片边缘定位不准确, 最终导致分割不理想。边缘通常是指像素值发生跃迁的地方 (变化率最大处, 导数最大处), 是图像的显著特征之一, 在图像特征提取、对象检测、模式识别等方面都有重要的作用。本文对 Mask R-CNN 模型的 Mask 分支 (如图 6 所示) 进行扩展。

从 Mask 分支的 $28 \times 28 \times 80$ 维输出中, 选择叶片类别掩膜, 结合真值掩膜作为扩展模块的输入, 通过一个 $3 \times 3 \times 2$ 维的边缘检测滤波器 (Sobel 滤波器), 进行卷积分别得到 $28 \times 28 \times 2$ 的叶片预测和真值边缘, 利用均方误差 (binary cross-entropy) 得到损失项 L_{edge} 。

Sobel 算子^[25] 是比较常用的一阶微分边缘检测算子, 引入类似局部平均的运算, 对噪声具有平滑作用, 能很好地消除噪声的影响, 强调和边缘相邻的像素点对边缘的影响。与 Prewitt 算子^[26] 相比, Sobel 算子对于像素位置的影响做了加权, 可以降低边缘模糊程度, 因此效果更好。




图 6 改进的 Mask 分支
Fig.6 Improved Mask branch

改进思路是使用两个 3×3 的矩阵 (水平和垂直模板) 去和原始图片进行卷积操作, 设原始图像为式 (1), 其中 p_i 是像素点的数值。根据式 (2) 和 (3) 分别得到水平和垂直方向的亮度差分近似值, 因此 Sobel 边缘检测具有方向性, 对水平和垂直方向的边缘检测具有较好的效果。然后为了降低噪声的影响, 由式 (4) 计算水平和垂直梯度近似值, 并且由式 (5) 得到梯度的方向, 如果梯度值大于某一个阈值, 则认为该点为边缘点。

$$I(x, y) = \begin{pmatrix} p_1 & p_2 & p_3 \\ p_4 & p_5 & p_6 \\ p_7 & p_8 & p_9 \end{pmatrix} \quad (1)$$

$$G_x = \begin{pmatrix} -1 & 0 & 1 \\ -2 & 0 & 2 \\ -1 & 0 & 1 \end{pmatrix} I(x, y) \quad (2)$$

$$G_y = \begin{pmatrix} 1 & 2 & 1 \\ 0 & 0 & 0 \\ -1 & -2 & -1 \end{pmatrix} I(x, y) \quad (3)$$

$$G = \sqrt{G_x^2 + G_y^2} \quad (4)$$

$$\Theta = \arctan\left(\frac{G(y)}{G(x)}\right) \quad (5)$$

由于损失函数作为决定深度神经网络预测效果的重要参数之一, 极大地影响了模型的收敛速度, 也控制着网络的目标, 所以本试验主要在损失函数中进行改进。

原始 Mask R-CNN 算法的损失函数 L_{MRCNN} 分别由分类损失 L_{cls} 、边框损失 L_{box} 和掩膜损失 L_{mask} 构成, 如式 (6) 所示。其中 L_{cls} 为分类损失函数, 表示目标的类别分类损失程度, 如式 (7) 所示。 L_{box} 为边框回归损失函数, 表示目标的检测框坐标的损失程度, 如式 (8) 所示。 L_{mask} 为掩膜损失函数, 表示目标的掩膜分割网络的损失程度, 如式 (9) 所示。将标记的目标边缘和预测边缘的均方误差记为 (如式 (10) 所示) 加入损失函数。但由于添加新的损失项可能影响现有的损失函数之间存在平衡和增加模型的计算成本, 所以本文引入了一个权重因子 λ 以确保新的损失函数能够有效地改进模型性能, 并在实际应用中表现良好, 如式 (11) 所示。

$$L_{MRCNN} = L_{cls} + L_{box} + L_{mask} \quad (6)$$

$$L_{cls} = -\ln[p_i \cdot p_i^* - (1 - p_i^*)(1 - p_i)] \quad (7)$$

$$L_{box} = \text{SmoothL1}(x) = \begin{cases} 0.5x^2, & \text{if } |x| < 1 \\ |x| - 0.5, & \text{other} \end{cases} \quad (8)$$

$$L_{mask} = -\sum_y y \ln(1 - \hat{y}) + (1 - y) \ln(1 - \hat{y}) \quad (9)$$

$$L_{edge} = \frac{1}{n} \sum_1^n (y - \hat{y})^2 \quad (10)$$

$$L = L_{cls} + L_{box} + L_{mask} + \lambda L_{edge} \quad (11)$$

式中 p_i 和 p_i^* 代表候选区域含有目标的概率值和概率期望值; SmoothL1 代表鲁棒损失函数, x 为输入值; y 和 $\hat{y}$ 分别为真实值和模型预测的输出掩膜; n 为边缘点数量, λ 为权重因子, L 为新的损失函数。

1.4 黄瓜叶面积计算

由于模型最终输出图像是彩色的而且掩膜的颜色不能完全覆盖住底层的原图像, 若只根据掩膜颜色这一属性来统计掩膜的像素点数量会受到图片中其他具有相同颜色物体影响, 从而产生极大的误差。因此, 使用 OpenCV 对模型输出的图像进行二值化处理^[27], 从而得到每个叶片和标签的掩膜二值化图像 (如图 7 所示)。其中间每个叶片的二值图分别对应输出图中不同颜色的叶片掩膜。最后把每一个目标的掩膜保存到本地文件中。在二值化图像中, 黑色 (像素值为 0) 代表背景; 白色 (像素值为 255) 代表目标物体 (叶片和标签)。




图 7 掩膜二值化图

Fig.7 Binary image of the mask

对处理过的掩膜二值化图像, 利用 python 代码统计该图像中白色和黑色像素点个数 (即目标物体和背景的像素点数量), 计算出叶片和标签的像素点数量, 由下式求出叶片的真实面积 S 。

$$S = S_1 / S_2 S_0 \quad (12)$$

式中 S_1 代表叶片的像素点数量, S_2 代表标签像素点数量, S_0 代表标签的真实面积。

在试验中, 将上述所获得叶面积值 (式 12) 与人工测量值进行对比, 以衡量叶面积测量的准确度。人工测量叶面积计算如下^[28]:

$$S = 0.743lW \quad (13)$$

式中 l 代表叶长 (叶柄至叶尖的长度), cm; W 代表叶宽 (中部两角间的长度), cm。

1.5 试验环境

在 Windows11 操作系统下, 使用 NVIDIA GeForce RTX 3050 Ti 显卡。构造 tensorflow1.5.0+keras 框架, 配置安装 Python3.6 环境。模型训练时首先采用在 COCO 数据集上训练好的预训练权重进行迁移学习以完成网络参数初始化, 再将自标注的叶片数据集转化为 COCO 数据集格式后送入网络进行训练。为了提高训练效果减小损失, 调整参数的大小来进行训练模型, 从而确定参数值。在本试验中批量大小设为 2, 学习率设为 0.001, 动量因子设为 0.9, 训练 100 个 epoch。

1.6 评价指标

本文试验使用精确率 (precision, P)、召回率 (recall, R)、交并比 (intersection over union, I_{ou}) 及面积误差率 (area error rate, A_{ER}) 等 4 个评价指标以验证模型的分割效果, 其计算公式分别如式 (14) ~ (17) 所示。

$$P = \frac{T_p}{T_p + F_p} \quad (14)$$

$$R = \frac{T_p}{T_p + F_n} \quad (15)$$

$$I_{ou} = \frac{S_{\Omega_r \cap \Omega_{gt}}}{S_{\Omega_r \cup \Omega_{gt}}} \quad (16)$$

$$A_{ER} = \left| 1 - \frac{S_g}{S_l} \right| \quad (17)$$

式中 T_p (true positive) 代表检测正确的叶片像素点数量, F_p (false positive) 代表检测出是叶片的像素点事实上是背景的像素点数量。 F_n (false negative) 代表检测出是背景的像素点事实上是叶片的像素点数量; Ω_r 代表模型检测出的掩膜, Ω_{gt} 代表真值掩膜, $S_{\Omega_r \cap \Omega_{gt}}$ 代表两掩膜相交的部分面积, $S_{\Omega_r \cup \Omega_{gt}}$ 代表两掩膜所占有的所有面积; S_g 代表估算的叶面积, S_l 代表叶片的真实面积。

2 结果与分析

2.1 主干网络选取

针对锯齿状边缘叶片, 采用不同主干网络的 Marm 模型与 Mask R-CNN 模型在测试集上的检测分割试验结果如表 1 所示。可以看出, Mask R-CNN 模型的精确率、召回率、交并比和面积误差率分别为 97.82%、93.74%、91.03% 和 5.80%。而以 ResNet101 为主干网络的 Marm 模型相比 Mask R-CNN 模型在精确率、召回率和交并比方面, 分别提高了 1.28 个百分点、1.13 个百分点和 1.05 个百分点, 面积误差率下降 1.43 个百分点。这说明边缘检测可以提高模型对边缘的分割精度, 且克服了叶片的

锯齿状边缘导致模型将边缘部分像素点类别错分为背景的问题。相比于 ResNet101 主干网络, ResNet34 和 ResNet50 则精确率分别降低了 1.07 个百分点和 0.52 个百分点, 召回率分别降低了 0.63 个百分点和 1.22 个百分点, 交并比降低了 0.67 个百分点和 0.31 个百分点, 同时面积误差率上升。在后续试验中, 本文以 ResNet101 为 Marm 模型的主干网络。

表 1 不同主干网络模型的性能结果
Table 1 Performance results of different backbone network models %

模型 Model	主干网络 Backbone	精确率 Precision	召回率 Recall	交并比 Intersection over union	面积误差率 Area erro rate
Mask R-CNN	ResNet101	97.82	93.74	91.13	5.80
Marm-34	ResNet34	98.03	93.65	91.51	5.53
Marm-50	ResNet50	98.58	94.24	91.87	4.99
Marm-101	ResNet101	99.10	94.87	92.18	4.37

如图 8 所示, 4 张图分别是叶片图像经过 Mask R-CNN、Marm (ResNet34)、Marm (ResNet50) 和 Marm (ResNet101) 模型处理后的效果图。




图 8 分割对比图

Fig.8 Comparison images of segmentation

可以看出在方框标出的地方 Mask R-CNN (图 8a) 输出的掩膜离叶片边缘还有一定的距离, 而改进后的模型输出的掩膜逐渐靠近叶片边缘, 并且主干网络为 ResNet101

(图 8b) 的改进模型输出的掩膜要更为贴近。综上所述, 主干网络为 ResNet101 的 Marm 模型相较于其他主干网络对具有锯齿状边缘的黄瓜叶片分割效果最好, 且输出的掩膜更贴合叶片边缘, 从而叶面积估算最精确。

2.2 L_{edge} 权重因子选取

引入权重因子 λ 来权衡损失项 L_{edge} 对整体损失的影响, 通过试验分析不同取值的效果, 如图 9 所示, 可以发现 λ 的数值由 0.5 增加到 1 时, Marm 模型的总损失和边缘损失都下降, 但当 λ 的数值继续增加到 2 和 4 时, Marm 的总损失和边缘损失都呈上升趋势, 且其他损失项较高。因此, 发现权重因子取值为 1 时, 显示出在加强掩膜预测的同时, 能有效平衡网络的其他损失项。




图 9 权重因子对损失函数的影响

Fig.9 The impact of weight factors on the loss function

2.3 不同遮挡程度叶片的分割性能

采集的照片中, 黄瓜叶片遮挡的情况按照遮挡率分为轻微遮挡、中度遮挡和严重遮挡共 3 类照片 (如图 10 所示)。




图 10 不同遮挡程度的黄瓜叶片

Fig.10 Cucumber leaves with varying degrees of obstruction

在不同分割模型中对不同遮挡程度叶片的分割性能如表 2 所示, 从表格数据可知, Marm 模型的分割性能优于目前主流的目标检测算法。但当叶片遮挡程度增加时, 特别是当叶片被严重遮挡时, 分割的准确率明显下降。此外, 由于 Marm 模型添加边缘损失只增加了模型的规模且未增加训练模型的变量, 所以参数量增加的较小。

表 2 不同分割模型中对不同遮挡程度叶片的分割性能

Table 2 Segmentation performance of different models on leaves with varied degrees of occlusion

模型 Model	主干网络 Backbone	精确率 Precision/%			平均精确率 Average precision/%	召回率 Recall /%	参数量 Parameters/M	平均分割时间 Average segmentation time/s
		轻微遮挡 Slight obstruction	中度遮挡 Moderate obstruction	严重遮挡 Severe obstruction				
Faster R-CNN	ResNet50	92.25	89.53	88.37	90.07	88.78	67.90	0.450
YOLOv5	CSPDarknet	95.10	94.73	92.52	94.30	91.10	24.06	0.407
Mask R-CNN	ResNet101	98.34	96.02	95.35	97.82	93.74	245.50	0.511
Marm	ResNet101	99.28	98.53	97.90	99.1	94.87	248.97	0.530

如图 11 中 Faster R-CNN^[29] 和 YOLOv5 模型^[30] 无法识别出被严重遮挡的下层叶片。这是由于被遮挡的叶片会有阴影存在, 从而导致被遮挡的叶片与背景相似, 模型难以区分黄瓜叶片的特征。虽然本文模型的性能在一定程度会

受到叶片遮挡的影响, 但是相对于其他分割模型, Marm 模型对不同遮挡程度的黄瓜叶片是具有较好的分割性能。

2.4 黄瓜叶片不同生长周期的试验结果

图 12 为 Marm (ResNet101) 模型输出的黄瓜叶片

生长周期试验样例。可以看出，在幼苗/初花期（图 12a、12b），椭圆形叶片与锯齿状边缘的叶片分割效果相差较小；而在结果期（图 12c），叶片识别分割效果却没有幼苗期和初花期好，其主要原因在于该时期叶片多而杂乱并且有黄瓜果实遮挡的影响。在未来工作中，将针对上述问题进行深入研究。




图 11 不同分割模型对遮挡黄瓜叶片的分割效果
Fig.11 Segmentation performance comparison of different models on occluded cucumber leaves




图 12 黄瓜叶片生长周期试验样例
Fig.12 Samples of cucumber leaf growth cycle experiment

2.5 叶面积测量结果分析

为检验量化的叶面积识别效果，从测试集中随机挑选 40 个样本，即分别选取 20 张幼苗时期面积较小的黄瓜叶片图像和 20 张初花期和结果时期面积较大的黄瓜叶片图像。对黄瓜叶面积分别进行人工测量和模型估计，并得到其线性相关关系。

Marm 模型与人工测量对比结果如图 13 所示。




图 13 黄瓜叶面积模型测量结果与人工测量结果对比
Fig.13 Comparison of cucumber leaf area model measurement results with manual measurements

图中 y 轴是 Marm（ResNet101）检测后图片进行一系列图像处理操作得出的叶面积，x 轴是人工测量的叶面积。图 13a 的图样本数据是面积较小的黄瓜叶片，其

决定系数 R^2 为 0.995；图 13b 的图样本数据是面积较大的黄瓜叶片，其决定系数 R^2 为 0.956。可以看出改进后的模型估算面积较小的黄瓜叶面积与真实值比较接近，而面积较大的黄瓜叶片估算面积与真实面积有一定差距。这是由于面积较大的黄瓜叶片一般处于初花期和结果期，而这段时期图像由于叶片数量多和叶片遮挡影响模型识别像素点，从而叶面积估计不准确。

2.6 单影响因素和多影响因素图像分析

表 3 给出了 Marm（ResNet101）模型对单影响因素和多影响因素的识别效果。

Table 3 Experimental results of single-factor and multi-factor images					
图像种类 Types of images	数量 Number	精确率 Precision	召回率 Recall	交并比 Intersection over union	面积误差率 Area error rate %
单影响因素图像 Single-factor images	105	99.35	95.45	92.68	2.99
多影响因素图像 Multi-factor images	100	97.98	93.74	91.35	5.45

可以看出，对于所有单影响因素，精确率在 99.35% 左右，面积误差率在 2.99% 左右；对多影响因素情况，精确率也维持在 97.98% 左右，面积误差率在 5.45% 左右。因此，Marm（ResNet101）模型即使在自然环境中的多重影响因素下，也能准确分割识别黄瓜叶片和面积估算。

3 结 论

本文选择黄瓜叶片作为研究对象，针对锯齿状边缘的识别精度要比光滑的要低的问题，在 Mask R-CNN 的掩码分支中增加边缘损失，提高检测精确度。

1) 试验结果显示，以 ResNet101 为主干网络的 Marm 模型对黄瓜叶片分割的精确率为 99.10%，召回率为 94.87%，交并比为 92.18%。如表 2 所示，本研究 Marm 模型的精确率相比 Faster R-CNN 模型、Yolov5 模型、以 ResNet101 为主干网络的 Mask R-CNN 模型分别提高了 9.03、4.8 和 1.28 个百分点。这表明对神经网络模型本身提出改进可以有效应用于叶片分割领域以解决锯齿状边缘分割效果不佳的问题。

2) 改进后的模型去检测不同遮挡程度的黄瓜叶片，试验表明叶片遮挡越严重，模型的精确率会下降。但即使是多影响因素图像，精确率保持在 97.98% 左右。针对此问题，未来考虑使用深度相机等工具采集植物三维点云数据，以获取更丰富的三维信息，有助于更准确地重建植物结构，精确地计算叶面积。

3) 将在自然场景下采集的图像输入改进后的模型，得到叶片和标签的掩膜图像，进一步计算叶面积。虽然存在遮挡和阴影等影响，但面积误差率能控制在 5.45% 左右，并且无需采摘叶片进行离体测量，更能适用于实际叶面积测量场景。

【参 考 文 献】

[1] 袁泉, 卢威, 王君, 等. 基于辐射累积量的灌溉策略对不同土壤质地温室黄瓜产量和品质的影响[J]. 农业工程学报, 2023, 39(11): 98-105.

- YUAN Quan, LU Wei, WANG Jun, et al. Effects of the irrigation strategies of accumulated solar radiation on cucumber yield and quality under different soil textures in the greenhouse[J]. Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE), 2023, 39(11): 98-105.
- [2] Bogacheva I A. Size-dependent selective leaf damage by insects and some methodological implications of this phenomenon[J]. Russian Journal of Ecology, 2002, 33(6): 423-428.
- [3] 邹青青, 吴含玉, 刘东焕, 等. 植物光合作用的三维特性研究进展[J]. 植物学报, 2022, 57(2): 250-258.
ZOU Qingqing, WU Hanyu, LIU Donghuan, et al. Advances in three-dimensional characteristics of photosynthesis in plants[J]. Chinese Bulletin of Botany, 2022, 57(2): 250-258. (in Chinese with English abstract)
- [4] BELLO R W, ADIPERE G F. Application of region-based convolutional neural network for prompt Segmentation between infected cucumber leaves and healthy cucumber leaves[J]. Journal of Applied Sciences and Environmental Management, 2022, 26(11): 1791-1797.
- [5] 张颜如, 邵鹏帅. 棚龄对大棚种植黄瓜品质影响的傅里叶变换红外光谱研究[J]. 光谱学与光分析, 2022, 42(6): 1816-1821.
ZHANG Yanru, SHAO Pengshuai. Study on the effects of planting years of vegetable greenhouse on the cucumber qualities using mid-IR spectroscopy[J]. Spectroscopy and Spectral Analysis, 2022, 42(6): 1816-1821. (in Chinese with English abstract)
- [6] AFKARI-SAYYAH A H. Near-infrared spectroscopy for non-destructive determination of quality of fresh cut cucumber during shelf life[J]. Journal of Environmental Science Studies, 2022, 7(2): 4787-4798.
- [7] Huixian J. The analysis of plants image recognition based on deep learning and artificial neural network[J]. IEEE Access, 2020, 8(1): 68828-68841.
- [8] Liu J, Wang X. Plant diseases and pests detection based on deep learning: A review[J]. Plant Methods, 2021, 17(1): 1-18.
- [9] Xiong J, Yu D, Liu S, et al. A review of plant phenotypic image recognition technology based on deep learning[J]. Electronics, 2021, 10(1): 81-99.
- [10] 张帅. 基于深度学习的植物叶片识别算法研究[D]. 北京: 北京林业大学, 2016.
ZHANG Shuai. Research on plant leaf images identification algorithm based on deep learning[D]. Beijing: Beijing Forestry University, 2016. (in Chinese with English abstract)
- [11] 朱永宁, 周望, 杨洋, 等. 基于 Faster R-CNN 的枸杞开花期与果实成熟期识别技术[J]. 中国农业气象, 2020, 41(10): 668-677.
ZHU Yongning, ZHOU Wang, YANG Yang, et al. Automatic Identification Technology of Lycium barbarum Flowering Period and Fruit Ripening Period Based on Faster R-CNN[J]. Chinese Journal of Agrometeorology, 2020, 41(10): 668-677. (in Chinese with English abstract)
- [12] 王梁, 侯义锋, 贺杰. 基于 Mask-RCNN 的自然场景下油茶果目标识别与检测[J]. 中国农机化学报, 2022, 43(12): 148-154.
WANG Liang, HOU Yifeng, HE Jie. Target recognition and detection of camellia oleifera fruit in natural scene based on Mask-RCNN[J]. Journal of Chinese Agricultural Mechanization, 2022, 43(12): 148-154. (in Chinese with English abstract)
- [13] 龙洁花, 赵春江, 林森, 等. 改进 Mask R-CNN 的温室环境下不同成熟度番茄果实分割方法[J]. 农业工程学报, 2021, 37(18): 100-108.
LONG Jiehua, ZHAO Chunjiang, LIN Sen, et al. Segmentation method of the tomato fruits with different maturities under greenhouse environment based on improved Mask R-CNN[J]. Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE), 2021, 37(18): 100-108. (in Chinese with English abstract)
- [14] 袁山, 汤浩, 郭亚. 基于改进 Mask R-CNN 模型的植物叶片分割方法[J]. 农业工程学报, 2022, 38(1): 212-220.
YUAN Shan, TANG Hao, GUO Ya. Plant leaf segmentation method based on improved Mask R-CNN model[J]. Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE), 2022, 38(1): 212-220. (in Chinese with English abstract)
- [15] 郭奕, 黄佳芯, 邓博奇, 等. 改进 Mask R-CNN 的真实环境下鱼体语义分割[J]. 农业工程学报, 2022, 38(23): 162-169.
GUO Yi, HUANG Jiaxin, DENG Boqi, et al. Semantic segmentation of the fish bodies in real environment using improved Mask-RCNN model[J]. Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE), 2022, 38(23): 162-169. (in Chinese with English abstract)
- [16] 张鑫, 孟繁疆. 植物叶面积测定方法的比较研究[J]. 农业网络信息, 2008(12): 14-15.
ZHANG Xin, MENG Fanjiang. Comparative study on the measure methods of the plant leaf area[J]. Agricultural Network Information, 2008(12): 14-15. (in Chinese with English abstract)
- [17] 李秀启, 李晓琳, 李颜, 等. 黄瓜叶面积测量方法的评价[J]. 长江蔬菜, 2008(6): 71-73.
LI Xiuqi, LI Xiaolin, LI Yan, et al. Evaluation of the measure methods of cucumber leaf area[J]. Journal of Changjiang Vegetables, 2008(6): 71-73.
- [18] 王雪晴, 郭亚航. 基于视觉技术的植物叶片面积测量研究[J]. 农业与技术, 2020, 40(20): 8-11.
- [19] 于守超, 张秀省, 冀芦莎. 基于 Photoshop CS5 的植物叶面积测定方法[J]. 湖北农业科学, 2012, 51(15): 3340-3342.
YU Shouchao, ZHANG Xiusheng, JI Lusha. A method for leaf area measurement of plant based on Photoshop CS5 software [J]. HUBEI AGRICULTURAL SCIENCES, 2012, 51(15): 3340-3342. (in Chinese with English abstract)
- [20] 马丽, 陶佳, 杜秋菊. 基于图像处理的植物叶面面积计算算法研究[J]. 安徽农业科学, 2011, 39(25): 15812-15814.
MA Li, TAO Jia, DU Qiuju. Study on Calculation Algorithm of Plant Leaf Area Based on Image Processing [J]. Journal of Anhui Agricultural Sciences, 2011, 39(25): 15812-15814. (in Chinese with English abstract)
- [21] 宋英博. 数字图像处理技术在叶面积测量中的应用[J]. 农学报, 2022, 12(2): 73-75.
SONG Yingbo. Leaf area measurement system based on digital image processing technology[J]. Journal of Agriculture, 2022, 12(2): 73-75. (in Chinese with English abstract)
- [22] 冯晓硕, 沈樾, 王冬琦. 基于图像的数据增强方法发展现状综述[J]. 计算机科学与应用, 2021, 11(1): 370-383.
FENG Xiaoshuo, SHEN Yue, WANG Dongqi. A survey on the development of image data augmentation[J]. Computer Science and Application, 2021, 11(1): 370-383. (in Chinese with English abstract)
- [23] HE K, GKIOXARI G, DOLLAR P, et al. Mask r-cnn[C]//Proceedings of the IEEE International Conference on

- Computer Vision. Honolulu, HI, USA: IEEE, 2017.
- [24] SARWINDA D, PARADISA R H, BUSTAMAM A, et al. Deep learning in image classification using residual network (ResNet) variants for detection of colorectal cancer[J]. Procedia Computer Science, 2021, 179: 423-431.
- [25] Vairalkar M K, Nimbhorkar S U. Edge detection of images using Sobel operator[J]. International Journal of Emerging Technology and Advanced Engineering, 2012, 2(1): 291-293.
- [26] GAO Q, CHEN J, JI Y, et al. The edge extraction method of casting images based on improved canny operator[C]//2022 IEEE International Conference on Mechatronics and Automation (ICMA). Guangxi, China: IEEE, 2022: 1708-1713.
- [27] 唐海童. 基于深度学习的裂缝检测算法研究及应用[D]. 连云港: 江苏海洋大学, 2023.
- TANG Haitong. Research and Application of crack detection algorithms based on deep learning[D]. Lianyungang: Jiangsu Ocean University, 2023. (in Chinese with English abstract)
- [28] 裴孝伯, 李世诚, 张福漫, 等. 温室黄瓜叶面积计算及其与株高的相关性研究[J]. 中国农学通报, 2005, 21(8): 80-82.
- PEI Xiaobo, LI Shicheng, ZHANG Fumai, et al. Study on leaf area calculation and its correlation with plant height of cucumber in greenhouse [J]. Chinese Agricultural Science Bulletin, 2005, 21(8): 80-82. (in Chinese with English abstract)
- [29] GIRSHICK R. Fast r-cnn[C]//Proceedings of the IEEE International Conference on Computer. Vision Boston, MA, USA: IEEE, 2015: 1440-1448.
- [30] 尚钰莹, 张倩如, 宋怀波. 基于 YOLOv5s 的深度学习在自然场景苹果花朵检测中的应用[J]. 农业工程学报, 2022, 38(9): 222-229.
- SHANG Yuying, ZHANG Qianru, SONG Huaibo. Application of deep learning using YOLOv5s to apple flower detection in natural scenes[J]. Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE), 2022, 38(9): 222-229. (in Chinese with English abstract)

Measuring the cucumber leaf area using improved Mask R-CNN

ZHANG Yonglong¹, XIE Yaling¹, XU Xiangying¹, MIAO Minmin^{2,3,4*}

(1. School of Information Engineering, Yangzhou University, Yangzhou 225000, China; 2. School of Horticulture and Plant Protection, Yangzhou University, Yangzhou 225000, China; 3. Joint International Research Laboratory of Agriculture and Agri-Product Safety of Ministry of Education of China, Yangzhou University, Yangzhou 225000, China; 4. Key Laboratory of Plant Functional Genomics of the Ministry of Education/Jiangsu Key Laboratory of Crop Genomics and Molecular Breeding, Yangzhou University, Yangzhou 225000, China)

Abstract: The plant leaf area can serve as an indicator of the plant's growth rate, nutrient uptake, and photosynthetic efficiency. However, some challenges are still remained to accurately segment the leaf areas and subsequent measurements, particularly with the leaves bearing some distinct characteristics, such as the serrated edges found on cucumber leaves. It is a high demand to promote the reliability of research outcomes and practical applications in the field of agriculture. In this study, an innovative "Marm" model was introduced to measure the cucumber leaf area from the realm of deep convolutional neural networks (CNN). The architecture of Mask R-CNN was also extended to incorporate the Sobel operator. The intricate contours of cucumber leaf edges were capture and detect using the Sobel operator with the enhanced edge details. A suite of mask was obtained to fully depicted the intricate topography inherent in these leaves. Among them, the edges were acted as a connective thread weaving precision into the process. The architecture of the model was enhanced to introduce a tailored component of edge loss. A strategic addition was then used to improve the segmentation accuracies. A weight factor was introduced into the new loss component, in order to balance among the existing loss functions and potentially computational costs. The better performance of the improved model was then effectively enhanced with the pragmatic feasibility. A comprehensive strategy was employed to leverage a synergistic blend of model-generated mask images and validated reference object labels. The morphological intricacies and contextual validation were integrated to facilitated the steadfast and reliable measurements of cucumber leaf area across various growth stages. A better resilience of data and validation was then established to deftly navigate the diverse terrain of leaf morphology from germination to maturity. The precision, recall, and Intersection over Union (IoU) scores reached 99.1%, 94.87%, and 92.18%, respectively, after the empirical validation, indicating over the benchmarks of the original Mask R-CNN architecture. The performance was improved by 1.28, 1.13, and 1.05 percentage points in the precision, recall, and IoU scores, respectively. There was also the substantial reduction of 1.43 percentage points in the error of area measurement, suitable for the complexities of leaf edge segmentation. Although there are various factors affecting the images, such as occlusion and shadows, the error rate in area measurement can be controlled to around 5.45%. In conclusion, the improved Marm model can be expected to use for the plant biometric measurements with the higher accuracy than before. The serrated leaf edges can also be accurately segmented for the fully understanding of the plant growth dynamics and informed agricultural practices. The intricate scenarios of leaf edge can be captured to extend the promising transformative applications in the diverse fields, including the computer vision in modern agriculture. As the technological advancements empowered agriculture, this finding can significantly contributed to the ongoing evolution of sustainable food production. The landscape of advanced techniques can be evolved for the plant phenotype. The improved model can also be utilized to navigate the complexities of leaf edge segmentation in the field of botanical sciences.

Keywords: image segmentation; deep learning; Mask R-CNN; plant phenotype; instance segmentation; cucumber