

基于计算机视觉的茶叶嫩芽识别与分类方法研究

作 者：	曹林君
指导教师：	林春丽教授
学 科：	控制工程
答辩日期：	2022 年 3 月 11 日

分类号 TP181 密 级 公开
U D C 单位代码 10146
学 号 192085210292

硕士学位论文

基于计算机视觉的茶叶嫩芽识别与分类方法研究

研究生姓名：曹林君

指 导 教 师：	<u>林春丽 教授</u>	工 作 单 位：	<u>辽宁科技大学</u>
指 导 教 师：	<u>魏东 教授</u>	工 作 单 位：	<u>辽宁科技大学</u>
论 文 提 交 日 期：	<u> </u>	答 辩 日 期：	<u>2022.03.11</u>
学 位 授 予 日 期：	<u> </u>	授 予 单 位：	<u> </u>
论 文 评 阅 人：	<u> </u>	工 作 单 位：	<u> </u>
论 文 评 阅 人：	<u> </u>	工 作 单 位：	<u> </u>
答 辩 委 员 会 主 席：	<u>孙红星 教授</u>	工 作 单 位：	<u>辽宁科技大学</u>

**Research on the Recognition and Classification Method of
Tea Sprouts Based on Computer Vision**

**A thesis Submitted to
University of Science and Technology Liaoning**

**by
Cao Linjun
(Control Engineering)**

**Supervisor: Prof. Lin Chunli
Associate: Prof. Wei Dong**

March,2022

独创性声明

本人声明所呈交的论文是我个人在导师指导下进行的研究工作及取得的研究成果。尽我所知，除了文中特别加以标注和致谢的地方外，论文中不包含其他人已经发表或撰写过的研究成果，也不包含为获得辽宁科技大学或其它教育机构的学位或证书而使用过的材料，与我一同工作的同志对本研究所做的任何贡献均已在论文中作了明确的说明并表示了谢意。

论文作者签名： 常林君 日期：2022 年 3 月 15 日

关于论文使用授权的说明

本人完全了解辽宁科技大学有关保留、使用学位论文的规定，即：学校有权保留送交论文的复印件，允许论文被查阅和借阅；学校可以公布论文的全部或部分内容，可以采用影印、缩印或其他复制手段保存论文。

本学位论文属于： 保 密 ☐ 在 年解密后适用本授权书。

不保密 ☒ （请在以上方框内打“√”）

论文作者签名： 常林君 日期：2022 年 3 月 15 日

指导教师签名： 林春丽 日期：2022 年 3 月 15 日

中文摘要

茶叶的出口需求量越来越多,其中高端品质的茶叶一直广受大众追捧。目前,以绿茶和白茶为主的名优茶叶以人工选择性采摘为主。但这种采摘方式效率低下,人工生产成本较高,尤其是其采摘的季节性短暂,短期的用工人数量巨大,对人力的要求高。因此急需研究针对高端名优茶的自动采摘装置,而其中最关键的则是茶叶嫩芽的分类识别及位置朝向信息的识别,这是自动化茶叶采摘的基础,目前已经成为相关领域的研究热点。本文利用计算机视觉技术对茶叶嫩芽进行分类识别,并确定嫩芽具体朝向位置,具体研究内容如下:

(1) 构建自有数据集。本文数据采集工作是在茶叶的采摘季节,对实际茶园基地场景中的茶叶进行数据采集。将采集到实际数据,按照嫩芽的形状差异,分为三种类型。分别为:全开面、半开面以及一芽两叶类型,从中构建自有数据集。本文的正样本为三种类型的嫩芽数据,负样本是非嫩芽部分的背景区域,构建完嫩芽数据集后并做好自有数据集的标记工作。

(2) 提出改进的双线性分支残差网络 ResNet18 模型,实现茶叶嫩芽的分类。为了增强模型对嫩芽的感受能力,在 ResNet18 网络的基础上应用双线性分支网络结构。上分支关注全局特征,下分支做细粒度检测,关注局部特征;为了降低网络模型的参数量和计算量,本文采用了全局池化代替全连接层的方式,解决网络计算结果过拟合问题,在数据集的验证上取得了较好的效果。

(3) 提出了改进的 GMM 模型的嫩芽分割方法,实现了嫩芽位置及朝向的识别。首先,通过改进的网络模型在茶叶实际数据中获取到嫩芽的局部区域定位;然后以高斯混合模型为基础,对其中的参数进行优化选取,获取嫩芽局部区域图像的二值化分割图像;最后利用图像的不变矩算法对嫩芽的质心及朝向进行计算,得到嫩芽的准确位置信息及朝向角度;在实际图像数据上进行验证,取得较好效果,得到嫩芽的位置及朝向角度信息,为后续机械手的抓取动作提供数据基础。

关键词: 计算机视觉; 双线性分支残差网络; 茶叶嫩芽识别; 图像分割

ABSTRACT

The export demand for tea is increasing, among which high-end quality tea has been widely sought after by the public. At present, the famous and high-end quality tea, which are mainly green tea and white tea, are mainly picked manually. However, this kind of picking method is inefficient, and the labor cost is high, especially the seasonal picking is short, the number of short-term workers is huge, and the manpower requirements are high. Therefore, there is an urgent need to study automatic picking devices for high-end quality tea, and the most important thing is the classification and identification of tea sprouts and the identification of position orientation information. This is the basis of automatic tea picking and has become a research hotspot in related fields. This paper uses computer vision technology to classify and identify tea sprouts and determine the specific orientation of the tea sprouts. The specific research content is as follows:

(1) Build its own dataset. The data collection work in this paper is to collect the data of the tea in the actual tea garden base scene during the tea picking season. The actual data collected will be divided into three types according to the shape difference of the tea sprouts. They are: types of fully-open tea sprouts, types of half-open tea sprouts, and types of one-bud two-leaf tea sprouts, from which to construct their own datasets. The positive samples in this article are three types of tea sprouts data, and the negative samples are the background area of the non-tea sprouts; after constructing the tea sprouts dataset, we will do a good job of labeling our own dataset.

(2) An improved bilinear branch residual network ResNet18 model is proposed to realize the classification of tea sprouts. In order to enhance the model's ability to perceive tea sprouts, a bilinear branch network structure is applied on the basis of the ResNet18 network. The upper branch focuses on global features, the lower branch does fine-grained detection, and focuses on local features; In order to reduce the amount of parameters and computation of the network model, this paper adopts the method of global pooling instead of the fully connected layer to solve the problem of over-fitting of the network calculation results, and has achieved good results in the verification of the data set.

(3) An improved tea sprouts segmentation method of GMM model is proposed, which realizes the identification of the position and orientation of the tea sprouts. First, obtain the local area location of the tea sprouts in the actual tea sprouts data through the improved network model; Then, based on the Gaussian mixture model,

optimize the parameters among them to obtain the binarized segmentation image of the local area of the tea sprouts; Finally, use the image invariant moment algorithm to calculate the centroid and orientation of the tea sprouts to obtain the accurate position information and orientation angle of the tea sprouts; It is verified on the actual image data to achieve better results, and obtain the position and orientation angle information of the tea sprouts, which provides a data basis for the subsequent grasping actions of the manipulator.

Key Words : Computer Vision , Bilinear Branch Residual Network, Tea Bud Recognition, Image Segmentation

目 录

独创性声明	i
关于论文使用授权的说明	i
中 文 摘 要	ii
ABSTRACT	iii
1. 绪论	1
1.1 研究背景与意义	1
1.2 国内外研究现状	3
1.2.1 国外相关技术研究现状	3
1.2.2 国内相关技术研究现状	4
1.3 本文研究内容及章节安排	5
1.3.1 本文研究内容	5
1.3.2 本文章节安排	7
2. 卷积神经网络概述与茶叶嫩芽数据集构建	8
2.1 机器学习与深度学习	8
2.2 卷积神经网络概述	9
2.2.1 卷积神经网络	10
2.2.2 网络训练过程	14
2.3 茶叶嫩芽数据集的构建	15
2.3.1 茶叶数据的获取	15
2.3.2 嫩芽数据集的样本制作	16
2.4 本章小结	19
3. 改进的 ResNet18 茶叶嫩芽识别分类模型	20
3.1 卷积神经网络模型概述	20
3.2 卷积神经网络模型介绍	20
3.2.1 AlexNet 网络模型	20
3.2.2 VGG 网络模型	22
3.2.3 残差网络模型	23
3.3 基于 ResNet18 网络模型的改进	25
3.3.1 改进的双线性分支 ResNet18 网络结构	26
3.3.2 网络模型双线性分支构建	27
3.3.3 全连接层改进	28
3.3.4 混淆矩阵构建	29
3.4 改进后 ResNet18 网络与传统的网络模型对比分析	31
3.4.1 本文网络实验结果	31
3.4.2 网络模型运算时间对比分析	32
3.4.3 网络模型训练精度对比分析	33
3.4.4 网络模型损失率对比分析	34
3.4.5 网络模型混淆矩阵对比分析	35
3.5 本章小结	36
4. 实际茶叶嫩芽数据分类识别结果及分析	37
4.1 实际场景数据嫩芽分类识别	37
4.1.1 多尺度滑窗的验证方式	37

4.1.2 实际数据验证结果展示	39
4.2 嫩芽局部区域图像提取	40
4.3 本章小结	42
5. 图像分割及嫩芽位置信息识别	43
5.1 基于改进的 GMM 模型茶叶嫩芽分割方法	43
5.1.1 基于 K-means 的嫩芽分割	43
5.1.2 基于 GMM 模型的嫩芽分割	45
5.2 基于不变矩的嫩芽质心计算方法	48
5.2.1 不变矩的定义	48
5.2.2 质心及偏转角的确定	49
5.3 实验结果分析	51
5.3.1 K-means 处理结果展示	51
5.3.2 GMM 模型处理结果展示	53
5.3.3 两种方法对比效果展示	54
5.3.4 GMM 模型的嫩芽质心及角度结果展示	55
5.4 本章小结	55
6. 总结展望	56
6.1 总结	56
6.2 展望	57
参考文献	58
攻读硕士学位期间参与科研项目情况	61
致 谢	62
作者简介	63

1. 绪论

1.1 研究背景与意义

茶叶在中国的古代就受到了众多文人志士的追捧，中国特有的茶文化也由此流传至今。茶叶作为一种消耗品，逐渐渗透到人们的日常生活中，并慢慢形成了茶道、茶艺、茶礼、茶俗、茶疗等风尚与习俗品^[1]。茶不仅仅是上等品，同时还有着很高的药用及营养价值，多项研究表明茶叶中含有多种有机化学成分和无机矿物元素，非常有利于人类的身心健康。下图 1.1 所示，为不同品种茶叶的展示，茶叶品种及口味的不同也满足了不同人的需求，满足了大众的口味。



图 1.1 不同茶叶品种

Fig. 1.1 Different tea varieties

在这个文化背景下，中国也成为了全球最大的茶叶生产地和出口国。中国土地幅员辽阔，地势的优势性及土壤的肥沃性十分适合茶叶的生长。因此，中国的茶树的种植面积也是全球最大的，所生长的茶叶品种众多，可以满足不同人士的需求。结合上述背景，茶叶的智能化采摘装置的研究十分符合现代科技的发展，实现茶叶智能化采摘不仅仅能够解放农民双手，还能够提高茶叶采摘的效率及质量。研究数据表明，从 2006 年至今，中国的茶叶总生产量始终位于世界的首位^[2]。下图 1.2 所示的柱状图所示，从 2015 年至今中国茶叶产量逐年稳步增长。与此同时，在 2020 年中国的茶叶产量已经完成了占据全球茶叶总产

量 40%以上的指标。这为国产茶叶的出口打下了坚实的基础。上述数据表明，茶叶的需求量在不断升高。



图 1.2 2015-2020 年中国茶叶产量统计情况

Fig. 1.2 Statistics of China's tea production from 2015 to 2020

茶叶的收获具有较强的季节性，一般茶叶的采摘有两个最佳时间段。一个时间段是每年的清明时节，另一个采茶时间在每年的九月份左右。如果不及时对生长出来的茶叶嫩芽进行采摘，那么茶叶嫩芽就会面临变老，从而错过最佳采摘期的情况^[3]。而在茶叶采摘季到来之时，广袤的茶叶种植基地，需要雇佣大量的人工劳动力。茶叶嫩芽生长的不同步性又对茶农的采摘工作增加了隐形的负担。茶农采茶一般就是以人工的方式，如下图 1.3 所示。手工采茶的方式虽然可以精确采摘，但是采摘的效率比较低下，对人工的要求也比较高，需要占据用大量的劳动力以及花费大量的农时，生产成本较高。图 1.4 展示的是茶农携带机器进行茶叶嫩芽的采摘，目前茶叶采摘的主要机器形式有：往复式切割、钩刀式切割以及螺旋式滚切^[4]。茶叶嫩芽采摘机利用了机械动力带动刀片运转的工作原理，可以快速完成茶树上嫩芽的切割工作，从而完成茶叶采摘的任务。人工携带机器进行一刀切的方式，虽然提高了茶叶采摘的工作效率，但是一刀切的工作方式对大部分的茶叶嫩芽损伤较大，摘下的茶叶完整度不高，高端的茶叶嫩芽资源存在被浪费的情况，没有达到茶叶嫩芽选择性采摘级别。采摘下来的茶叶嫩芽的大小不一，大部分嫩芽的完整度在一定程度上也遭到了破损，严重影响了嫩芽的品质和产量^[5]。

茶叶市场日渐庞大，相关产业链也日渐完善。这不仅提高了当地农民的基本收入，同时也带动了以茶为主的地方经济的快速发展。因此，为了解决人工进行高端茶叶选择性采摘效率低、生产成本低，人工携带机器进行一刀割式茶叶切割对茶叶完整度破损大等问题，现阶段急需研究一种用于高端茶叶的自动采摘装置^[6]。



图 1.3 手工采茶

Fig. 1.3 Manual picking of tea



图 1.4 人工携带机器采茶

Fig. 1.4 Picking tea manually with a machine

1.2 国内外研究现状

1.2.1 国外相关技术研究现状

随着计算机视觉研究的不断深入和完善，计算机视觉不再局限于外部环境的单一领域，已经渗透于各个领域的发展，在农业方面也有了较大的成就。随着茶产业的不断发展壮大，优质茶叶的大批量采摘需求也越来越大。国内外研究人员对于茶叶智能采摘的成果也越来越多，一定程度上缓解了茶农徒手采摘茶叶效率低的现状，提高了采茶的效率和品质^[7]。

早期的图像处理，以基础的图像处理方法为主。Borah^[8]等人以标准的数据库为基础，将检测到的茶叶颜色信息与数据库中的信息进行对比，在图像处理的方式上选用了 HSI 颜色模型处理相关图像信息，从而便于与标准图像数据库中的颜色进行匹配。Antonio^[9]等人利用模式识别相关技术检测来自非洲和亚洲国家不同茶叶类型，这些茶叶中含有不同的微量元素。实验根据茶叶中所含的各种微量元素来进行相应的分类。Neto^[10]等人应用了傅里叶描述符，根据不同植物叶子的个体形状差异进行相关识别，实验的平均识别准确率为 89.4%。

近年来随着智能方法的发展，以机器学习及深度学习的为主流学习被广泛应用于图像的特征提取，网络的学习也成为主流的学习方式。AlexKrizhsky^[11]

提出的卷积神经网络 AlexNet 由五个卷积层组成。卷积层之后是最大的池化层和三个全连接层。最后使用 softmax 分类器进行相关分类,网络以强大的优势取胜。Kaiming He^[12]等人在 ResNet 网络中引用了残差结构的学习方式,这种方式在加深网络深度的同时保证了网络的准确性,使得网络的分类错误率降低为 4%。Konstantions^[13]等人建立了关于植物病害的检测与相关类型诊断的模型,使用卷积神经网络模型进行相应的分类识别,最终的识别准确率达 99.53%。Bakhshipour^[14]等人通过检测包括傅立叶描述符和矩不变特征在内的一组形状特征,研究了甜菜田中的四种常见杂草。采用支持向量机和人工神经网络进行训练,获得了良好的分割效果。Khan Z^[15]等人提出了基于深度学习模型训练的植被指数估计方法,该方法通过深度神经网络学习植被的 RGB 图像与其对应的 MSI 计算的指数之间的非线性空间光谱关系。获取当地作物健康状况、含水量、营养成分及其他信息来进行图像的分析处理。

1.2.2 国内相关技术研究现状

目前茶叶采摘的方式以人工进行选择采摘为主要手段,人工携带机器采摘为辅助手段。然而人工选择性采摘茶叶嫩芽的方式效率低下,生产成本较高。同时,茶叶采摘具有较高的季节性,采摘的周期较短,短期内需要的劳动力巨大。人工携带机器一刀式进行嫩芽采摘对嫩芽的损坏有较严重,所以近年来国内的学者致力于自动化的茶叶采摘的相关研究^[16]。

杨增福^[17]等人选用颜色以及形状作为主要的区别特征,根据相关图像处理方法对茶叶嫩芽进行识别与检测。实验证明,上述方法能有效的识别出茶叶嫩芽,识别准确率高,一定程度上推动了茶叶嫩芽自动化采摘进程。刘志杰^[18]等人通过提取嫩芽的绿色分量以及对应的区域标记再进行相应结合的方式,利用阈值分割的方法分离实际茶叶图片中嫩芽与背景,取得了较好的实验效果。汪建^[19]将茶叶嫩芽 RGB 图像转换成 HSI 空间,选用茶叶图像的颜色及边缘作为识别的主要特征,增强图像信息结合区域生长的相关方法,对图像中的茶叶嫩芽进行相应的分割提取,实验取得了较好的分割效果。吴雪梅^[20]为了提取嫩芽中 G 分量以及 G-B 分量,选用了阈值计算的相关方法,且对其进行相应的改进,最终根据改进后的最大方差自动阈值方法提取与茶叶嫩芽有关的信息。与此同时,提出了可以有效消除光线对于嫩芽影响的识别方法,一定程度上为茶叶嫩芽自动化采摘机提供了技术支持。邵明^[21]等人选用茶叶嫩芽的超绿-超红信息作为识别的主要特征,利用基础的阈值分割及形态学相关方法对茶叶的背景部分进行去除,采用混合的图像分割方法对龙井茶叶进行相关嫩芽部分的提取,获得了较好的实验效果。王琨^[22]将采集到的茶叶图像训练集送进深度神经网络进行训练,针对实际的应用场景对卷积神经网络的相关算法进行优化,最终的网

络可以准确识别茶叶嫩芽的相关状态。张可^[23]等人结合传统的阈值分割及聚类算法,提取到茶叶 RGB 图像中的 R-B 分量,完成茶叶嫩芽图像的自动识别,获得了较好的实验验证效果。孙肖肖^[24]针对复杂背景下的茶叶嫩芽识别效果较低的问题,选用茶叶嫩芽的超绿特征作为识别的主要特征,利用 OSTU 算法先进行图像的相关处理,采用 YOLOv3 深度网络模型训练数据集。为解决网络弥散等现象,在网络中引入了 Dropout、局部对比度归一化等方式,实验取得了较好的效果。陈妙婷^[25]将支持向量机相关算法进行改进,利用改进后的 PSO-SVM 算法对名优茶嫩芽进行相应的分割。根据茶叶采摘的实际情况对嫩芽相关采摘点进行具体判断。实验利用深度学习模型 YOLO 训练相应的数据集,最终网络的识别准确率达 84%。邵佩迪^[26]分别采用基于聚类、阈值等图像分割方法对茶叶嫩芽进行相关处理,取得了较好的分割效果。

纵观国内外采茶现状,可以看出机械采茶仍是一种粗狂的、规模化的采茶方式,这种方式不符合优质茶叶选择性采摘的要求。虽然许多科研人员对茶叶嫩芽进行了鉴定研究,但相应的鉴定效果和识别的速度还未达到实际采摘的标准,大部分实际操作应用于室内或实验室,识别稳定性比较低,不能推广到实际茶园的茶叶采摘工作。因此,针对茶叶嫩芽选择性采摘的自动化设备研究的课题变得十分重要。只有准确知道具体嫩芽位置以及具体嫩芽的朝向角度,才能借助自动化设备,更好的实现芽叶嫩芽的自动采摘。

1.3 本文研究内容及章节安排

1.3.1 本文研究内容

本文主要研究基于计算机视觉的茶叶嫩芽的识别与分类工作,对比利用相关神经网络训练模型对嫩芽进行训练与分类,从而能够更好地解决实际应用场景中对所拍摄的茶叶图片进行嫩芽具体位置的识别以及类别的判定,为实现农业现代化打下坚实的基础。

由于直接用实际茶树图像进行嫩芽检测过程中的计算和学习量太大,且实际茶树图像中的嫩芽叶片太小。当目标物太小检测识别的效果往往会比较差,识别的准确率也难以保证。所以本文的技术路线如下:

首先制作嫩芽样本训练数据集。本文数据集采集工作是在茶叶的采摘季节,对实际茶园基地场景中的茶叶进行数据采集。首先将采集到实际数据,按照嫩芽的形状差异,分为三种类型。分别为:全开面、半开面以及一芽两叶类型,从中构建自有数据集。其中将三种嫩芽的数据作为正样本,非嫩芽部分的背景区域作为负样本,构建完嫩芽数据集后并做好自有数据集的标记工作。

嫩芽数据集制作完成后,用小嫩芽样本作为网络训练的数据,进行网络的学习。本文对比利用了四种网络模型,最后提出改进的双线性分支残差网络

ResNet18 模型进行嫩芽的训练与分类。在 ResNet18 网络的基础上提出了双线性分支网络结构，上分支应用 ResNet18 的 4 个 block，感受野大，关注全局特征。下分支应用 ResNet18 的前 3 个 block，裁剪出关注区域，做细粒度检测，感受野小，关注局部特征。网络的下分支用来提取局部的细粒度特征。通过上下分支网络的分工，提取嫩芽相关特征。

然后针对高清的实际茶树图像，利用多尺度滑窗的方式获得茶树全景图片的 patch 块，并将其送进改进的模型网络中进行验证，从而进行实际茶树图像中嫩芽目标的检测，获得茶树全景图片中局部嫩芽的区域。把每一个识别到的嫩芽局部区域图像信息提取出来，给后续对嫩芽具体质心位置和朝向信息进行识别做准备。下图 1.5 展示了论文的技术路线：




图 1.5 论文技术路线图

Fig. 1.5 Thesis technology roadmap

由于检测到的嫩芽朝向等信息未知，为了便于后续机械手的介入，本文设计了相关算法对检测到的局部嫩芽区域进行相应的图像分割，最后以高斯混合

模型为基础，对其中的参数进行优化选取，应用于嫩芽区域局部图像的二值化处理，获得嫩芽的二值化分割图像。采用图像的矩方法对嫩芽的质心进行判定并计算具体的偏转角度。最终得到嫩芽的准确定位信息及朝向角度。为后续机械手的抓取动作提供数据基础。

1.3.2 本文章节安排

论文组成共分为 6 章，具体内容如下：

第一章绪论部分主要介绍了课题研究的背景和意义，针对目前智能化采摘茶叶嫩芽的背景，讨论了将计算机视觉相关技术应用到实际场景中的实际意义。详细阐述了茶叶嫩芽采摘技术的国内外现状，以及本文的具体研究内容。

第二章详细阐述了卷积神经网络学习训练的相关基础与自有茶叶嫩芽数据集的构建过程。

第三章主要对比分析了不同网络模型对本数据集的训练效果。结合双线性分支网络对 ResNet18 进行相应的改进。结果表明，改进后的网络更适应本文数据集的训练，各项性能指标都有所提升。

第四章利用改进的模型在实际数据中验证其分类效果，并且得到嫩芽的局部区域定位，把每一个嫩芽的局部区域图像信息提取出来，方便后续对具体嫩芽位置和朝向信息进行识别。

第五章以高斯混合模型为基础，对其中的参数进行优化选取，应用于嫩芽区域局部图像的二值化处理，获得嫩芽的二值化分割图像；采用图像的矩方法对嫩芽的质心进行判定并计算具体的偏转角度。最终得到嫩芽的准确定位信息及朝向角度。

第六章为总结展望部分，对本文的工作做了相关总结，客观分析了本文所取得的成果，认识到本文工作还存在不足之处，对未来工作做一个展望并计划下一步任务研究。

2. 卷积神经网络概述与茶叶嫩芽数据集构建

2.1 机器学习与深度学习

传统的机器学习算法如下图 2.1 所示, 需要先对样本数据进行人工特征提取, 再将提取完特征的样本数据送进网络中进行相应的训练学习。通过网络模型权重的不断学习更新后有一套固定的权重值, 当再次输入一批样本数据后, 网络模型就会得到一个预测的结果^[27]。通过神经网络的不断发展, 深度学习的方式得到了众多学者的亲睐。相比于机器学习, 深度学习最大的特点就是模型可以自动提取输入样本数据的特征, 这种学习方式更加智能化。同时随着学习模型的深入, 图像的基础特征通过模型的学习可以组合出更高层的特征, 比如线条、简单形状等^[28], 这就使得不同类别的图像分类更加便捷。深度学习算法将提取到的特征经过模型的学习, 更新模型权重参数等步骤, 得到预测结果。




图 2.1 传统机器学习算法

Fig. 2.1 Traditional machine learning algorithms

如下图 2.2 可见,深度学习网络并不是能够完全脱离传统算法而另起炉灶的, 而是对于传统算法的改进, 将原始算法的复杂步骤融入到网络中, 从而简化流程, 提高效率。相比于浅层网络的学习方法, 深度神经网络最大的特点就是网络结构多、参数量大, 且网络内部的连接方式也会随着不同网络的类型而以不同形式出现^[29]。多层结构化的深度神经网络可以学习到更多层次、更加抽象的表达, 总的来说, 深度神经网络是传统的神经网络的一种新的且前进式的发展, 具有很大的优势。




图 2.2 深度学习算法

Fig. 2.2 Deep learning algorithm

本文研究的深度学习模型主要以卷积神经网络为主, 卷积神经网络最大的特点就是卷积核参数共享以及层间连接的稀疏性。这使得卷积神经网络中的计算量相对较少, 同时网络可以快速计算出输入样本数据的相应特征^[30]。这种方式简化了网络模型的结构, 从而大大降低了特征学习的复杂程度。卷积神经网络在图像处理等方面的有着显著的成绩, 其受欢迎的程度也很高, 也带动了相

关领域的发展研究。卷积神经网络是一个典型的空间上的深度神经网络，能够有效的提取和学习所采样的图片的特征，有利于进行图片的分类。深度学习算法采用神经网络-中枢-大脑的工作原理，设计出不断迭代以及抽象的过程。从信号输入开始，网络先进行低特征的提取，逐渐向高层进行抽象迭代，从而组成深度学习算法的基本框架^[31]。

2.2 卷积神经网络概述

LeCun 提出卷积神经网络，这种网络由可学习权重和偏置常数的神经元组成，是一个具有卷积结构的前馈深度神经网络。输入数据经过网络的逐层卷积和池化得到相应的特征信息。网络可以自主学习到输入数据图像的相关特征^[32]。每个卷积神经网络由多个卷积层结构组成，每个卷积层包含多个卷积核，通过共享权值的方式进行相应的卷积操作。网络模型中卷积核按照从左到右、从上到下的方式对输入图像进行相关扫描工作，从而得到相应的特征图。卷积神经网络的基本结构由输入层、卷积层、池化层、全连接层和输出层组成。具体网络结构如下图 2.3 所示。




图 2.3 卷积神经网络结构图

Fig. 2.3 Convolutional neural network structure diagram

其中的输入层 **Input** 是不需要人工提取特征的原始数据的，图中的 **C1** 层是隐藏层中的卷积层，其中包括很多个卷积核，这些卷积核对输入的数据进行一定的卷积从而生成特征图，**C1** 之后的结构是 **S2**，**S2** 为隐藏层中的池化层，它

的作用就是对于 C1 层中所得到的特征图进行相应的池化，从而生成所对应的池化过后的特征图，而 C3 层到 S4 层的作用就是重复之前的 C1 到 S2 的步骤，经过一系列的卷积与池化得到最后生成的特征图。选用的深度卷积神经网络是利用卷积与池化的搭配从而对数据进行特征的提取。在降低特征图像分辨率的同时，增加特征图数量，获得更多的特征数据信息。最后再采用全连接的方式，通过分类器的作用，得到最后的输出结果。

2.2.1 卷积神经网络

(1) 卷积层和激活函数

卷积核之所以能够提取特征，是因为对图像使用卷积核提取特征就相当于为图像矩阵 A 寻找最合适的特征向量集，神经网络就是通过反向传播来不断拟合一个非常逼近的特征向量，也就是卷积核的值。有了权重值，让它与原始图像矩阵相乘，就能得到对应的特征。卷积层的主要作用提取输入数据的特征信息。其权值共享的特点，极大程度上降低了网络的计算参数量，有效的避免了网络因参数量过大的问题而导致的过拟合现象。具体的卷积过程如下图 2.4 所示：




图 2.4 卷积层卷积过程图

Fig. 2.4 Convolutional layer convolution process diagram

卷积层运算过程如上图 2.4 所示，原始特征图的大小是 4*5，使用卷积核矩阵从图像左上角开始，卷积核设定为 2*2 大小的尺寸。卷积核按照从左到右、从上到下的方式对输入数据进行扫描，移动步长为 1，用卷积核中的每个参数与对应卷积窗口中的参数相乘再求和得到输出值，作为下一层的输入。如上图 2.4 所示，经过卷积运算操作，最终输出特征图大小为 3*4。

将激活函数作用于上述卷积操作后得到的输出，激活函数在一定程度上提高了神经网络的非线性能力，以下为几种常见的激活函数：

(a) Sigmoid 函数

Sigmoid 函数及其导数：

$$f(x) = \frac{1}{1+e^{-x}} \quad (2.1)$$

$$f'(x) = \left(\frac{1}{1+e^{-x}}\right)' = \frac{1}{1+e^{-x}} \left(1 - \frac{1}{1+e^{-x}}\right) = f(x)(1-f(x)) \quad (2.2)$$

通过 Sigmoid 激活函数的作用，可以将输入值映射成值域为 (0, 1) 区间内。函数具有单调且连续的性质，非线性是其最大的特点。由上式 2.2 所示，Sigmoid 激活函数的导数形式与其本身形式相关，是关于自身的变换。因此，简化了网络在反向更新权重参数时求导的计算形式，从而提高了网络整体的计算效率。

(b) Tanh 函数

Tanh 函数及其导数：

$$f(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}} \quad (2.3)$$

$$f'(x) = \left(\frac{e^x - e^{-x}}{e^x + e^{-x}}\right)' = 1 - \left(\frac{e^x - e^{-x}}{e^x + e^{-x}}\right)^2 = 1 - f^2(x) \quad (2.4)$$

通过 Tanh 激活函数的作用，可以将输入值映射成值域为 (-1, 1) 区间内。此函数从一定程度上改进了 Sigmoid 激活函数的部分缺点。在函数收敛速度方面，Tanh 激活函数比 Sigmoid 激活函数收敛得更快。但网络仍然存在梯度消失的现象。

(c) ReLU 函数

ReLU 函数及其导数：

$$f(x) = \begin{cases} x & x > 0 \\ 0 & x < 0 \end{cases} = \max(0, x) \quad (2.5)$$

$$f'(x) = \begin{cases} 1 & x \geq 0 \\ 0 & x < 0 \end{cases} \quad (2.6)$$

ReLU 激活函数以相对简单的函数形式受到大众的欢迎。如果输入数据大于零，则其输出等于输入且导数始终为常数值 1。如果输入数据为负，则其输出值将始终为零，导数值始终恒等于 0。利用 ReLU 激活函数，网络在梯度下降反向求导时，参数更新速度更快，可以很好的进行梯度的传递工作。这种函数适合于较深的神经网络的训练。同时，更快的收敛速度也有助于提高网络的泛化能力。因此，深度学习的激活函数通常选择 ReLU 激活函数。

(2) 池化层

相比于卷积层的复杂度，池化层则要简单的多。池化层的主要作用是避免网络过拟合的现象。在卷积神经网络中，卷积层和池化层交替出现，每个池化层的输入都是前一个卷积层的输出。同时，卷积层和池化层的特征面是一一对应的。池化层的作用是进行数据特征映射。即通过对上一层获取的特征图进行二次采样，减少了数据量，同时保留了有用的数据信息^[33]。如果池化核的大小是 2*2 尺寸，那么就是将输入数据的子矩阵的每一个 2*2 大小的矩阵降维成一个元素。如果池化核的大小是 3*3 尺寸，那么将子矩阵的每个 3*3 大小的矩阵转化为一个元素，这样的池化操作就会起到降低输入矩阵维度的作用。卷积神经网络池化方式中使用次数最频繁的是最大池化，公式如下所示：

$$p_j^{l+1}(i) = \max_{(i-1)W+1 \leq t \leq iW} \{a_j^l(t)\} \quad (2.7)$$

式中， $p_j^{l+1}(i)$ 所表示的是池化操作过程中第 $l+1$ 层中的神经元的相应值， W 指的是池化区域的宽度。

下图 2.5 所示为用的最频繁的最大池化的池化过程：




图 2.5 最大池化示例

Fig. 2.5 Maximum pooling example

其中池化核的大小为 2×2 ，每次池化过程的步长为 2。池化核从输入数据的左上角开始，每次向右移动两步，池化层直接计算每个池化窗口对应的最大值，作为下一层的输入。上图原始特征图的大小为 4×4 ，池化核的大小为 2×2 。经过池化操作后的输出特征图的维度降到了 2×2 大小的尺寸。

(3) 全连接层

全连接层是将网络学习到的特征通过等价于分类器的线性映射，投影到样本空间中。全连接层中的每个神经元都连接到前一层的所有神经元，所有局部特征通过卷积操作连接到全局特征。一般用于分类任务中，全连接层通常位于网络的末端位置，通过输入数据进行整合，从而可以得出反应数据特征的特征向量^[34]。

下图 2.6 所示为全连接层的前向传播过程：




图 2.6 全连接层

Fig. 2.6 Fully connected layer

其中， x_1, x_2, x_3 表示全连接层的输入， a_1, a_2, a_3 表示全连接层的输出， w_{ij} 表示上一层与全连接层的连接权重。

$$a_1 = w_{11} \times x_1 + w_{12} \times x_2 + w_{13} \times x_3 \quad (2.8)$$

$$a_2 = w_{21} \times x_1 + w_{22} \times x_2 + w_{23} \times x_3 \quad (2.9)$$

$$a_3 = w_{31} \times x_1 + w_{32} \times x_2 + w_{33} \times x_3 \quad (2.10)$$

作为隐藏层的最后一层，全连接层将本层的每个神经元与上一层的所有神

经元连接起来，整合卷积层或者池化层中具有类别区分性的局部信息，得到整个网络的输出状态。

(4) softmax 分类器

全连接层的输出需要采用 softmax 逻辑回归进行分类工作,softmax 分类器将原始数据转化为类别的概率。其概率的范围是 (0, 1) 之间，且所有类别的概率值之和为 1。

softmax 函数公式：

$$Li = -\log\left(\frac{e^{f_{y_i}}}{\sum_j e^{f_j}}\right) \quad (2.11)$$

$$f_j(z) = \frac{e^{z_j}}{\sum_k e^{z_k}} \quad (2.12)$$

下图 2.7 所示为神经元从全连接层经过增加非线性能力，再通过 softmax 分类器进行相应的分类。




图 2.7 softmax 分类器

Fig. 2.7 softmax classifier

2.2.2 网络训练过程

卷积神经网络有两个重要的训练过程，分别为前向传播以及误差的反向传播。前者指的是将待实验的样本数据送进网络中，初始化参数设置，经过层层卷积池化来进行相应的特征提取，进而得到网络的输出。前向传播的过程中，首先需要定义网络模型的参数，主要包括权重和偏置。接着将样本数据输进网络中，按照网络结构中的卷积层、池化层、全连接层等进行不断的进行特征的

学习，依次计算网络中的变量及相应的输出。反向传播是将网络实际输出值与真实值进行对比分析，并使用损失函数来衡量相应的误差。进行反向传播的时候会产生一些梯度的变化。为了达到减少损失的目的，应该使用梯度下降法来更新网络结构的参数。反向传播网络在训练神经网络中起着重要作用，主要思想遵循链式法则。输入数据通过网络向前传播，最终得到输出值。将输出值与实际值进行比较，得到相应的误差。在具有损失函数作用的反向传播网络中，网络中的每个权重参数都通过梯度不断更新以更新每个参数^[35]。

2.3 茶叶嫩芽数据集的构建

2.3.1 茶叶数据的获取

本次实验的茶叶图片数据采集于江苏省常州市溧阳市天目湖茶园，主要拍摄具有当地特色的白茶嫩芽的实景图片。数据集采集时间是在茶叶生长的采摘季节，对实际茶园基地场景中的茶叶进行数据采集。以备本论文中的数据集构建工作。如下图 2.8 所示为实际场景下所拍摄到的茶树全景图片。



图 2.8 茶树全景图采集

Fig. 2.8 Tea tree panorama collection

上示茶树图像的分辨率为 1278*719，由于直接在这种高分辨率的图像中进行茶叶嫩芽的检测效果相对一般，所以本文针对嫩芽外形的差异性，先建立嫩

芽的数据集，以实际茶树图片中的嫩芽作为网络训练的样本，训练网络模型。再利用高分辨的茶树图片进行模型的验证，对实际茶树图片中的嫩芽进行类别的判定以及相关位置及角度的识别。

2.3.2 嫩芽数据集的样本制作

由于茶叶嫩芽的形状各异，初步选定将嫩芽样本送进卷积神经网络中训练学习。所以论文的首要工作就是创建关于嫩芽样本的数据集，由于上示图 2.8 片中茶叶嫩芽的分布较多，在复杂的叶片周围的边沿较乱，所以网络学习训练之前采取截取方式获取嫩芽数据集，便于后续卷积神经网络的学习与训练。首先将采集到实际茶叶数据，按照嫩芽的形状差异，分为三种类型。分别为：一芽两叶、全开面以及半开面类型，从中构建自有的数据集，如下图 2.9 所示：



图 2.9 茶叶嫩芽样本数据集的制作

Fig. 2.9 Preparation of tea sprout sample data set

由于神经网络做学习分类需要对应的正负样本，本文将三种嫩芽的数据作为网络训练的正样本，非嫩芽部分的背景区域作为负样本。所以本文选取了实际拍摄图片中的非嫩芽部分的背景图片作为网络训练的负样本数据，如下图 2.10 所示：




图 2.10 非嫩芽部分的背景图

Fig. 2.10 Background image of non-sprout parts

构建完嫩芽数据集后并做好自有数据集的标记工作。将制作完成的几种嫩芽类型分别建立起各自的文件夹，并且按照一定比例分为训练数据集和验证数据集，如下图 2.11 所示，进行数据集的构建及标注工作。




图 2.11 建立嫩芽训练数据集与验证数据集

Fig. 2.11 Establish sprout training dataset and validation dataset

其中，验证数据集与训练数据集的比例设置为 2: 8，即验证集的数目占总样本的百分之 20%，训练集的数目占总样本的 80%。下图 2.12 所示的文件 1 中存储的是一芽两叶类型的嫩芽，文件 2 中存储的是全开面类型的嫩芽，文件 3 中存储的是半开面类型的嫩芽，文件 4 中存储的是本文送进网络学习的负样本文件，负样本选择的是非嫩芽的背景图片。

本地磁盘 (D:) > clj-yan > wk > dataset > train

名称	修改日期	类型
1	2020/12/22 9:18	文件夹
2	2020/12/22 9:18	文件夹
3	2020/12/22 9:18	文件夹
4	2021/4/25 15:03	文件夹

图 2.12 制定嫩芽训练数据集标签

Fig. 2.12 Develop sprout training dataset labels

验证集文件存储内容与形式与训练集文件相一致，选取了每类嫩芽样本中的 20%的数据集作为验证的数据。上述工作为全部数据集建立和嫩芽样本的标注工作，下图 2.13 为具体工作流程展示。




图 2.13 数据集的建立

Fig. 2.13 Data set creation

构建完关于嫩芽的数据集且完成各类相应的标注，是为了方便后续的卷积神经网络训练与学习工作的展开。本次实验共构建三类嫩芽数据及负样本数据共 2000 多张。综上所述，自有数据集的构建及标注工作完成。

2.4 本章小结

本章节主要介绍了卷积神经网络的相关基础知识，详细描述了训练数据进入网络后，从卷积层到池化层再到全连接层等每一层的具体过程。详细阐述了本论文茶叶数据集的来源以及自有数据集嫩芽样本的构建过程，并进行相应的标注工作。为下一阶段应用卷积神经网络模型进行数据集样本的学习与训练打下基础。

3. 改进的 ResNet18 茶叶嫩芽识别分类模型

3.1 卷积神经网络模型概述

卷积神经网络不仅可以自动提取输入数据图像中的信息特征，还可以主动的降低人为的干扰。针对本文茶叶嫩芽数据集识别而言，卷积神经网络可以根据输入嫩芽图片的局部特征进行相应的卷积操作。实验结果表明，卷积神经网络的识别方式有着较高的效率。其中更深度、复杂的网络对于输入数据的特征提取能力会更强。下文所述为利用卷积神经网络框架对茶叶嫩芽进行相应的识别。

3.2 卷积神经网络模型介绍

3.2.1 AlexNet 网络模型

为了加速网络训练，AlexNet 在相关实现中使用了具有饱和神经元和卷积运算的高效 GPU。AlexNet 网络由五个卷积层和三个全连接层组成，共八层。其中，第一个卷积层的卷积核大小为 11×11 ，一共使用了 96 个卷积核。第二个卷积层的卷积核大小为 3×3 ，一共使用了 256 个卷积核。第三和第四卷积层的卷积核大小为 3×3 ，卷积核个数相同，均为 384。与前一层相比，最后一层卷积层将卷积核的数量减少到 256 个，没有调整卷积核的大小，在卷积操作之后是全连接层。为了减少全连接层的过度拟合，网络采用了“dropout”正则化方案。在网络的末端是一个 softmax 层，它的任务是执行相应的网络分类。如下表 3.1 所示，第一和第二卷积层之后有两个归一化层，第一、第二和第五卷积层之后有三个最大池化层^[36]。

表 3.1 AlexNet 网络结构

Tab. 3.1 AlexNet network structure

Layer Name	Conv1	Conv2	Conv3	Conv4	Conv5	FC6	FC7	FC8
CONV	11*11*96	3*3*256	3*3*384	3*3*384	3*3*256	N	N	N
LRN	Y	Y	N	N	N	N	N	N
POOL	Y	Y	N	N	Y	N	N	N
FC	N	N	N	N	N	4096	4096	1000
ReLU	N	N	N	N	N	Y	Y	N
Dropout	N	N	N	N	N	N	Y	N

上表格 3.1 所示为 AlexNet 网络的具体结构以及各层卷积核数量和相关尺寸大小的罗列。

```
elif model_name == 'AlexNet':
    model_ft = models.alexnet(pretrained=False)
    model_ft.features = nn.Sequential(
        nn.Conv2d(3, 64, kernel_size=11, stride=2, padding=2),
        nn.ReLU(inplace=True),
        nn.MaxPool2d(kernel_size=3, stride=2),
        nn.Conv2d(64, 192, kernel_size=5, padding=2),
        nn.ReLU(inplace=True),
        nn.MaxPool2d(kernel_size=3, stride=2),
        nn.Conv2d(192, 384, kernel_size=3, padding=1),
        nn.ReLU(inplace=True),
        nn.Conv2d(384, 256, kernel_size=3, padding=1),
        nn.ReLU(inplace=True),
        nn.Conv2d(256, 256, kernel_size=3, padding=1),
        nn.ReLU(inplace=True),
        nn.MaxPool2d(kernel_size=3, stride=2),
    )
    model_ft.classifier = nn.Sequential(
        nn.Dropout(),
        nn.Linear(256 * 6 * 6, 4096),
        nn.ReLU(inplace=True),
        nn.Dropout(),
        nn.Linear(4096, 4096),
        nn.ReLU(inplace=True),
        nn.Linear(4096, 4),
    )
```

图 3.1 AlexNet 网络模型

Fig. 3.1 AlexNet network model

结合本文数据集的特殊性，本文利用传统的 AlexNet 网络模型，将网络中的第一层卷积核数量由原来的 96 改成 64 个卷积核，卷积核的大小不变，为 11×11 ，步长为 2。减少卷积核数量是因为一种卷积核相当于提取一种特征，后面的卷积核处理的是前一层特征，相当于提取特征的特征。卷积核逐层减少，就相当于在逐层做特征的抽象，逐层提取更高级的特征。

将第二层卷积的卷积核由原来的 256 改变成 192，卷积核的大小由原来的 3×3 增大为 5×5 大小，步长为 2。第三层的卷积部分未作相应修改，仍为 $3 \times 3 \times 384$ 的卷积操作，将网络的第四层卷积核的数量再从原来的 384 降低为本文中选用的 256 个卷积核数量。最后一层卷积层仍为原来网络中 $3 \times 3 \times 256$ 的卷积操作。之所以增加卷积核的大小，是因为原始网络中 5 层卷积层中的卷积核大小分别是 11×11 ，后四层的卷积核大小均为 3×3 ，虽然说 3 个 3×3 卷积的感受野的等同于 1 个 7×7 的卷积，但是用图像处理的卷积做实验时，3 个 3×3 卷积的效果是无法跟 1 个 7×7 卷积效果划等号的。 3×3 卷积处理轮廓比较粗的图像边缘时，提取不充分，即使连续使用 3 次也没有一次 7×7 的提取的完整。所以本文中

第二层卷积大小替换为 5×5 ，在大尺寸卷积核与小尺寸卷积核之间做一个过渡，这样能在后续的 3×3 卷积之前获得比较好的图像特征。

3.2.2 VGG 网络模型

VGG 网络是一个公认的，具有较强计算能力的深度卷积神经网络，其最大的特点是利用了现代的 GPU 进行相关数据的处理。其网络层数的多样性也满足了针对不同数据集进行不同的网络层数选择的特点，具有较强的适应能力。不同层数的 VGG 网络之间有具有相同的网络结构特点。网络的每一层卷积之后都紧接着最大池化层，网络中共有 5 个最大池化层，且网络的最后都是统一由 softmax 层进行相关数据的分类操作。与此同时，对称型的网络架构是 VGG 非常明显的特征。且 VGG 网络还有一个比较显著的特点就是所有的卷积核的尺寸大小均为 3×3 ，这使得网络具有相对较少的数据计算量，便于网络的相关实现，下图 3.2 所示为 VGG 网络模型具体结构。

ConvNet Configuration					
A	A-LRN	B	C	D	E
11 weight layers	11 weight layers	13 weight layers	16 weight layers	16 weight layers	19 weight layers
input (224*224 RGB image)					
conv3-64	conv3-64 LRN	conv3-64 conv3-64	conv3-64 conv3-64	conv3-64 conv3-64	conv3-64 conv3-64
maxpool					
conv3-128	conv3-128	conv3-128 conv3-128	conv3-128 conv3-128	conv3-128 conv3-128	conv3-128 conv3-128
maxpool					
conv3-256 conv3-256	conv3-256 conv3-256	conv3-256 conv3-256	conv3-256 conv3-256 conv1-256	conv3-256 conv3-256	conv3-256 conv3-256 conv3-256
maxpool					
conv3-512 conv3-512	conv3-512 conv3-512	conv3-512 conv3-512	conv3-512 conv3-512 conv1-512	conv3-512 conv3-512	conv3-512 conv3-512 conv3-512
maxpool					
conv3-512 conv3-512	conv3-512 conv3-512	conv3-512 conv3-512	conv3-512 conv3-512 conv1-512	conv3-512 conv3-512	conv3-512 conv3-512 conv3-512
maxpool					
FC-4096					
FC-4096					
FC-1000					
soft-max					

图 3.2 VGG 网络结构图

Fig. 3.2 VGG network structure diagram

VGG 网络利用了三个 3×3 的卷积核代替 7×7 卷积核, 用两个 3×3 卷积核来代替 5×5 卷积核。在保证相同感知野的条件下, 提高了网络的深度, 一定程度上提高了神经网络的有效性^[37]。

```
elif model_name == 'VGG':
    model_ft = models.vgg11(pretrained=False)
    model_ft.classifier = nn.Sequential(
        nn.Linear(512 * 7 * 7, 4096),
        nn.ReLU(True),
        nn.Dropout(),
        nn.Linear(4096, 4096),
        nn.ReLU(True),
        nn.Dropout(),
        nn.Linear(4096, 4),
    )
```

图 3.3 VGG 网络模型

Fig. 3.3 VGG network model

本文采用的是 VGG-11 的网络模型, 针对本文数据集的特点具体将线性分类层进行相应的改进, 将网络最后的三层全连接层的前两层分别以线性分类结合激活函数再加上 dropout 层进行相应的映射, 最后通过线性分类将 4096 维的数据映射成本数据集对应四种类别的数据, 即全开面类型嫩芽、半开面类型嫩芽、一芽两叶类型嫩芽以及非嫩芽的背景部分。

3.2.3 残差网络模型

残差网络是著名的 Researcher Kaiming He(何凯明)^[38]于 2015 年提出的深度卷积网络。增加网络深度的目的是对输入数据进行更强的特征提取, 但是增加网络深度会导致网络梯度爆炸现象。所以, 残差网络最大的优点就是通过引入残差模块的方式, 进行一个残差的学习, 保留了输入数据的完整性。从而很好的解决了增加网络的深度带来的网络退化的问题, 提升网络的性能。

如下图 3.4 所示的残差块结构所示: 对于一个堆积层结构来说, 在输入样本为 x 时, 假设输出结果为 $H(x)$, 在传统的网络中是直接学习输入到输出的映射 $H(x)$, 而残差网络学习的是 $F(x) = H(x) - x$, 即目标值 $H(x)$ 与输入值 x 的差值, 称为残差。当 $F(x)$ 足够小时, 输出就近似于 $H(x) = x$, 此时堆积层仅仅做了恒等映射, 这样不必重新学习一个映射函数, 更容易拟合残差。




图 3.4 残差模块结构图

Fig. 3.4 Residual module structure diagram

每个残差块的计算公式如式 (3.1) (3.2) 所示:

$$y_l = h(x_l) + F(x_l, W_l) \quad (3.1)$$

$$x_{l+1} = f(y_l) \quad (3.2)$$

式中, x_l 和 y_l 分别表示第 l 层的输入和输出, $h(x_l)$ 为恒等映射, $F(x_l, W_l)$ 为残差部分, 一般由两个或三个卷积操作构成, W_l 为权值矩阵, f 为激活函数。

这时的残差块可以表示为:

$$x_{l+1} = x_l + F(x_l, W_l) \quad (3.3)$$

通过递归, 可以得到任意深层 L 与浅层 l 的关系表达式:

$$x_L = x_l + \sum_{i=l}^{L-1} F(x_i, W_i) \quad (3.4)$$

根据 BP 算法中使用的导数的链式法则, 反向传播的梯度可以表示为:

$$\frac{\partial \varepsilon}{\partial x_l} = \frac{\partial \varepsilon}{\partial x_L} \frac{\partial x_L}{\partial x_l} = \frac{\partial \varepsilon}{\partial x_l} \left(1 + \frac{\partial}{\partial x_l} \sum_{i=l}^{L-1} F(x_i, W_i) \right) \quad (3.5)$$

其中 ε 表示损失函数。在整个训练过程中, 由于 $\frac{\partial}{\partial x_l} \sum_{i=l}^{L-1} F(x_i, W_i)$ 不可能全为

-1, 因此这个公式保证了网络不会出现梯度消失的现象, 这就使得残差学习更加容易。每个残差单元包含两个残差块, 执行步骤就是先以传统的方法顺序执行两个卷积层, 但是卷积过多容易丢失信息, 所以再将原始数据 x 直接加上,

以减少信息的丢失。

残差单元中存在虚线是因为，在进行卷积后的值和初始值 x 进行加法运算时，输入特征矩阵与输出特征矩阵是不一样的，由于卷积可能会导致图像减小，为了保证能相加所以必须将两个数据大小统一，引入的虚线的残差结构可以将输入特征矩阵宽高以及深度都进行一个变化。

为了提高网络的性能，获得更丰富的特征信息有效的方法就是增加网络的深度。但为了追求网络性能一味的增加深度会引发很多问题，残差网络通过跳跃的连接方式，避免了增加网络深度而引起的梯度弥散或者爆炸现象，将单元的输入与输出加在一起再进行相应的激活。这样就可以成功解决深度网络训练过程中时出现的退化问题^[39]。

3.3 基于 ResNet18 网络模型的改进

本文所选用的网络模型针对茶叶嫩芽数据集的特点，基于残差网络 ResNet18 进行了如下改进：

1、由于本文嫩芽数据集叶片的形状有大有小，为了更加准确地检测定位出嫩芽叶片，应该要同时关注全局特征跟局部特征。因此结合本文数据集特点，在 ResNet18 网络的基础上引入双线性分支网络的思想，进行网络结构的特定调整，上分支应用的了 ResNet18 网络的完整的四个 Basic Block，经过层层卷积池化的过程，网络的上分支可以进行全局信息的提取。下分支只应用了 ResNet18 网络的前三个 Basic Block，为了做细粒度的检测，从而可以进行嫩芽的局部信息的特征提取。经过双线性分支网络的分工操作，可以进行嫩芽全局以及局部特征信息的同步提取，然后将卷积神经网络提取到的特征信息进行线性的连接，从而提高了模型识别的效率。

2、将 ResNet18 网络结构最后的全连接层利用全局池化进行了相应的替代，降低了网络参数的计算量，不仅提高了网络计算速度，还避免了网络出现过拟合问题，一定程度上提高了网络模型的泛化能力。

3、引入混淆矩阵，混淆矩阵可以清晰的表现出数据训练的效果，利用混淆矩阵的可视化，可以清晰的判断出网络模型在各类别上的识别效果，还可以验证模型的有效性。在本文中，利用混淆矩阵的可视化，可以非常清晰的观察到各模型针对嫩芽数据集分类识别正确的结果。

与此同时，由于本文数据集训练学习的样本量较大，每个模型的训练过程中往往会出现无法收敛、过拟合以及梯度消失等现象。本文及时对随机梯度下降等优化函数中的学习率及相关参数进行调整，优化梯度下降问题，帮助模型更稳定的收敛。

3.3.1 改进的双线性分支 ResNet18 网络结构




图 3.5 改进后的 ResNet18 网络结构

Fig. 3.5 Improved ResNet 18 network

图 3.5 所示为改进后的 ResNet18 网络结构, 利用双线性分支的结构, 将图片分为两个分支同时进行对应的特征提取工作。上分支将图片送进 ResNet18 网络中, 首先通过 7×7 的卷积, 共有 64 个卷积核, 再通过最大池化的作用获取特征信息, 接着就是经过了残差网络的 basic block1、basic block2、basic block3、basic block4 进行相应的特征提取过程, 最终获得 512 维的特征向量。由于经过了 ResNet18 的四个 block 的作用, 感受野大, 所以上分支用来提取全局特征。与此同时, 下分支将图片 resize 成 24×24 大小的尺寸送进 ResNet18 网络中, 也同样先通过 7×7 的卷积, 共有 64 个卷积核, 再通过最大池化的作用获取特征信息, 与上分支不同的是, 下分支的数据输入大小改成 24×24 , 且下分支只采用了 ResNet18 的前三个 basic block 模块进行特征提取, 最终获得 256 维的特征向量。感受野小, 所以网络的下分支用来提取局部的细颗粒特征。通过上下分支网络的分工操作, 并对 CNN 提取到的特征信息进行相应的线性融合。通过 softmax 分类器将所获取到的 768 维的特征向量最终映射成本数据集中对应的 4 维特征向量, 分别对应于一芽两叶类型嫩芽, 全开面类型嫩芽, 半开面类型嫩芽以及非嫩芽部分的背景。

3.3.2 网络模型双线性分支构建

Tanenbaum 和 Freeman 提出了双线性模型^[40]。

图像分类的双线性模型 B 由四个参数影响着, $B = (f_A, f_B, P, C)$ 。其中 f_A, f_B 是特征函数, P 是池函数, C 是分类函数。一个特征函数是一个映射 $f: L \times I \rightarrow R^{c \times D}$, 上述公式表示, 特征函数接受一个图像 I 和一个位置信息 L , 输出一个尺寸为 $c \times D$ 大小的特征。其中位置信息 L 既可以包括位置也可以包括比例尺。特征的输出是使用矩阵外积在每个位置进行结合, 即特征 f_A, f_B 在某个位置的双线性特征组合 l 。其中 l 由公式 $(l, I, f_A, f_B) = f_A(l, I)^T f_B(l, I)$ 所影响。

本文在残差网络 ResNet18 的基础上增加了一种双线性分支模型, 从而对 ResNet18 加以改进, 这种双线性架构在识别上存在一定的优势。

双线性分支网络的特征提取是基于具有上下分支的卷积神经网络的特征输出, 在图像的每个位置以外积相乘的方式进行特征的提取操作。通过不同位置信息的集合来进行图像的相关描述。上下分支的特征通道具有一定的相关性, 以平移不变的方式来模拟局部成对特征的信息交互, 这种方式比较适用于对细粒度进行分类的任务。其中细化程度越高, 粒度级就越小; 相反, 细化程度越低, 粒度级就越大^[41]。细粒度的识别任务一般在鸟类的物种以及飞机的模型种

应用的比较多，当然它是比较有挑战性的，因为类别之间的视觉差异比较小，如姿势、观点或在图像中对象的位置，这些都是很容易被淹没的因素。例如，“环喙鸥”和“加州鸥”之间由于其喙上的图案差异而产生的类别间差异显著小于一个流行的鸟类细粒度识别数据集上的分类差异。

双线性模型特征提取器是基于卷积神经网络的，简化了网络的梯度计算。使用 ImageNet 数据集初始化的网络来进行特定区域的调整。在测试的过程中，用于图像分类的双线性 CNN 模型由分支 A 与分支 B 组合而成，它们的输出在图像的每一个位置使用外部乘积的方式，并汇集到一起以获得双线性向量，接着通过分类层来获得相应的预测^[42]。

由于本文数据集嫩芽叶片有大有小，为了准确检测定位叶片，应该要同时关注全局特征跟局部特征。结合双线性 CNN 模型的特点，所以本文在残差网络中增加设计双线性分支模型。利用上分支将样本数据经过 ResNet18 的全部四个 basic block 作用，关注全局特征。下分支裁剪出关注区域，将样本数据大小设置为 24*24 大小，通过 ResNet18 前三个 basic block 进行特征提取，做细粒度的检测。通过上述方式，关注局部特征。这种双线性分支的模型既找到了样本数据的全局特征信息，同时也关注到了局部的细节。最后综合全局信息及局部信息进行相应的特征分类，一定程度上提高了模型的相关性能及精度。上述网络模型结构使得本数据集可以得到更好的训练学习。

3.3.3 全连接层改进

传统的 CNN 模型采用全连接层，由于网络 90% 的参数都集中在该层，这将导致较大的计算机内存需求，Hinton 等人提出全连接层设置 Dropout，可以减少参数量，避免过拟合，使得网络性能更好。但是 Dropout 参数寻优依赖于人工的经验，针对参数量过大，容易出现过拟合的现象，所以本文采取全局池化来有效避免该问题，将 ResNet18 网络利用全局池化（global pooling）代替原网络中的全连接层。达到了降低参数的目的。将输出特征图的尺寸变成 1*1 大小，这样可以在减少参数计算量的同时得到图像的具体特征^[43]。

传统的 ResNet18 模型是在 ImageNet 数据库上进行训练的，模型在 ImageNet 数据库中最后分类有 1000 类。结合本文的嫩芽数据集的特点，因数据集共分类为 4 类，4 种类别分别为一芽两叶嫩芽类型、全开面嫩芽类型、半开面嫩芽类型以及非嫩芽部分的背景图片。本文将在 ImageNet 数据集上训练的 1000 类的分类层调整为适应本数据集的 4 类的 softmax 层，将最后的全连接层分类的维度调整为本数据集对应的 4 类嫩芽。由于双线性分支的上分支最终得到的是 512 维的特征向量，下分支经过特征提取得到了 256 维的特征向量。通过全连接将上下分支的特征向量线性融合成共 768 维的特征向量，结合 softmax 分类器，

将双线性分支最后的全连接层提取到的 768 维的特征向量映射成 4 维特征向量。通过分类器的转换，完成了本数据集的 4 类嫩芽的分类工作。

3.3.4 混淆矩阵构建

为了提取模型性能的更多信息，可以使用混淆矩阵，混淆矩阵有助于区分不同类别时鉴别类型是否“混淆”。所以混淆矩阵是一种可以衡量模型训练及验证准确率、召回率等性能指标的直观性的可视化矩阵。所以本文针对数据验证的正常的训练精度、损失率指标以外，考虑到本数据集的特殊性，对自有数据集应用了混淆矩阵来进行相应验证，用混淆矩阵的方法验证模型的有效性，以保证本论文数据集的识别效果。

混淆矩阵是模式识别领域常用的一种表达方式，作为一种分析表，用于总结机器学习中分类模型的预测。这是一种常用的评估分类器性能的方法，通过混淆矩阵的形式可以显示样本数据的真实属性与分类预测结果类型之间的关系^[44]。本次实验中引入混淆矩阵从而可以清晰的看出数据训练的效果，通过混淆矩阵的计算，可以迅速看出每次训练的召回率和准确率等指标。

表 3.2 四分类问题的混淆矩阵

Tab. 3.2 Confusion matrix for a four-class problem

预测值 真实值	类别 1	类别 2	类别 3	类别 4	小计
类别 1	a	e	h	j	v
类别 2	k	b	f	i	w
类别 3	n	l	c	g	x
类别 4	p	o	m	d	y
小计	r	s	t	u	z

上示表 3.2 中，v，w，x，y 分别代表类别 1，类别 2，类别 3，类别 4 的真实样本数，r，s，t，u 分别代表结果中预测为类别 1，类别 2，类别 3，类别 4 的样本数。z 是所有样本的总数。表格中的 a，b，c，d 分别代表的是正确分类的样本数目，e，f，g，h，i，j，k，l，m，n，o，p 代表的是错误分类的样本数目。

准确率作为分类问题最原始的评价指标，定义为正确预测样本占总样本的百分比，对于上述表格所表示的混淆矩阵其准确率表示如下：

$$accuracy = \frac{a+b+c+d}{z} \quad (3.6)$$

正确分类的概率越高，损失函数的值越小。正确分类的概率越小，损失函

数的值越高。如果正确分类的概率为 1，即分类结果完全正确，则损失函数的值应为 0。通过分类模型得到的预测结果和实际属性可以以列表的形式显示出来。下图 3.6 所示，是利用混淆矩阵表示改进后的网络对数据训练的效果。




图 3.6 混淆矩阵计算展示

Fig. 3.6 Confusion matrix calculation display

混淆矩阵每行的四个元素代表实际值，而矩阵中每一列的四个元素则分别对应的是预测为这四种类型的预测结果。由混淆矩阵我们可以计算出网络的每次训练所对应的各项指标值精确率以及召回率等。

上示混淆矩阵中，纵轴上的标签表示真实属性，横轴的标签 1、2、3、4 表示分类预测结果分别为一芽两叶嫩芽类型、全开面类型、半开面类型以及当作负样本训练的非嫩芽部位的背景图片。纵轴的标签则是每种嫩芽的实际类型。

上述混淆矩阵中第一行第一列中的数字 213 表示一芽两叶类型的嫩芽被成功分类成为一芽两叶的样本数，分类正确。其中第三行第一列的数字 1 表示半开面嫩芽被错误分类成一芽两叶的样本数目，属于分类错误。

混淆矩阵每一行显示的数据总和代表了该类别的实际数目，每列显示的数据总和代表了该类别的预测的总数目。矩阵中的对角线上的数值表示被准确预测的样本数。

混淆矩阵可以清晰的表示出数据训练的效果，通过可视化的方式可以看出本文嫩芽数据集检测正确的样本数目。通过混淆矩阵的展示，可以很直观的分

析出类别的判断是否准确，从而可以对网络学习的模型及时进行相应的调整。

3.4 改进后 ResNet18 网络与传统的网络模型对比分析

3.4.1 本文网络实验结果

本文的所有网络模型的实验均以 anaconda 软件为基础，所依赖的开发环境为 spyder。使用 python3.6.5 版本，pytorch1.6.0，处理器为 11th Gen Intel(R) Core(TM) i5-11400 @ 2.60GHz 2.59 GHz。

经过上述改进后的网络对于本文茶叶嫩芽数据集的训练学习，实验数据通过上下网络分支同时进行特征提取，嫩芽数据得到了较好的分类。

最终网络验证的结果如下图 3.7 所示，这是改进后的网络模型每次在验证样本集上的验证结果展示，下图所示验证结果的验证方式为每次随机从验证样本集中随机进行嫩芽的抽取检测结果。下图 3.7a 验证结果所示的三个一芽两叶类型的嫩芽全部正确检测为第 1 类的嫩芽样本，三张非嫩芽的背景部分也均正确检测为第四类的背景部分。其中全开面嫩芽类型被正确检测为第二类的类型。随机抽取的验证图片的检测结果均正确，实验证明了网络模型的准确性及网络分类的有效性。



图 3.7 验证过程嫩芽类型检测结果展示

Fig. 3.7 Validation process sprout type detection results display

3.4.2 网络模型运算时间对比分析

网络模型训练各项指标展示如下图 3.8 所示：



图 3.8 各网络模型运算结果展示

Fig. 3.8 Display of calculation results of each network model

如下表 3.3 所示为四种不同网络模型的第 25 次网络训练的精确度以及损失率以及相应的训练时长的对比展示表。从表中可以清晰的看出，对本文嫩芽数据集训练学习完成所需时长可以看出，VGG 网络模型对嫩芽样本的训练所需时间相较于其他模型来说是最长的。改进后的 ResNet18 网络模型对于嫩芽样本的训练学习时间是四个模型中最短的，时间为 32min17s，而且改进后的 ResNet18 网络模型的训练、验证精确度以及损失率相较于其他四个网络模型而言，其性能指标也是最佳的。综上所述，基于改进的双线性分支残差网络 ResNet18 网络模型更适用于本数据集的应用。

表 3.3 四种网络模型各性能指标对比

Tab. 3.3 Comparison of performance indicators of four network models

模型名称	Train_loss	Train_acc	Val_loss	Val_acc	Time	Epoch
AlexNet	0.2512	0.8957	0.2409	0.8989	204min24s	25
VGG	0.1118	0.9638	0.1091	0.9580	215min15s	25
ResNet18	0.0641	0.9841	0.0308	0.9898	32min30s	25
改进 ResNet18	0.0514	0.9860	0.0151	0.9981	32min17s	25

3.4.3 网络模型训练精度对比分析

训练过程中四种模型的训练精度折线对比如下图 3.9 所示：




图 3.9 四种模型的训练精度曲线对比图

Fig. 3.9 Comparison of training accuracy curves of four models

验证过程中四种模型的验证精度折线对比如下图 3.10 所示：




图 3.10 四种模型的验证精度曲线对比图

Fig. 3.10 Comparison of verification accuracy curves of four models

精确度是衡量一个网络模型训练是否准确的一个重要指标，精确度越高表示网络模型越好，精确度越低则表示网络模型较差。

由上述训练及验证过程中四个模型对比曲线可以明显观察出来：随着训练次数的增加，模型的精确度在不断提升，其中经过改进后的 ResNet18 的训练及验证精确度明显都优于其他三个的网络模型的精度；此外，除了 AlexNet 模型，

其余四个网络模型的验证精度都明显高于其训练时的精度，其中改进过后的 ResNet18 的起始精确度由 0.7883 上升到 0.8824，精确度上升了近 0.1，且一直处于稳步上升的趋势，验证的最高精确度达 0.9981。

3.4.4 网络模型损失率对比分析

训练过程中四种模型的损失率折线对比如下图 3.11 所示：




图 3.11 四种模型的训练损失率曲线对比图

Fig. 3.11 Comparison of training loss rate curves of four models

验证过程中四种模型的损失率折线对比如下图 3.12 所示：




图 3.12 四种模型的验证损失率曲线对比图

Fig. 3.12 Comparison of verification loss rate curves of four models

正确分类的概率越高，损失率的值越小，正确分类的概率越低，损失率的值越高。如果正确分类的概率为 1，即分类结果完全正确，则损失率的值应为 0。由上述训练及验证过程中四个模型损失率对比曲线可以明显观察出来：随着训练次数的增加，损失率也在下降，改进后的 ResNet18 网络模型的训练及验证时的初始损失率相较其他网络模型而言更低，训练时的初始损失率低为 0.5856，验证时的初始损失率为 0.3024，这表明改进后的网络性能更优。与此同时，改进后的 ResNet18 网络模型的损失率曲线下降的最快，且最早的趋于稳定。各项指标表明改进后的 ResNet18 网络性能更加适合本数据集的应用。

3.4.5 网络模型混淆矩阵对比分析

下图 3.13 所示为四种模型的混淆矩阵计算结果，混淆矩阵中主对角线上的四个元素分别为正确检测为一芽两叶、全开面、半开面、背景图的样本数目，其中改进后的 ResNet18 网络检测出正确样本相对于其他网络而言数目最多，网络性能最佳。




图 3.13 四种模型混淆矩阵结果展示

Fig. 3.13 Four model confusion matrix results display

3.5 本章小结

本章节主要介绍了 Alexnet、VGG、ResNet 卷积神经网络的模型的具体结构，利用传统网络结构的权重对本数据集进行训练学习，由于本数据集嫩芽大小不一的特点，对传统的 ResNet18 网络进行了相应的改进工作，加入双线性分支模型，将 ResNet18 网络中的全连接层用全局池化代替，降低参数量。利用 softmax 分类器进行特征向量的分类。网络验证的各项指标显示改进后的 ResNet18 网络性能更佳，为下一章节对实际场景嫩芽数据分类识别打下基础。

4. 实际茶叶嫩芽数据分类识别结果及分析

4.1 实际场景数据嫩芽分类识别

4.1.1 多尺度滑窗的验证方式

为了检测网络模型的性能,需要将实际茶叶大图分割成与训练样本大小相同的图像,并输入到网络中进行相应的验证。与许多识别和检测任务一样,需要在大图像中准确找到检测框^[45]。这就需要利用多尺度滑动窗口的方式获取与训练样本所对应的样本的尺寸。比如 `opencv` 自带的行人检测模块,使用多尺度滑动窗口提取 n 个检测窗口,记录窗口的坐标,最后再将这些检测的子窗口送入分类器^[46]。由于从茶树全场景图中检测出嫩芽的位置并给嫩芽进行相应类型的分类,即判定嫩芽类型为全开面、一芽两叶、半开面中的具体类型,这种任务是一种标准的目标检测任务。但由于本文数据集的标注比较少,无法完成目标检测模型的训练,所以本文将目标检测任务转化成一个图像块分类的一个任务即 `patch` 块的分类任务。

如下图 4.1 所示,图中的三个框分别表示三个不同尺寸的滑动窗口,本文利用了 $32*32$, $48*48$, $64*64$ 三种不同尺寸的框做滑动窗口,用不同大小的框分别去做测试,按照三种比例的滑动窗口对茶树全场景图进行遍历,获取小的 `patch` 图块。

(1) 多尺度测试方法的识别过程



图 4.1 多尺度检测方式示意图

Fig. 4.1 Schematic diagram of multi-scale detection method

以上述方式为前提, 本文利用多尺度滑窗的方式获取茶树全场景图中的 patch 块, 并且将其送进改进后的网络模型中去验证, 通过分类器的作用, 得到每个 patch 的对应的类别。

完成上述操作后将滑窗得到的 patch 块送进网络模型中去验证。整体思路为: 在一个大图上划分 patch。假设大图是 512×512 的, 每个 patch 块是 32×32 的。设置了一个这样的窗口后, 对此窗口按照一定的步长进行滑窗, 每抠出来这样的一个 patch 块都把它输入到改进的双线性 ResNet18 网络中做分类结果, 并通过分类器将把分类的结果附给每一个 patch 块的取值。

验证部分的流程如下图 4.2 所示:




图 4.2 验证部分流程图

Fig. 4.2 Verification part flow chart

以前述训练得到的网络模型为基础, 对茶树全场景图进行检测验证, 利用多尺度测量方法, 对整张图嫩芽的局部区域 patch 块, 送到网络中进行识别, 经过层层卷积与池化过程来得到每个 patch 对应的特征向量, 通过 softmax 分类器, 能够计算出每个特征向量所对应的概率值, 从而可以得知每个 patch 所对应的概率, 即可判断出其所属的类别。根据识别结果汇总数据标记。

(2) 不同滑窗尺寸对检测结果的分析

将本文分别利用三种不同尺寸的滑动窗口进行相应性能指标的对比如下表 4.1 所示：

表 4.1 不同滑窗尺寸性能指标对比分析

Tab. 4.1 Comparative analysis of performance indicators of different sliding window sizes

尺寸	遍历步长	遍历时间	检测精度
32*32	2	60s	75%
48*48	2	45s	72%
64*64	2	40s	68%

如上表所示，当滑动窗口在实景茶树图像中的遍历步长同时设定为 2 时，三个尺寸的滑动窗口所需时间最短的是 64*64，但是检测精度最高的确是 32*32 尺寸大小的滑动窗口，根据本文所需参考的性能指标，最终选择利用检测精度更加高的 32*32 尺寸大小的滑窗作为最终选择的尺寸。

4.1.2 实际数据验证结果展示

如下图 4.3 所示，为复杂背景下的茶叶基地拍摄图片，通过多尺度滑窗的方式，将得到的滑动窗口喂入上述改进后的 ResNet18 网络模型中进行相应的识别工作。



图 4.3 茶叶实际验证图展示

Fig. 4.3 Tea actual verification diagram display

经过网络识别能够判断出嫩芽的所属类别，同时根据坐标信息可以定位出茶叶嫩芽的局部框图。利用实际场景茶树图片验证改进模型的准确性，实验结果也证明了改进后网络模型的有效性。

下图 4.4 所示为用实际茶树全景图片，来验证改进后的 ResNet18 网络模型性能有效性的验证结果展示图。图中显示，模型识别出了茶叶嫩芽的局部框图。每个局部框图显示的信息为，框图的序号及嫩芽所属的类别信息。其中蓝色框及其中的 ly 表示的是一芽两叶的茶叶嫩芽类型，红色框及其中的 qk 表示的是全开面的茶叶类型，绿色框及其中的 bk 表示的是半开面的茶叶嫩芽类型。但是由上示茶叶检测出的局部嫩芽的效果所示，出现了部分嫩芽漏检的情况，证明网络的泛化性能还有待提高。




图 4.4 实际验证图检测结果展示

Fig. 4.4 Actual verification image test result display

4.2 嫩芽局部区域图像提取

由于识别到的嫩芽存在不同角度的偏转，为了实现机械化嫩芽采摘，需要给机械手提供嫩芽具体位置信息以及相应的偏转角度。所以本文准备设计相关方法对检测到的嫩芽进行位置信息及朝向信息的获取。在此之前需要标记出所检测到嫩芽的位置信息，利用相关存储语句将改进后的模型所检测到的嫩芽位置信息保存在如下.txt 文件所示的文件夹中，并通过获取的位置坐标信息将相关嫩芽自动分割出来便于后续嫩芽二值化处理，从而可以利用形态学的方法对嫩

芽的朝向问题及嫩芽中心点的获取提供基础，具体流程如下图 4.5 所示：




图 4.5 嫩芽局部区域图像提取流程

Fig. 4.5 Image extraction process of sprout local area

下图 4.6 所示为每次检测的实际数据中检测到的嫩芽图片，图中所示为检测到的实际检测数据集中的第 33 幅茶叶实景图片。提取到的嫩芽局部框图图片命名的方式是：第一个数字为实际检测大图的序号-id-检测出来的嫩芽的序号-检测嫩芽框的对角的横坐标及纵坐标（用四个数字进行相应的表示）-class-检测出来的每个嫩芽的类别（ly 为一芽两叶类型，qk 为全开面的类型，bk 为半开面的类型）。




图 4.6 检测出的嫩芽坐标及类型获取

Fig. 4.6 Acquisition of detected sprout coordinates and type

用上述所示方式将识别结果进行标记并单独分割，为后续嫩芽准确位置坐

标及朝向信息识别提供基础数据。

4.3 本章小结

本章节具体工作为实景茶树图片对网络模型进行验证的工作，利用改进的模型在实际数据中验证其分类效果。具体利用多尺度滑窗的方式将实景茶树图片划分成多个 patch 块送进网络进行验证，从而检测局部嫩芽的具体位置，并且得到嫩芽的局部区域定位，把每一个嫩芽的局部区域图像信息提取出来，方便后续对具体嫩芽位置和朝向信息进行识别，为下一章节计算检测到的嫩芽的质心及相应的偏转角度打下基础。

5. 图像分割及嫩芽位置信息识别

本章节着重对上一章节识别到的嫩芽局部区域图片进行相应的形态学方法处理。对比选用了两种图像分割的方法对嫩芽进行感兴趣部分的分割提取，为后续嫩芽质心的获取及朝向偏转角的计算提供基础数据。

5.1 基于改进的 GMM 模型茶叶嫩芽分割方法

5.1.1 基于 K-means 的嫩芽分割

(1) K-means 具体的思想：

K-means 是把图像的每个像素点的灰度值看成是一中特征的表示，在灰度值的空间上做无监督的聚类。假设有两个簇，首先需要完成的工作就是选出两个簇所对应的聚类中心。聚类中心的设置方式选用随机化方式，对这个簇中的所有样本点与其聚类中心计算距离^[47]，这两个聚类中心就是对应着我嫩芽数据集的前景和背景，前景是有嫩芽的部分。经过计算距离可以分出属于每个聚类中心的子簇，经过每次迭代都可以找到属于聚类中心的簇。

(2) K-means 算法具体流程如下图 5.1 所示：




图 5.1 K-means 算法流程图

Fig. 5.1 K-means algorithm flow chart

如果按照上述步骤，第一次迭代完成后得到两个信息。一个是初始聚类的中心，另一个是每个样本所属的类别。得到这两个信息后，就可以估算出新的聚类中心。经过不断的迭代，每次迭代完成后都会产生一个新的聚类中心。每个类别属于具体的聚类中心的簇的无监督的标签，然后不断的去做聚类，反复迭代^[48]。

(3) K-means 算法代码详解：

在 RGB 空间做聚类的，需要将 RGB 图像对应像素值转化成相应的灰度值，用下述代码中的方式进行数据的加载。用 `np.array` 将数据以数组的形式进行保存，用 `opencv` 中的函数直接把它转变成灰度值。灰度空间的计算实质上就相当于对 RGB 做一个加权 ($R \times \text{系数} + G \times \text{系数} + B \times \text{系数}$)。完成上述步骤可以得到了一个单通道的图像，图像尺寸大小是 $m \times n$ ，通道数是 1，每一个像素点代表它的灰度。

```
def load_data(file_path):
    f = open(file_path, "rb")
    data = []
    image_rgb = np.array(image.open(f))
    print(image_rgb.shape)
    im = image.open(f).convert('L')
    print(im.size)

    img = np.array(im)
    # m, n, dims= img.shape
    m, n = img.shape
```

图 5.2 图像灰度化

Fig. 5.2 Image grayscale

得到灰度值就可以随机选取聚类中心，然后对除了聚类中心之外的样本数据做距离的计算。

```
k = 2
cluster_center = Kmeans_randomInitv2(img,k)
#print(cluster_center)
iteration = 10
for i in range(iteration):
    cluster,distance = Kmeans_ComputeDis(img,cluster_center)
    cluster_center = Kmeans_ComputerCenter(img,cluster,k)
    if i%1 == 0:
        # print(cluster_center)
        print('curr distance is: ' + str(distance))
    #print(cluster)
```

图 5.3 样本数据与聚类中心的距离计算

Fig. 5.3 Calculation of distance between sample data and cluster center

本文利用 $Kmeans_ComputeDis$ 来计算样本数据与聚类中心之间的距离,有了这个距离之后就可以算出新的聚类中心,重复上述步骤(本文迭代次数为10),整个过程是无监督的,根据本数据集的特点,希望输出有嫩芽的地方是正类,非嫩芽部分为负类。所以将聚类中心的个数 $k=2$ 。

5.1.2 基于 GMM 模型的嫩芽分割

(1) 高斯混合模型基本原理:

高斯混合模型是一种用于近似图像直方图的概率模型,将灰度图像 I 视为随机场,图像中有 k 个不同的区域,在第 i 个区域的灰度服从以 (μ_i, σ_i) 为参数,服从高斯分布,整个图像可以用这 k 个统计模型的混合统计模型表示。待分割的目标区域的灰度统计分布也可以用这 k 个统计模型中的若干个统计模型混合表示^[49]。

如果图像的感兴趣区域和背景区域存在较大差异,且背景区域和感兴趣区域之间的灰度级有一定的差异,那么图像的灰度直方图显示现双峰-谷形状,其中一个峰对应于目标,另一个峰对应于背景的中心灰度^[50]。

本文对 GMM 模型的改进:利用 gibbs 方程结合平滑项来估计模型的参数。使用 GMM 模型,将一个分布用多个高斯分布来做估计,而不是只用单一的高斯分布来进行。可根据具体实验要求来确定到底用几个高斯分布来做,实验中可用 k 来具体表示, k 表示使用高斯分布的数量。本文的 k 的取值为 5,即用了 5 个高斯混合模型,进行估计。

(2) 具体公式及参数的选取:

本文利用 α_n 参数来代表每个像素属于前景还是背景的概率。 α_n 的取值为 0 和 1。

首先建立 Gibbs 方程:

$$E(\underline{\alpha}, k, \underline{\theta}, z) = U(\underline{\alpha}, k, \underline{\theta}, z) + V(\underline{\alpha}, z) \quad (5.1)$$

此方程的中心思想是将能量函数最小化来得到前景的部分;

其中, $U(\underline{\alpha}, k, \underline{\theta}, z)$ 表达式中,参数 $\underline{\alpha}$ 是最终的输出结果;参数 k 表示用了几个高斯模型来估计前景和背景的像素的分布。本次实验的 k 设定为 5。 $\underline{\theta}$ 是高斯混合模型中的参数; z_n 是输入数据,在 RGB 空间上,一个分布用几个高斯模型来估计,而不是只用一个高斯分布。设置 $V(\underline{\alpha}, z)$ 作为函数的平滑项;上述

Gibbs 方程中的 U 为:

$$U(\underline{\alpha}, k, \underline{\theta}, z) = \sum_n D(\alpha_n, k_n, \underline{\theta}, z_n) \quad (5.2)$$

$$D(\alpha_n, k_n, \underline{\theta}, z_n) = -\log p(z_n | \alpha_n, k_n, \underline{\theta}) - \log \pi(\alpha_n, k_n) \quad (5.3)$$

其中 $p(z_n | \alpha_n, k_n, \underline{\theta})$ 是一个高斯概率模型, n 表示高斯模型的数量, 拿 n 个高斯模型做相乘这样的方式来估计它到底属不属于这个类别。只需知道两个参数即可把此模型估计出来, 一个是均值, 另一个就是方差。估计每一个高斯模型的均值和方差。这里应用了多个复杂的高斯模型来估计 $h(z; \alpha)$, 即 $\underline{\theta}$ 的值。

$$V(\underline{\alpha}, z) = \gamma \sum_{(m,n) \in C} [\alpha_n \neq \alpha_m] \exp - \beta \|z_m - z_n\|^2 \quad (5.4)$$

上式 5.4 中, $\|z_m - z_n\|^2$ 表示输入数据的 RGB 之间的距离, $\exp - \beta \|z_m - z_n\|^2$ 可以看成是一个高斯距离, 用高斯距离来衡量他们之间的距离。如果像素值的距离近, 但又没被分到同一个类别, 就要受到一个惩罚。 $\pi(\alpha_n, k_n)$ 是混合的加权的系数。

(3) GMM 模型算法代码详解:

GMM 算法是直接调用的库, opencv 中执行好的代码:

```
image_base_path = r'D:/clj-yan/picture/嫩芽手动切割图片/全开面'
for image_name in os.listdir(image_base_path):
    image_path = os.path.join(image_base_path, image_name)

    src = np.array(PIM.open(image_path))[:, :, :3][:, :, ::-1]
    #src = cv.resize(src, (0,0), fx=3, fy=3)
    #src = cv.imread(image_base_path)
    src = cv.pyrMeanShiftFiltering(src, 25, 40, None, 2)
    #cv.imshow("result", np.hstack((src,dst)))
```

图 5.4 数据的读入

Fig. 5.4 Data reading

首先将图片以数组的形式读入, 用 opencv 做一个类似于双边滤波的图片平滑工作, 用均值和方差做预处理, 可以设置一个阈值范围, 让图像看起来比较平滑。平滑部分利用 opencv 中的 *cv.pyrMeanShiftFiltering* 进行平滑。将平滑过后的图片使存进 *src* 里面。

如下图 5.5 为整个 GMM 模型的流程图, 其中的函数是在优化前景及背景统计直方图时, 增加一个平滑项 (即惩罚项)。因为图像分割是一个结构化输出

的任务，它相邻的像素很大概率是要被划分成同一个标签。如果这两个像素 z_m 、 z_n 差异比较大，但又把它们划分成了同一个类别，那么它就要受到这样一个惩罚。起到鼓励 RGB 空间上相似的像素能够被分为同一类别的作用。 α_n, α_m 代表两个上述像素是否属于同一类别。如果两个像素的相似度很大，但又没被划分到同一类别，就会受到此惩罚。




图 5.5 GMM 模型流程图

Fig. 5.5 GMM model flow chart

高斯混合模型（GMM）算法的基本建模方法就是在目标图像中可以先自定义框出一个可以区分前景和背景的框，针对于本文的数据集就是 GMM 模型期望定义出一个可以区分嫩芽以及非嫩芽部分的背景区域。然后建立相应的高斯模型，判断目标图像种的各个像素点究竟隶属于哪一个高斯模型。下图 5.6 所示为选定区分前景与背景框的操作过程。定义从左边的 0.05 到右边的 0.95 这个

大致的范围为前景部分，对应于本文目标图像的嫩芽部分，剩余的就是全部的非嫩芽区域的背景部分。

```
# 提取前景和可能的前景区域
mask2 = np.where((mask==1) + (mask==3), 255, 0).astype('uint8')

print(mask2.shape)

result = cv.bitwise_and(src,src,mask=mask2)

result_base_path = "D:/clj-yan/gmm-result"
if not os.path.exists(result_base_path):
    os.mkdir(result_base_path)
save_name = image_name.replace(".PNG", ".jpg")

# save ROI images
save_path = os.path.join(result_base_path, "imgmask")
if not os.path.exists(save_path):
    os.mkdir(save_path)
cv.imwrite(os.path.join(save_path, save_name), result.astype(np.uint8))
cv.imwrite(os.path.join(save_path, "ROI_"+save_name), roi.astype(np.uint8))

# save 2Bit images
save_path = os.path.join(result_base_path, "2bit")
if not os.path.exists(save_path):
    os.mkdir(save_path)
cv.imwrite(os.path.join(save_path, save_name), (mask2).astype(np.uint8))
```

图 5.6 前景与背景区域的提取

Fig. 5.6 Extraction of foreground and background regions

首先初始化一些预先定义的高斯模型，然后初始化高斯模型的参数，并求出之后将要用到的参数。然后，对于每一帧中的每一个像素进行处理，看其是否匹配某个模型。如果它们匹配，则将它们分类到模型中，并根据新的像素值更新模型。若不匹配，则以该像素建立一个高斯模型，初始化参数，代理原有模型中最不可能的模型。最后选择前面几个最有可能的模型作为背景模型，为背景目标提取做铺垫。

5.2 基于不变矩的嫩芽质心计算方法

5.2.1 不变矩的定义

矩特征是表征图像区域的几何特征^[51]，它也被称为不变矩，因为它对于旋转、平移和尺度变化是恒定的。Hu 不变矩是一种典型的不变矩。在上示利用 GMM 模型获取到的嫩芽二值图像具有明显的轮廓，所以接下来本文将截取到的嫩芽二值图像的轮廓的周长及面积作为基本特征，经过处理后得到 Hu 不变矩特征，用于检测嫩芽二值图像的质心^[52]。

Image Moment 是一种非常有用的图像处理算法。它可用于计算区域图像的

质心、方向和其他几何属性。同时 M_{pq} 的高阶具有旋转不变性，可以用来实现图像比较与分类。正是因为 Moments 有这些特性，很多手绘油画效果。也会基于该算法来模拟实现。它的数学表达为：

$$M_{pq} = \int_{a_1}^{a_2} \int_{b_1}^{b_2} x^p y^q f(x, y) dx dy \quad (5.5)$$

其中 x, y 为像素的坐标， $f(x, y)$ 为像素， MN 为图像的大小。

大小为 $M * N$ 的数字图像 $f(x, y)$ 的二维 $(p + q)$ 阶矩定义为：

$$m_{pq} = \sum_{X=0}^{M-1} \sum_{Y=0}^{N-1} x^p y^q f(x, y) \quad (5.6)$$

式 5.6 中， $p = 0, 1, 2, \dots$ 和 $q = 0, 1, 2, \dots$ 是整数，相应的 $(p + q)$ 阶中心矩定义为：

$$\mu_{pq} = \sum_{X=0}^{M-1} \sum_{Y=0}^{N-1} (x - \bar{x})^p (y - \bar{y})^q f(x, y) \quad (5.7)$$

式中， $p = 0, 1, 2, \dots$ 和 $q = 0, 1, 2, \dots$ 其中

$$\bar{x} = \frac{m_{10}}{m_{00}} \text{ 和 } \bar{y} = \frac{m_{01}}{m_{00}} \quad (5.8)$$

其中 $b = \frac{m_{11}}{m_{00}} - \bar{x}\bar{y}, a = \frac{m_{20}}{m_{00}} - \bar{x}^2, c = \frac{m_{01}}{m_{00}} - \bar{y}^2$ 。

5.2.2 质心及偏转角的确定

几何矩在图像分析和模式识别中应用最为广泛，主要得益于它的简单性、不变性以及低阶矩所具有的几何意义。实际上零阶矩 m_{00} 代表的是灰度图像的质量，一阶矩 (m_{10}, m_{01}) 代表的是质心的位置，即对应为本文样本集中嫩芽质心的位置。二阶矩 (m_{20}, m_{11}, m_{02}) 可用于表示图像椭圆的特性，可以用来计算区域的方向或者角度。所以本文采用矩计算的方式来对嫩芽的质心以及相应的偏转角度做出相应的计算。

其中坐标 $(\bar{x}, \bar{y})$ 为所求图片的中心矩，又称图片的质心，即嫩芽质心坐标为

$$\left(\frac{m_{10}}{m_{00}}, \frac{m_{01}}{m_{00}} \right)。$$

下图 5.7 所示为具体的嫩芽质心坐标的计算，利用质心坐标公式可以将嫩芽图像的质心表示出来。

```
# centroid
center_save_path = os.path.join(result_base_path, "centroid")
if not os.path.exists(save_path):
    os.mkdir(save_path)
if np.sum(mask2) > 5:
    M = cv.moments((mask2).astype(np.uint8))
    cX = int(M["m10"] / M["m00"])
    cY = int(M["m01"] / M["m00"])
    #cen_roi = mask2.astype(np.uint8)
    cen_roi = np.zeros((mask2.shape[0], mask2.shape[1], 3))
    cen_roi[mask2 > 0] = (255, 255, 255)
    cv.circle(cen_roi, (cX, cY), 2, (0, 0, 255), -1)
    #cv.putText(cen_roi, "center", (cX - 25, cY - 25), cv.FONT_HERSHEY_SIMPLEX, 0.5,
    cv.imwrite(os.path.join(center_save_path, save_name), (cen_roi).astype(np.uint8))
```

图 5.7 质心坐标的计算

Fig. 5.7 Calculation of centroid coordinates

本文利用了角度计算的公式来估计嫩芽具体形状偏转的方向，具体的偏转角为：

$$\theta = \frac{1}{2} \arctan \frac{2b}{a-c}, \theta \in [-90^\circ, 90^\circ] \quad (5.9)$$

下图 5.8 所示为嫩芽具体偏转角度的计算公式：

```
if not one_flag:
    xx = [xy[0][0] for xy in approx]
    yy = [xy[0][1] for xy in approx]
    min_x, max_x, min_y, max_y = min(xx), max(xx), min(yy), max(yy)
    #print(min_x, max_x, min_y, max_y)
    cv.circle(tmp, (min_x, min_y), 2, 255, -1)
    cv.circle(tmp, (max_x, min_y), 2, 255, -1)
    cv.circle(tmp, (cX, cY), 2, 255, -1)
    #theta_1 = np.arctan(abs(cX - max_x) / abs(cY - min_y))
    #theta_2 = np.arctan(abs(cX - min_x) / abs(cY - min_y))
    theta_1 = azimuthAngle(min_x, min_y, cX, cY)
    theta_2 = azimuthAngle(max_x, min_y, cX, cY)
    #cv.imwrite(os.path.join(save_path, save_name), (tmp).astype(np.uint8))
    print('两个叶片的夹角分别是: ', theta_1, theta_2)
else:
    xx = [xy[0][0] for xy in approx]
    yy = [xy[0][1] for xy in approx]
    min_x, max_x, min_y, max_y = min(xx), max(xx), min(yy), max(yy)
    if tmp[int(min_x), int(min_y)] > 0:
        theta = azimuthAngle(min_x, min_y, cX, cY)
    else:
        theta = azimuthAngle(max_x, min_y, cX, cY)
    print('叶片的夹角是: ', theta)
```

图 5.8 嫩芽朝向角度计算

Fig. 5.8 Calculation of the orientation angle of the shoots

嫩芽质心及偏转角度的具体计算流程如下图 5.9 所示：




图 5.9 质心算法流程图

Fig. 5. 9 Centroid algorithm flowchart

将识别到的嫩芽局部框图利用 GMM 分割算法将框图中的嫩芽部分进行提取，并且将其二值化处理，再利用图像的矩相关计算方法确定嫩芽的质心以及相关朝向角度，再将处理后的图像进行相应的输出保存。

5.3 实验结果分析

5.3.1 K-means 处理结果展示

全开面嫩芽类型处理结果如下图 5.10 所示：



图 5.10 全开面类型嫩芽分割效果展示

Fig. 5.10 Full-open noodle type sprout splitting effect display

半开面嫩芽处理结果如下图 5.11 所示：



图 5.11 半开面类型嫩芽分割效果展示

Fig. 5.11 Half-open noodle type sprout splitting effect display

一芽两叶嫩芽处理结果如下图 5.12 所示：




图 5.12 一芽两叶类型嫩芽分割效果展示

Fig. 5.12 One bud and two leaves type buds segmentation effect display

如上述处理结果所示，通过利用 K-means 聚类方法，通过聚类中心不停的迭代选取，实验得到关于嫩芽聚类完成的掩膜，最终通过对聚类得到的掩膜进行二值化来得到相对清晰的嫩芽二值图像，从而可以为嫩芽质心及偏转角度的计算做基础。从上示结果图可以观察到，处理过后的嫩芽二值化图片比未处理时的彩色图的轮廓更加清晰明了。但是部分背景较复杂的嫩芽处理的效果一般，有待改进。

5.3.2 GMM 模型处理结果展示

全开面嫩芽类型处理结果如下图 5.13 所示：




图 5.13 全开面类型嫩芽分割效果展示

Fig. 5.13 Full-open noodle type sprout splitting effect display

半开面嫩芽类型处理结果如下图 5.14 所示：



图 5.14 半开面类型嫩芽分割效果展示

Fig. 5.14 Half-open noodle type sprout splitting effect display

利用高斯混合模型，给定一个图像，在人为标注前景框的前提下，能把框里面的前景给区分出来。从而利用模型的建立，得到相对清晰的嫩芽掩膜图，接着对掩膜做二值化的工作，从而得到相对更加清晰的嫩芽图片。

一芽两叶嫩芽类型处理结果如下图 5.15 所示：




图 5.15 一芽两叶类型嫩芽分割效果展示

Fig. 5.15 One bud and two leaves type buds segmentation effect display

5.3.3 两种方法对比效果展示

通过对比 K-means 聚类方法与基于高斯混合模型（GMM）的嫩芽分割，可以发现利用高斯混合模型的嫩芽分割方法更优，其处理的图像边缘更平滑，杂质相对于 K-means 方法处理的效果要好。如下图 5.16 所示，将利用高斯混合模型（GMM）处理过后的嫩芽样本数据集作为训练样本更有利于后续实验的进行。




图 5.16 两种分割方法对比图

Fig. 5.16 Comparison of two segmentation methods

5.3.4 GMM 模型的嫩芽质心及角度结果展示

下图 5.17a 所示为利用图像的矩相关方法计算出的全开面类型嫩芽的质心及偏转角度的展示，图中的红点为嫩芽的质心，对应的数字为嫩芽的偏转角度。b 图所示为半开面类型嫩芽的处理结果展示，c 图为一芽两叶嫩芽类型处理结果，从处理结果中可以看出，针对两个芽叶，其偏转角度为两个，分别为各个叶片的偏转角度。




图 5.17 质心及角度信息展示图

Fig. 5.17 Center of mass and angle information display diagram

5.4 本章小结

本章节针对第四章检测识别到的茶叶嫩芽局部框图，利用图像分割方法进行嫩芽部分的分割，并将分割后的嫩芽图片进行二值化处理。对比了基于 K-means 以及 GMM 两种图像分割算法，最终选用处理效果更佳的优化后的 GMM 模型，并利用图像的矩的相关计算方法计算出嫩芽的质心及相应的偏转角度。

6. 总结展望

6.1 总结

结合高端茶叶人工采摘效率低的现状,本文提出基于计算机视觉的茶叶嫩芽识别与分类方法研究,结合传统的训练网络,提出改进方案,在一定程度上为实际场景中的嫩芽分类采摘做出相应的贡献。本文的研究内容、提出的改进策略如下所示:

(1) 首先本文以茶叶嫩芽分类为研究背景,结合国内外的研究现状,采用了网络学习模型为主的深度学习进行嫩芽的识别及分类,来代替人工采摘嫩芽并对其进行相应的分类。通过近年来国内外学者对于特征提取及目标识别的研究方法,确定了本文茶叶嫩芽识别及相应分类的研究方向。

(2) 数据集的制作。由于复杂环境拍摄下来的茶叶图片中的嫩芽所受干扰严重,本文首先将收集到的茶叶数据集进行嫩芽样本的截取分类保存,从而获得关于茶叶嫩芽的数据集,便于后续网络学习及训练工作的开展。

(3) 网络模型的相关介绍及相应改进措施的提出。嫩芽数据集制作完成后,提出改进的双线性分支残差网络 ResNet18 模型进行嫩芽的训练与分类。在进行嫩芽训练分类的过程中分别对比 Alexnet、VGG 和 ResNet18 网络模型性能,然后在 ResNet18 网络的基础上提出了双线性分支网络结构,上分支应用 ResNet18 的 4 个 block,感受野大,关注全局特征。下分支应用 ResNet18 的前 3 个 block,裁剪出关注区域,做细粒度检测,感受野小,关注局部特征。网络的下分支用来提取局部的细颗粒特征。通过上下分支网络的分工,将 CNN 提取到的特征信息进行相应的融合,结果表明:改进后的 ResNet18 网络模型相较于单独的模型,其运行速度更快、网络训练准确率也有所提高,可以很好的完成嫩芽的训练分类任务。

(4) 实际数据的验证工作。接着就是对本文改进的模型的验证工作,即利用实际场景拍摄的茶树实景图片进行相应的验证,将茶树实景图片利用多尺度滑窗的方式获取 patch 块,送进训练好的最佳模型中去验证,从而定位嫩芽位置及判断嫩芽所属类别。

(5) 检测出的嫩芽进行质心及角度的获取。由于检测到的嫩芽朝向等信息未知,为了便于后续机械手的介入,本文设计了相关算法对检测到的嫩芽进行相应的图像分割,对比利用了基于 K-means 聚类方法的嫩芽切割和基于高斯混合模型的嫩芽切割两种图像处理方法,为后续的嫩芽的中心点的获取及嫩芽偏转角的计算提供了基础。

6.2 展望

受研究时间与精力均有限的约束，本论文研究的茶叶嫩芽识别分类的模型还有待改进，今后的研究思路可以从以下方面改进：

（1）扩大数据集，做更多类别的识别定位研究。在茶叶的生长阶段中，实际的茶叶种类远比本文研究的类别更多，应该研究更多类别的茶叶类型及不同品质的茶叶类型。

（2）继续改进算法，将嫩芽继续按照品质进行相应的分类，再设计相关的神经网络的学习模型。

（3）由于茶叶实际场景的复杂性，在实际茶叶嫩芽检测中，存在漏检的情况。针对上述情况，本文模型的泛化性还有待提高。

参考文献

- [1] 虞文霞. 新时代茶文化的多向度创新发展思考[J]. 农业考古, 2021(05): 7-11.
- [2] 相雅欣, 李华, 刘旭芳. 我国茶叶出口贸易现状及问题分析[J]. 农村经济与科技, 2021, 32(14): 94-96.
- [3] 刘声传, 林开勤, 梁思慧. 不同化肥减施技术下茶叶产量、品质、养分利用率及经济效益[J]. 热带作物学报, 2021, 42(09): 2601-2609.
- [4] 易文裕, 程方平, 邱云. 单人采茶机研究现状与发展趋势[J]. 中国农机化学报, 2020, 41(11): 33-38.
- [5] 牟顺海, 李少华. 茶叶采摘机器人采摘剪刀设计及仿真[J]. 西南师范大学学报(自然科学版), 2014, 39(06): 55-58.
- [6] 黄留锁, 宋艳. 茶叶茶梗的计算机在线识别技术及其应用[J]. 福建茶叶, 2016, 38(07): 161-162.
- [7] 王文明, 肖宏儒, 宋志禹. 茶叶生产全程机械化技术研究现状与展望[J]. 中国农机化学报, 2020, 41(05): 226-236.
- [8] S. Borah and M. Bhuyan. Quality indexing by machine vision during fermentation in black tea manufacturing[C]. Gatlinburg, TE, United States, 2003.
- [9] Moreda-Pi Eiro A, Fisher A, Hill S J. The classification of tea according to region of origin using pattern recognition techniques and trace metal data[J]. Journal of Food Composition & Analysis, 2003, 16(02): 195-211.
- [10] Neto, JC, Meyer, et al. Plant species identification using Elliptic Fourier leaf shape analysis[J]. Comput Electron Agric, 2006, 50: 121-134.
- [11] Alex Krizhevsky, Ilya Sutskever, Geoffrey E. Hinton. ImageNet classification with deep convolutional neural networks[J]. Communications of the ACM, 2017, 60(06): 1-38.
- [12] Kaiming He, Xiangyu Zhang, Shaoqing Ren, et al. Deep Residual Learning for Image Recognition. [J]. CoRR, 2015, abs/1512. 03385: 1-5.
- [13] Konstantinos P. Ferentinos. Deep learning models for plant disease detection and diagnosis[J]. Computers and Electronics in Agriculture, 2018, 145: 311-318.
- [14] Adel Bakhshipour, Abdolabbas Jafari. Evaluation of support vector machine and artificial neural networks in weed detection using shape features[J]. Computers and Electronics in Agriculture, 2018, 145: 153-160.
- [15] Khan Zohaib, Rahimi-Eichi Vahid, Haefele Stephan, et al. Estimation of vegetation indices for high-throughput phenotyping of wheat using aerial imaging. [J]. Plant methods, 2018, 14(01): 20-20.
- [16] 张蕴. 茶叶嫩芽图像识别方法研究[D]. 安徽农业大学, 2020.
- [17] 杨福增, 杨亮亮, 田艳娜, 等. 基于颜色和形状特征的茶叶嫩芽识别方法[J]. 农业机械

- 学报, 2009, 40(s1): 119-123.
- [18] 刘志杰, 田艳娜, 杨亮亮, 等. 重叠条件下茶叶嫩芽的自动检测方法[J]. 中国体视学与图像分析, 2009, 14(02): 129-132.
- [19] 汪建. 结合颜色和区域生长的茶叶图像分割算法研究[J]. 茶叶科学, 2011, 31(01): 72-77.
- [20] 吴雪梅, 张富贵, 吕敬堂. 基于图像颜色信息的茶叶嫩叶识别方法研究[J]. 茶叶科学, 2013, 33(06): 584-589.
- [21] 邵明. 基于计算机视觉的龙井茶叶嫩芽识别方法研究[D]. 中国计量学院, 2013.
- [22] 王琨, 刘大茂. 基于深度学习的茶叶状态智能识别方法[J]. 重庆理工大学学报(自然科学), 2015, 29(12): 120-126.
- [23] 张可, 吕军. 自然条件下茶叶嫩芽图像分割方法的研究[J]. 黑龙江八一农垦大学学报, 2016, 28(02): 100-104.
- [24] 孙肖肖. 基于深度学习的茶叶嫩芽检测和叶部病害图像识别研究[D]. 山东农业大学, 2019.
- [25] 陈妙婷. 基于计算机视觉的名优茶嫩芽识别与定位[D]. 青岛科技大学, 2019.
- [26] 邵佩迪. 基于机器视觉的茶叶嫩芽识别关键算法研究[D]. 上海工程技术大学, 2020.
- [27] 黄鲁成, 薛爽. 机器学习技术发展现状与国际竞争分析[J]. 现代情报, 2019, 39(10): 165-176.
- [28] 付晓丽. 近十年国内深度学习发展现状与趋势[J]. 唐山师范学院学报, 2020, 42(03): 106-110+128.
- [29] Yuxiang Yang, Zhihao Ni, Mingyu Gao, et al. Collaborative Pushing and Grasping of Tightly Stacked Objects via Deep Reinforcement Learning[J]. IEEE/CAA Journal of Automatica Sinica, 2022, 9(01): 135-145.
- [30] Luca Butera, Alberto Ferrante, Cesare Alippi. Precise Agriculture: Effective Deep Learning Strategies to Detect Pest Insects[J]. IEEE/CAA Journal of Automatica Sinica, 2022, 9(02): 246-258.
- [31] Bo Chen, Penghao Sun, Peng Zhang, et al. Traffic Engineering Based on Deep Reinforcement Learning in Hybrid IP/SR Network[J]. China Communications, 2021, 18(10): 204-213.
- [32] 林景栋, 吴欣怡, 柴毅, 等. 卷积神经网络结构优化综述[J]. 自动化学报, 2020, 46(01): 24-37.
- [33] 江泽涛, 秦嘉奇, 张少钦. 参数池化卷积神经网络图像分类方法[J]. 电子学报, 2020, 48(09): 1729-1734.
- [34] 唐泽民. 基于卷积神经网络的图像识别技术研究[D]. 苏州大学, 2020.
- [35] 刘威, 刘尚, 白润才. 互学习神经网络训练方法研究[J]. 计算机学报, 2017, 40(06): 1291-1308.

- [36] 吕军, 夏华鹏, 方梦瑞, 等. 基于 AlexNet 的茶叶嫩芽状态智能识别研究[J]. 黑龙江八一农垦大学学报, 2019, 31(02): 72-78.
- [37] 罗浩伦, 冯泽霖, 冉钟南. 基于 VGG16 网络的茶叶嫩芽自动检测研究[J]. 农业与技术, 2020, 40(01): 15-17.
- [38] He K, Zhang X, Ren S, et al. Deep Residual Learning for Image Recognition[J]. IEEE, 2016, 28(08): 35-38.
- [39] 谢小红, 李文韬. 深度残差网络综述[J]. 信息与电脑(理论版), 2021, 33(16): 85-87.
- [40] Tenenbaum J B, Freeman W T. Separating Style and Content with Bilinear Models[J]. Neural Computation, 2014, 12(06): 1247-1283.
- [41] 冀中, 赵可心, 张锁平, 等. 基于空间变换双线性网络的细粒度鱼类图像分类[J]. 天津大学学报(自然科学与工程技术版), 2019, 52(05): 475-482.
- [42] Lin T Y, Roychowdhury A, Maji S. Bilinear CNN Models for Fine-grained Visual Recognition[J]. IEEE, 2015, 26(01): 1-9.
- [43] 薛朝辉, 周逸飏, 强永刚, 等. 融合 NetVLAD 和全连接层的三元神经网络交叉视角场景图像定位[J]. 遥感学报, 2021, 25(05): 1095-1107.
- [44] 张静, 宋锐, 郁文贤, 等. 基于混淆矩阵和 Fisher 准则构造层次化分类器[J]. 软件学报, 2005(09): 1560-1567.
- [45] 郭黎利, 岳瑾, 孙志国, 等. 基于小波多尺度检测特性的扩频序列捕获研究[J]. 信息技术, 2005(07): 1-4.
- [46] 欧阳毅, 张三元, 张引. 基于窗口边缘梯度势能的人体遮挡多尺度检测算法[J]. 电子与信息学报, 2012, 34(04): 858-864.
- [47] 周智. 基于高色差分离预处理的 K-means 茶叶嫩芽识别研究[J]. 广东蚕业, 2020, 54(11): 74-75.
- [48] 安晓飞, 王培, 罗长海. 基于 K-means 聚类 and 分区寻优的秸秆覆盖率计算方法[J]. 农业机械学报, 2021, 52(10): 84-89.
- [49] 向日华, 王润生. 一种基于高斯混合模型的距离图像分割算法[J]. 软件学报, 2003(07): 1250-1257.
- [50] 毛腾跃, 张雯娟, 帖军. 基于显著性检测和 Grabcut 算法的茶叶嫩芽图像分割[J]. 中南民族大学学报(自然科学版), 2021, 40(01): 80-88.
- [51] 张力, 肖薇薇, 张基宏. 基于原始图像矩的仿射不变性水印算法[J]. 深圳大学学报(理工版), 2003(02): 16-21.
- [52] 舒华忠. 矩和矩不变量在图像处理和模式识别中的应用综述[J]. 四川师范大学学报(自然科学版), 2021, 44(05): 576-585+566.

攻读硕士学位期间参与科研项目情况

攻读研究生期间参与的科研项目情况：

参与，辽宁省自然科学基金，基于颜色和深度信息融合的特征匹配目标定位方法研究，2019-ZD-0031，2019.5-2021.5；

致 谢

庚子立题，辛丑落笔。随着这篇致谢之词的开始，意味着我在辽宁科技大学的学习生涯即将画下句点。时间是让人猝不及防的东西，晴时有风，阴时有雨。此刻的电信楼在初雪的映衬下，显得更加浪漫与端庄。我的脑海中也浮现出了和小伙伴们从二舍小跑来电信楼上课的场景。心中虽然万般不舍，但相遇终有离别之时。在这里祝福科大蒸蒸日上，科大的学子永创辉煌。

一朝沐杏雨，一生念恩师。感恩我的导师林春丽教授，感谢缘分让我们在科大相遇，感谢林老师在日常生活中的体贴慰问，让身处异乡的我感受到了温暖。感谢指导我论文写作的魏东教授，魏老师平易近人，在科大的日子，感谢您对我一路的学术指导，谆谆教诲。感谢魏东老师在我困惑的时候，为我指明前进的方向，让我在迷失的时候看见光的方向。

同窗数载，知己难寻。感谢我最可爱的室友王燕梅、顾振敏、雷倩、王文凤，感谢你们三年相伴，那些一起哭过、笑过的日子我永远也不会忘记。愿我们今后的岁月继续努力，不负彼此，不负自己。

感谢九号楼 539 课题室的小伙伴们，感谢袁志伟、于丰溢、崔雨欣、宋强、史怡、陈子一，感谢你们在我心情失落的时候，逗我开心。在你们身上，我学到了许多东西。相信有一种感情永远不会输给时间，希望你们得偿所愿，一直被幸运之神所眷顾。

父母之爱子，则为其计深远。我要特别感谢我的家人这么多年对我学习和生活上的帮助。因为你们，我才可以这么无忧无虑的学习与生活；因为你们，我才可以实现我自己的梦想。成为你们的孩子是我这辈子最幸福的事情。

最后，感谢储明旭同学，感谢你虽肩负压力，但依旧会给我最灿烂的笑容与最温暖的拥抱。三年之约即将到临，希望再次相遇之时，我们是更好的我们。

作者简介

姓名：曹林君


性别：女

出生年月：1996 年 9 月 26 日

民族：汉族

籍贯：汉

研究方向：数字图像处理



简历：2015.09-2019.06	南京邮电大学通达学院	自动化
2019.09-2022.03	辽宁科技大学	控制工程