



南京农业大学

本科生毕业论文（设计）

题目：基于图像处理的油菜叶片表型参数测量方法研究

姓名：杨晟伟

学号：19218211

学院：人工智能学院

专业：计算机科学与技术

指导教师：朱淑鑫 职称：副教授

2022 年 5 月 22 日

南京农业大学本科生毕业论文（设计）原创性声明

本人郑重声明：所提交的毕业论文（设计），是本人在导师的指导下，独立进行研究工作所取得的成果。除文中已经注明引用的内容外，本论文不包含任何其他个人或集体已经发表或撰写过的作品成果。对本文的研究做出重要贡献的个人和集体，均已在文中以明确方式标明。本人完全意识到本声明的法律结果由本人承担。

论文作者签名：杨淑伟

日期：2022 年 5 月 31 日

南京农业大学本科生毕业论文（设计）使用授权声明

本学位论文作者完全了解学校有关保留、使用毕业论文（设计）的规定，同意学校保留并向国家有关部门或机构送交论文的复印件和电子版，允许论文被查阅和借阅。本人授权南京农业大学教务处可以将本毕业论文（设计）的全部或部分内容编入有关数据库进行检索，可以采用影印、缩印或扫描等复制手段保存和汇编毕业论文（设计）。

论文作者签名：杨淑伟

日期：2022 年 5 月 31 日

导师签名：朱淑霞

日期：2022 年 5 月 31 日

目 录

目 录	I
摘 要	I
ABSTRACT	II
第 1 章 绪论	1
1 研究背景和意义	1
2 国内外研究进展	2
2.1 基于图像处理技术的作物表型测定	2
2.2 基于深度学习技术的作物表型测定	2
3 研究内容与技术路线	3
3.1 研究目标	3
3.2 主要内容	4
3.3 技术路线	5
第 2 章 相关理论基础	6
1 目标检测相关理论	6
1.1 目标检测概述	6
1.2 目标检测数据集	6
1.3 目标检测常用指标	7
2 YOLO 目标检测模型	7
2.1 Yolo 模型概述	7
2.2 Yolox 模型	8
3 图像分割算法	10
3.1 阈值分割	10
3.2 边缘检测分割	10
3.3 聚类分割	10
4 ResNet 和 EfficientNetV2 模型结构	10
4.1 ResNet 模型	10
4.2 EfficientNetV2	11
5 ONNX	12
第 3 章 油菜叶长宽和裂叶参数提取	14
1 数据集制作	15
1.1 数据集获取	15

1.2 图像标注-----	16
1.3 数据增强-----	17
1.4 数据集的划分-----	18
1.5 数据集存放格式-----	18
2 模型的训练与测试-----	19
2.1 环境准备与配置-----	19
2.2 模型的训练-----	2019
2.3 NMS 后处理-----	23
3 图像校正-----	24
3.1 油菜叶分割-----	24
3.2 基于矩的主轴方向计算-----	26
3.3 像素长宽测量-----	27
4 真实长宽提取-----	28
4.1 单目测距-----	28
4.2 焦距标定-----	28
4.3 长宽转换和误差分析-----	29
第 4 章 油菜卷叶识别-----	32
1 基于卷积神经网络的分类方法-----	32
1.1 数据集制作-----	32
1.2 数据增强-----	33
1.3 模型训练与测试-----	33
2 基于自监督的学习方法-----	35
2.1 数据处理-----	36
2.2 旋转自监督-----	37
2.3 模型的标准训练与测试-----	39
第 5 章 叶缘缺刻程度识别-----	42
1 叶缘特征提取-----	42
2 SVM 支持向量机-----	43
2.1 数据获取-----	43
2.2 SVM 训练与测试-----	44
第 6 章 模型的部署与系统开发-----	45
1 ONNX 模型部署-----	45
2 前后端实现-----	46

2.1 前端实现-----	46
2.2 Flask 后端-----	46
第 7 章 总结与展望-----	51
1 总结 -----	51
2 展望 -----	51
参考文献 -----	53
致谢-----	58

图目录

图 1-1 技术路线图.....	5
图 2-1 PASCAL VOC 和 COCO 数据集存放格式.....	6
图 2-2 YoloV3 SPP 结构图.....	8
图 2-3 Yolox 结构图	89
图 2-4 Decoupled Head 结构图	9
图 2-5 残差块结构图.....	11
图 2-6 MBConv 和 Fused-MBConv 结构	12
图 2-7 ONNX 所定义的数据结构	13
图 3-1 长宽参数提取标准.....	14
图 3-2 裂叶标准以及计数方式.....	14
图 3-3 拍摄方法.....	16
图 3-4 部分油菜图像.....	16
图 3-5 标注结果.....	17
图 3-6 XML 中的标签信息.....	17
图 3-7 增强后的图像.....	18
图 3-8 学习率变化曲线图.....	20
图 3-9 训练集上各项损失变化曲线.....	21
图 3-10 测试集上的 AP 指标.....	22
图 3-11 四种类别的 P-R 曲线.....	22
图 3-12 NMS 处理后的预测结果	23
图 3-13 Class-agnostic nms 处理结果.....	23
图 3-14 Class-aware nms 处理结果.....	24
图 3-15 不同分割算法的比较结果.....	25
图 3-16 主轴示意图.....	27
图 3-17 原始轮廓与校正轮廓.....	27
图 3-18 针孔成像模型示意图.....	28
图 3-19 用于标定的图像和标注出长度的图像.....	29
图 3-20 原始油菜图像及其预测图.....	30
图 4-1 卷叶分类标准.....	32
图 4-2 卷叶分类数据集部分图像.....	33
图 4-3 部分增强后的图像.....	33
图 4-4 EfficientNetV2 训练集和验证集准确率变化表	34
图 4-5 EfficientNetV2 训练集和验证集损失变化表	34

图 4-6 新拍摄的油菜叶图像.....	35
图 4-7 裁剪处理得到的数据集.....	36
图 4-8 Cifar10 预处理方法（右）与新的预处理方法（中）结果比对图.....	37
图 4-9 旋转自监督流程图.....	38
图 4-10 旋转自监督准确率变化表.....	38
图 4-11 旋转自监督损失变化表.....	39
图 4-12 ResNet32 准确率变化曲线.....	40
图 4-13 ResNet32 损失变化曲线.....	40
图 4-14 用于预测的图像.....	41
图 5-1 叶缘缺刻程度评估标准.....	42
图 5-2 特征点 1.....	43
图 5-3 特征点 2.....	43
图 5-4 部分叶缘缺刻程度为中等的油菜图像.....	44
图 5-5 记录的部分特征值.....	44
图 6-1 前端界面.....	46
图 6-2 展示上传的图像以及服务器返回的图像.....	47
图 6-3 放大标注长度的图像.....	48
图 6-4 上传图像后前端展示效果.....	49
图 6-5 导出至 Excel 的数据.....	49
图 6-6 预测结果图.....	50

表目录

表 3-1 拍摄时间等信息表.....	15
表 3-2 VOC 数据集格式	19
表 3-3 硬件配置.....	19
表 3-4 软件配置.....	19
表 3-5 训练参数表.....	20
表 3-6 四种类别分别在 IoU 为 0.5 和 0.75 下的 AP 值和 mAP 值	22
表 3-7 不同算法的分割误差.....	25
表 3-8 不同方法测得的像素长宽.....	28
表 3-9 真实长宽表.....	29
表 3-10 计算误差表.....	31
表 4-1 训练参数配置表.....	34
表 4-2 使用不同训练配置得到的准确率表.....	39
表 4-3 两种方法的比较结果.....	41
表 5-1 不同核系数下准确率变化表.....	44
表 6-1 导出 ONNX 模型的配置参数表	45
表 6-2 导出 ResNet32 模型的配置参数表.....	45
表 6-3 使用 ONNX 与不使用 ONNX 的推理速度的对比	45
表 6-4 /correct 提交参数格式.....	47
表 6-5 /correct 服务器响应格式.....	47
表 6-6 /param 提交的参数格式.....	48
表 6-7 /param 服务器响应格式.....	48
表 6-8 /ret_img 提交的参数格式	49
表 6-9 /ret_img 服务器响应格式	49

基于图像处理的油菜叶片表型参数测量方法研究

摘 要

近年来，计算机视觉技术在植物表型参数自动化测量上得到了广泛应用，本文使用图像处理等方法对油菜叶表型参数的自动测量进行了研究。

在叶长宽、叶片长宽、叶柄长、裂叶数量的提取上，使用 YOLOX 目标检测网络来提取油菜叶的各个部位，经旋转校正各个部位后再获取对应长宽，并使用单目测距的方法将像素单位长宽转化为厘米长宽。实验结果表明，校正后计算得到的部位平均误差在 10% 左右。

在卷叶识别上，针对数据集样本少且数据分布不平衡的问题，使用旋转自监督的方法训练 ResNet32 模型，然后使用相同的配置进行标准训练。经过测试，使用该方法得到的 ResNet32 网络在具有良好的准确率和泛化性能。

在叶缘缺刻程度识别上，使用多边形拟合叶缘的轮廓，求出相邻顶点与水平轴的弧度值，将中间 10 个弧度值作为特征向量，使用内核为 rbf 的 SVM 分类器进行分类。最后训练集和测试集达到的精度分别为 94.44%，85.71%。

在系统开发上，将 YOLOX 模型和 ResNet32 模型转化为 ONNX 格式，使用 Flask 后端和 bootstrap 前端开发 WEB 系统，以实现油菜叶表型参数的自动化测量。

关键词：目标检测；油菜叶；表型参数；自监督学习；模型部署

STUDY ON MEASUREMENT METHOD OF PHENOTYPIC PARAMETERS OF RAPE LEAVES BASED ON IMAGE PROCESSING

ABSTRACT

In recent years, computer vision technology has been widely used in the automatic measurement of plant phenotypic parameters. This paper studies the automatic measurement of rape leaf surface parameters by using image processing and other methods.

In the extraction of leaf length and width, blade length and width, petiole length and the number of split leaves, YOLOX object detection network is used to extract each part of rape leaves. After rotating and correcting each part, the corresponding length and width are obtained, and the pixel unit length and width is transformed into centimeter length and width by monocular ranging method. The experiment shows that the average error of the calculated part after correction is about 10%.

In the aspect of rolled leaf recognition, aiming at the problem of few data sets and unbalanced data distribution, the ResNet32 model is trained by using the rotation self-supervised method, and then the standard training is carried out with the same configuration. After testing, the ResNet32 network obtained by using this method has good accuracy and generalization performance.

In the recognition of leaf margin notch, polygon is used to fit the contour of leaf edge, the radian values of adjacent vertices and horizontal axis are obtained, the middle 10 radian values are used as feature vectors, and SVM classifier with rbf kernel is used for classification. Finally, the accuracy of training set and test set is 94.44% and 85.71%.

In the system development, YOLOX model and ResNet32 model are transformed into ONNX format, and the WEB system is developed by using flash back-end and bootstrap front-end to realize the automatic measurement of rape leaves.

KEY WORDS: Object detection; Rape leaves; Phenotypic parameters; Self supervised learning; Model deployment

第1章 绪论

1 研究背景和意义

油菜作为食用植物油和植物蛋白的主要来源，在农产品中有十分重要的地位^[1]。油菜作为我国重要的油料作物之一，除了兼具油、菜、花、蜜、茶、肥、饲等多维度利用价值，而且对缓解当前国内日益紧张的食用油供给矛盾具有重要的作用。数据表明，油菜占国产食用植物油总量的 50%以上，然而我国食用油自给率不足 35%^[2]。因此，油菜对发展绿色优质高效油菜产业，保障我国食用油安全需要至关重要，提高油菜产量和扩大种植面积具有十分重要的意义。江苏省是我国“双低”油菜重点种植区域之一，面积和单产均居全国前列，但近年来受水稻收获期不断推迟、生产成本以及种植规模等因素影响，种植面积下滑趋势明显^[3]。

为了提高油菜的种植面积以及竞争力，一种有效的方法是通过研究不同油菜的表型参数，将表型与相应的品种基因相互关联分析，以进一步筛选出优良的油菜基因，在减少种植油菜成本的同时，提高生产效益^[4]。而叶片是植物进行光合作用和蒸腾作用的主要器官，叶片的面积对作物的生长发育、抗逆性及产量具有十分大的影响，是遗传育种、作物栽培等方面研究经常考虑的内容^[4]。因此，获取包括植物叶片面积在内的一系列叶片表型数据对筛选并获取高效益油菜具有重要作用^{[5][6]}。

作物表型可以被定义为某个基因型作物在特定生长环境下所表现出来的一系列与其物候、结构、生理生化及与生产性能相关的性质，是基因型、环境因子及两者间复杂相互作用的结果^[7]。根据中华人民共和国甘蓝型油菜的《植物品种特异性、一致性和稳定性测试指南》，油菜表型包括叶长宽、叶片长宽、叶柄长度、生长习性、叶片颜色、裂片及其数量、叶柄长度、卷曲程度等性状，而对于油菜角果而言，又有果喙、果柄、果身等性状。

传统的作物表型测量方法主要有目测法和手工测量法。对于油菜叶的表型测量而言，目测法主要用于获取叶片的颜色、裂片及其数量、卷曲程度等。目测法依赖于测量人员的经验，估值过程具有较强的主观性^{[8][9]}。手动测量通常用于测量叶片长度、宽度、叶柄长度以及角果的三段长度等。

目前有关作物表型参数的自动测量虽然取得了较为丰硕的研究成果，但针对油菜表型参数的自动测量研究，仍然存在诸多待解决的问题，油菜表型的测量大都依靠人工完成，人工测量不仅精确度低而且费时费力，并且手动测量容易受量尺、外界环境的影响，测量的精确度很大程度上受限于操作人员的主观因素，更重要的是，研究人员需要在油菜生长过程中的各个环节上测量油菜的表型进行监控，大大增加了人力成本。因此，传统的表型测定方法具有低效、昂贵、人力成本高等特点^[9]。

近年来，随着计算机技术的快速发展，图像采集和处理的速度和技术都得到了极大

设置了格式：上标

的提升，计算机视觉技术开始应用于各个领域。基于此，本研究将使用图像处理技术、机器学习和深度学习等方法来获取油菜叶片的表型参数，为筛选和培育良好的油菜种型提供理论依据。

2 国内外研究进展

2.1 基于图像处理技术的作物表型测定

近年来，由于大量图像处理算法的提出和图像计算软件的开发，图像处理技术也渐渐地被应用于农业领域。尤其是 opencv 开源库的提出，使得开发者可以快速构建计算机视觉应用，许多基于图像处理技术的作物表型测定方法被应用到农业领域。

Chen^[10]等人对植物叶片图像进行分割标记、提取轮廓，得到了植物叶片的一系列参数，然后根据参考物体的真实值计算得到两个标定因子，根据因子和图像处理方法获得的参数可以得到其他植物叶片的真实表型参数。Liu^[11]等对植物叶片预处理后使用畸变校正消除图像的畸变，并提出了一种用叶片正外切矩形来计算叶片参数的方法，结果表明，该方法在 android 平台上能够有效计算叶片的表型参数。Mora M^[12]等在估算 LAI (leaf area index 叶面积指数) 时，使用了一种改进的基于特定图像进行分割的覆盖摄像方法，来尽可能排除图像中非叶子目标带来的影响。李锦卫^[13]等将含有叶片的图像进行预处理后，使用超绿变换获取与叶片有关的黑白图像，通过对像素点的计数得出有效像素总和，最后通过系数校正获取叶片面积。王静^[14]等人利用数学形态学和像素跟踪相结合的算法实现叶片与叶柄的分离，然后利用霍特林变换计算树叶最小外接矩形及其长宽比，为树叶的分类和识别奠定基础。徐义鑫^[15]使用了旋转法和矩方法来求最小面积外接矩形。王键^[16]在计算面积前先对图像通过透视变换进行几何校正，然后对图像分割分别获取矩形区域和叶片区域，并提取矩形和叶片的轮廓计算所占像素，再根据已知的矩形实际面积算出叶片的真实面积。李瑞洋^[17]使用近似拟合的方式求取叶片的长宽，使用到的方法有基于分段直线的叶片中轴线拟合及基于最小外接矩形的叶片中轴线拟合。

当现有的图像处理技术难以对某些表型参数进行提取时，深度学习技术得到了越来越多的关注。深度学习技术可以组合低层特征形成更加抽象的高层特征，具有强大的特征学习和特征表达能力。其代表——卷积神经网络能够为图像分类、识别等问题提供较为通用的方法，对图像拍摄环境的改变和作物品种差异等都具有较高的鲁棒性^[18]。

2.2 基于深度学习技术的作物表型测定

近几年来，深度学习技术发展迅速，在图像分类、语义分割、目标检测等任务上均有广泛的应用。

图像语义是在图像中为每个像素分配一个预先定义的表示其语义知识的类别标签。当每个像素有了计算机能识别的标签，就能应用于目标识别乃至场景理解等应用场景。当前，越来越多的应用场景需要利用图像中的语义知识，包括自动驾驶中的场景识别与理解、无人机控制与应用、医学影像辅助分析、图像搜索、增强现实等^[18]。2015 年提出的 FCN 语义分割网络的在图像的语义分割上具有非常好的效果^[19]，此后越来越多的语义

分割网络被发明出来，如 Segnet^[20]、U-Net^[21]、PSPNet^[22]等。

深度学习的图像语义分割以广泛应用于植物病害识别以及植物叶片识别。Slik J^[23] 提出了一种由 DeepLabv3、连接成分分析和基于二值图像的单叶分类器组成的管道，该方法与基于对象检测的方法相比有更高的 F1 分数，提取到的叶片表型参数更加接近真实值。Kolhar S^[24]等改进了 U-Net 网络并提出残差 U-Net 用于从背景中对植物进行语义分割，结果表明，残差的 U-Net 网络与 SegNet 和其他最先进的方法。刘健^[25]使用 MobileNetV3 Large 作为特征提取器，最终优化后的模型在葡萄病害叶片数据集上的病害识别准确率达到 99.1%。王鹤树^[26]等提出基于全卷积神经网络的深度学习方法进行植物图像的叶片分割，他以 U-net 分割网络为基础，对模型结构、激活函数和损失函数进行优化调整，设计出新的全卷积网络模型，实现了莲座植物图像的分割。娄路^[19]等提出了一种基于时间序列图像和深度卷积神经网络 Mask-RCNN 的植物茎叶实例分割方法，模型对在不同生长时期的植物茎叶的识别精度(mAP)达 70.0%以上。

郭晓丽^[27]使用改进的 U-Net 网络在花朵型和叶片型植物数据集上取得十分不错的分割效果，此后出现的 deeplab v3^[29]网络以 ResNet 为主干网络，语义分割的精度和准确率进一步增加，在没有添加任何后端处理的情况下达到了 89% mIoU。

目标检测是计算机视觉领域最基本和重要的任务之一，其内涵是从图像中定位感兴趣的目标，准确地判断出每个目标的具体类别，并给出每个目标的边界框^[30]。在作物表型测定上，目标检测技术一般用于计数，例如叶片数量的计数，自动化的计数可以大大降低人力成本。

陶莎^[31]使用改进锚框尺寸的 Faster R-CNN 实现了角果检测，然后针对拟南芥角果的特点，使用旋转框算法对网络进行改进，计算的叶长和叶宽与人工测量的相关系数均超过 0.96，能够满足准确、快速提取的要求。Hasan^[32]利用卷积神经网络对大田小麦麦穗进行计数，并且达到了 94%的检测精度。高云鹏^[33]针对大田麦穗计数效率低的问题，使用 YOLOv3 网络对不同尺度的麦穗图像数据集进行了分析，并使用 Mask R-CNN 实现了小麦麦穗的自动化检测，实验表明，YOLOv3 检测速度更快，而 Mask R-CNN 准确率更高。Tu Y L^[34]等使用 YOLOv3 网络对图像中的叶子进行检测和定位，根据预测框的数量对叶子进行计数，在 ABRC 和 CVPPP 数据集上的拟南芥图像测试，准确率达到 SOTA。Vishal M K^[35]等基于 YOLO 目标检测模型，通过计算与叶片数相等的叶尖数计算叶片总数，该方法在水稻植株叶片计数上达到的准确率高达 82%，并且在小麦上也表现良好。可见，目标检测技术在作物表现测定上也开始有相关的应用。

3 研究内容与技术路线

3.1 研究目标

本文以油菜叶为研究对象，使用不同的方法获取油菜叶的不同表型参数。将采集拍摄得到的大量油菜叶图像构建数据集并进行标注。一，使利用目标检测深度学习的方法，运用图像处理和分割等算法来获取的对油菜叶的参数有叶长宽、叶片长宽、叶柄长、裂叶

批注 [z1]: 图像分割包含在图像处理里

数量等参数进行获取。使用深度学习和机器学习的方法提取卷叶和叶缘缺刻程度参数。
最后，开发了此外，对 Web 系统的应用软件开发进行了研究？？？系统。

批注 [z2]: 这里想下叫什么系统，或者换个具体些的说法

3.2 主要内容

本文结构如下：

第一章，简要介绍了油菜在我国的重要影响和地位，阐明了油菜表型参数的自动化提取能够大大减少人力成本，对油菜基因的选取和育种都有十分重要的作用。分析了国内外学者在表型参数自动化提取方面所做的研究，进而引出本文的研究思路和方法。

第二章，简要介绍了有关本文的基础理论，包括目标检测相关理论、Yolo 系列模型、常用的图像分割算法、EfficientNet 和 ResNet 网络模型结构以及最后与模型部署相关的模型格式 ONNX。

第三章，对叶长宽、叶片长宽、叶柄长、裂叶数量进行了测量，仿照 PASCAL VOC 格式制作数据集并划分数据集，对数据集进行数据扩增。训练 Yolox 模型并使用该模型提取出油菜叶的各个部位。使用 k-means 方法对提取到的各个部位进行分割，求出图像的主轴并校正以求出其像素长宽。最后使用单目测距的方法获取真实值。

第四章，提取卷叶参数，使用卷积神经网络进行训练识别。首先使用 EfficientNetV2 网络在数据扩充后的数据集上进行训练，得到的效果不佳。为了缓解原有数据集的分布不平衡的问题，使用旋转自监督的学习方法对 ResNet32 网络进行预训练，并在预训练后网络的基础上进行相同配置的标准训练，最终实现了一个精度较高的卷叶分类器。


第五章，对叶缘缺刻程度进行测量。对叶缘轮廓进行多边形拟合，得到多个顶点。计算相邻顶点连线与水平轴的夹角，从中间提取 10 个弧度值作为特征向量。使用内核为 rbf 的 SVM 分类器进行训练，最终得到一个分类精度较高的叶缘缺刻程度分类器。

第六章，搭建 Web 网站供研究人员操作。使用 Flask 框架作为后端，使用 bootstrap 框架作为前端，使用 Ajax 发送和接收数据，对其中的一些关键技术进行了阐述？？？。

批注 [z3]: 这里要不要换个具体的名字？

第七章，对本文所做工作进行了总结，概括分析指出本研究的创新点，并对后期研究本工作中需要改进的地方进行作出了阐述和展望。

3.3 技术路线



批注 [z4]: 这行下面，加两句过渡的话，要不这个图挂着有点孤单。
图里可以把数据集这部分工作叶写进去。
最右边那个框，最下面长宽字体跟其它不一样。

图 1-1 技术路线图
Figure 1-1 Technology roadmap

第2章 相关理论基础

1 目标检测相关理论

1.1 目标检测概述

目标检测的基本任务是判别一幅图像中感兴趣的物体并作出分类，并使用矩形边界框来确定目标所在的位置以及大小，同时给出相对应的置信度。由于各类物体有不同的外观、形态、姿态，并且由于拍摄时光照和遮挡等因素的干扰，目标检测一直是计算机视觉领域最具有挑战的问题^[36]。

目前，主流的目标检测模型算法有两类：Two stage（双阶段）目标检测算法和 One stage（单阶段）目标检测算法。双阶段目标检测算法一般先使用区域建议网络（RPN）生成众多的候选框，然后对候选框参数进行回归修正得到真实矩形框。代表性网络有 R-CNN^[37]、Faster-RCNN^[38]、SPP-Net^[39]。而单阶段目标检测算法主要没有区域建议阶段，也就是没有 RPN 模块，通过训练可以直接得出目标类别以及矩形框。代表性网络有 Yolo、SSD^[40]。

1.2 目标检测数据集

目标检测领域的数据集有 PASCAL VOC^[41]、ImageNet^[42]、MS-COCO^[43]等。下面主要介绍 PASCAL VOC 数据集。

PASCAL VOC 于 2005 年发布，并截止 2012 年每年更新一次。目前广泛使用的 PASCAL VOC 数据集是 2007 年和 2012 年版本的数据集，这两个数据集中所包含的类别一共有 20 种，并且在数据集内有 XML 文件，用来表明每张图像中目标的类别和位置。一般情况下，如果要训练自己的目标检测数据集，常常需要把自己的数据集格式制作成类似 PASCAL VOC 数据集或者 MS-COCO 数据集的格式。PASCAL VOC2007 格式和 MS-COCO2014 数据集格式如图 2-1 图 2-1 所示。




图 2-1 PASCAL VOC 和 COCO 数据集存放格式

Figure 2-1 Pascal VOC and coco data set storage format

1.3 目标检测常用指标

(1) AP/mAP

在目标检测中，AP 值等于 P-R 曲线和坐标轴围起来的面积，P-R 曲线由精确率（Precision）和召回率（Recall）组成，mAP 是所有类别 AP 的平均值。精确率是相对于预测结果而言，预测为正的样本中正确的数量，而召回率表示样本中的正例被正确预测的个数。精确率和召回率的计算通常需要先计算 TP（模型预测为正例的正样本）、TN（模型预测为反例的负样本）、FP（模型预测为正例的负样本）、FN（模型预测为负类的正样本）。精确率(precision)和召回率(recall)计算公式如下所示：

$$precision = \frac{TP}{TP+FP} \quad (2-1)$$

$$recall = \frac{TP}{TP+FN} \quad (2-2)$$

(2) IOU

交并比 (intersection over union, IoU) 是指预测的边界框和原图像标注的真实边界框的重叠率, 交并比的值是两者交集与并集的比值. 当比值为 1 的时候则说明预测的效果达到最佳。常用的 AP50 和 AP75 就是指 IoU=0.5 以及 IoU=0.75 的情况下计算所得的 AP 值。

2 Yolo 目标检测模型

2.1 Yolo 模型概述

Yolo^[44]模型是 2015 年，由 Redmon 提出的单阶段目标检测算法。该算法的思想是将一副图像划分成 $S \times S$ 个网络单元，如果某个物体的中心落在一个网格内，则这个网格就负责预测这个物体，并给出置信度和矩形框参数，在预测的后处理阶段，使用置信度阈值筛选和 NMS 的方法去除冗余框。初代 Yolo 模型虽然速度非常快，但存在着无法识别小目标以及聚集目标的问题。

Yolo v2^[45]模型是 Redmon 于 2017 年提出的改进的 Yolo 模型。Yolo v2 模型引入了 Faster R-CNN 中使用的 Anchor，作者在训练集上使用 k-means 聚类的方法找到了 5 个常见的目标形状。在坐标预测上，虽然引入了 Anchor，但是并没有使用坐标的偏移量得到矩形框坐标，而是使用 Anchor 中心点相对于单元格左上角位置的偏移进行预测。由于 Yolo v2 可以识别 9000 种不同的物体，因此也被成为 Yolo9000。

Yolo v3^[46]模型使用了 Darknet-53 作为特征提取网络，并且在类别预测上，将 v2 中的 softmax 替换成了二值交叉熵损失函数，最重要的一点是，Yolo v3 引入了 FPN 来实现多尺度的预测。一系列的改进使得 Yolo v3 在今天所发挥的性能依然优于其他大部分目标检测模型。

Yolo v4^[47]使用了 CSPDarknet53 作为 backbone，并且引入了 SPP 模块来增大感受野，引入了注意力机制，使用 Mish 激活函数，最重要的是，作者使用 Mosaic 来做数据增强。可以说，Yolo v4 整合了当时众多的创意点，也让 Yolo v4 成为一个及其高效强大的目标检测模型。

2.2 YoloX 模型

YoloX^[48]模型是旷视科技于 2021 年 7 月发布的最新的 Yolo 系列目标检测器，YoloX 模型相比较先前的 Yolo 系列模型，有较大的改进，YoloX 的作者将 YoloV3 SPP 作为基准模型，并在此基础上进行了一系列改进。YoloV3 SPP 的结构如图 2-2 图 2-2 所示。




图 2-2 YoloV3 SPP 结构图

Figure 2-2 Structure diagram of YoloV3 SPP

SPP 全称是 Spatial Pyramid Pooling，即空间金字塔池化结构，该结构有四个并行分支，分别是内核大小为 5、9、13 的最大池化层以及一个捷径分支，该结构的设计思想来源于特征金字塔结构，特征图在经过局部特征与全局特征的融合后，能够更好地检测不同尺度的目标。作者在此基础上进行了一系列修改，最终得到了 YoloX 模型，其结构如图 2-3 图 2-3 所示。




图 2-3 YoloX 结构图

Figure 2-3 Structure diagram of YoloX

具体来说，Yolox 有以下改进点：

（1）数据增强

在 Yolov4 中，作者采用了 Mosaic 数据增强方式，主要是为了解决小目标的检测问题。该方式随机使用 4 张图像，随机缩放、随机分布、随机拼接，提升网络的鲁棒性。

在 Yolox 网络的输入端，作者使用了 MixUp^[49]数据增强,该方法是将不同类之间的图像进行融合，主要是利用一定的比例对 RGB 值进行混合，从而扩充训练数据集。

在使用 Mosaic 和 MixUp 进行数据增强时，作者还提出需要在训练结束前的 15 个 epoch 关闭数据增强，因为过量的 Mosaic 和 MixUp 增强生成的图像会脱离图像的真实分布，并且会带来许多不正确的标注框。

（2）Decoupled Head 解耦头

在 One stage 目标检测算法中（如 RetinaNet）都有 Decoupled Head 的应用，而在 Yolox 中，作者增加了三个 Decoupled Head，测试发现不单精度提高了，而且收敛速度也加快了，因此得出结论：此前 Yolo 系列的检测头表达能力没有 Decoupled Head 好。Coupled Head 和 Decoupled Head 结构如图 2-4 图 2-4 所示。




图 2-4 Decoupled Head 结构图

Figure 2-4 Structure diagram of Decoupled Head

（3）Anchor free

之前提及的 Yolo 系列都是 Anchor Based，该方式主要依靠人为设定一些 Anchor 大小，将预测框和标注框进行关联，然后计算损失并更新网络参数。Anchor Free 不需要先验的 Anchor 大小，其输出是一组特征向量。Anchor Free 计算量更小，代码可读性更高，使用

起来更方便。

(4) SimOTA

对候选框进行初步筛选得到正样本后，需要进行精细化筛选，在精细化筛选中，常用的是 OTA 方法，OTA^[50]是一种目标检测样本匹配策略，检测精度高，使用场景广。SimOTA 去掉了 OTA 中 Sinkhorn-Iter 的求解过程，运算速度更快，并且最后的精度在绝大多数数据集的测试下几乎没有影响。

Yolox 模型融合了当时诸多的创新点，使其一跃成为当年的 SOTA 模型。

3 图像分割算法

图像分割在图像识别中起至关重要的作用，合理的分割方法可以大大缩短图像识别的时间，有效提高后续任务的计算效率^{[51][52]}。常用的图像分割算法原理有三类：基于阈值的分割；基于边缘检测的分割；聚类分割。

3.1 阈值分割

阈值分割的基本原理是通过设定不同的灰度阈值，把图像中的像素点分为若干类，一般分为两类——目标与背景，进而得到黑白二值图。阈值分割常用于目标物体与背景差异较大的图像^[53]。分割中所设定的阈值一般根据人的主观经验进行设定，而在 1979 年提出的 Otsu 算法^[54]可以自适应地选择阈值。阈值分割的优点是计算简单、处理速度快，缺点是对噪声敏感，难以适应复杂场景。

3.2 边缘检测分割

基于边缘检测的图像分割算法依据区域边缘出现的灰度值间断性来检测图像中的边缘特征，从而实现图像分割^[55]。为此，算法需要检测灰度值变化较大的边界点，常用的边缘检测算子主要有：Canny 算子、Sobel 算子、Roberts 算子^[56]。该方法在使用过程中简单快捷，也存在噪声敏感等缺点。

3.3 聚类分割

聚类分析是一种无监督的学习方法，其主要目标是是根据一定的规则将数据对象分为多个类别，同一类别内的数据对象差异尽可能小，而不同类别内数据对象差异尽可能大^[57]。常见算法有 K-means 聚类、Mean-shift 聚类等。

4 ResNet 和 EfficientNetV2 模型结构

4.1 ResNet 模型

ResNet 模型^[64]是 2016 年提出的，作者发现，随着网络层数的增加，会出现梯度消失或者爆炸的问题，即使通过正则化使网络能够收敛，但是正确率会出现饱和甚至下降，称之为网络的退化问题。网络退化的根本原因是优化问题，因此提出了残差块，残差块结构如图 2-5 图 2-5 所示。




图 2-5 残差块结构图

Figure 2-5 Residual block structure diagram

残差块可以理解为在前向传播过程中增加了一个捷径连接，快捷连接不仅不会增加模型的参数和复杂度，而且易于实现。由残差块搭建的 ResNet152 网络获得 ILSVRC2015 竞赛的第一名。

4.2 EfficientNetV2

在 EfficientNet^[65]中，作者使用 NAS(Neural Architecture Search)技术来搜索网络的输入图像分辨率、网络的深度、宽度这三个参数的合理化配置。基于此，作者得出了两个结论：①放大网络宽度、深度或分辨率都可以提高模型精度，但模型越大，精度增益越小。②缩放网络的同时，需要同时调整深度和分辨率。为了证明上述方法的有效性，作者提出了新的模型——EfficientNet 模型，在模型中引入了 MBConv 卷积，并使用 Swish 激活函数和 SE 模块，最终，作者使用 EfficientNet-B7 在 Imagenet top-1 上达到的准确率为 84.7%。在 EfficientNetV2 中，作者仍然使用了 NAS 技术，并联合了 accuracy、parameter efficiency 以及 training efficiency 三个维度。在 EfficientNetV2^[66]中，作者使用了 EfficientNetV1 中提出的 MBConv，该模块是一个逆瓶颈结构，使用了 MobileNet 中的 DW 卷积，DW 卷积能够在大幅度减少参数量的同时，能使精确率几乎不变，MBConv 中还是用了 SE 注意力模块，除了 MBConv 之外，作者还使用了 Fused-MBConv，该模块将 MBConv 中的升维卷积和 DW 卷积替换成一个升维卷积。最终，EfficientNetV2-S 模型在 Imagenet top-1 上的准确率为 83.9%，参数量仅为 22M，而 EfficientNetV2-XL 模型达到了 87.3%的准确率，是当时的最高水平。MBConv、Fused-MBConv 以及 SE 模块的结构如图 2-6 图 2-6 所示。




图 2-6 MBConv 和 Fused-MBConv 结构
Figure 2-6 MBConv and Fused MBConv structures

5 ONNX

ONNX 全称是 Open Neural Network Exchange，即开放神经网络交换，是一套表示深度神经网络模型的开放格式。自微软和 Facebook 于 2017 年推出 ONNX 以来，ONNX 迅速得到了各大厂商和深度学习框架的支持。

ONNX 定义了一组与环境 and 平台无关的标准格式，为深度学习模型的互操作性提供了基础，使深度学习模型可以在不同框架和环境下交互使用。各厂商可以基于 ONNX 标准优化模型性能，让所有兼容 ONNX 标准的框架受益。目前，即使使用不同框架训练的模型，转化为 ONNX 格式后，也可以很容易的部署在兼容 ONNX 的运行环境中。

ONNX 采用序列化数据结构协议 `protobuf` 来存储模型信息，因此可以使用 `protobuf` 来解析 ONNX 模型。ONNX 定义的六种数据结构如下所示。




图 2-7 ONNX 所定义的数据结构
Figure 2-7 Data structure defined by ONNX

第3章 油菜叶长宽和裂叶参数提取

油菜叶的长宽和裂叶数量是油菜叶的重要表型参数，对区分不同生长时期和不同性状的油菜具有很大的帮助。对于油菜叶而言，需要提取的与长度有关的参数有：叶长宽、叶片长宽、叶柄长，各个参数提取的标准如图 3-1 图 3-1 所示。




图 3-1 长宽参数提取标准

Figure 3-1 Length and width parameter extraction standard

此外，还需要提取一片油菜叶中的裂叶数量，油菜裂叶的标准以及计数方式如图 3-2 图 3-2 所示。



图 3-2 裂叶标准以及计数方式

Figure 3-2 the standard of split leaf and the method of counting

由于油菜叶的外观形状不一，并且裂叶之间很容易有重叠遮挡，因此很难用传统的图像算法提取出油菜叶的各个部位并进行定量计算。根据国内外研究进展，使用深度学习的方法来提取上述参数是可行的。为了兼顾检测时间和检测精度，本研究使用深度学习中的 Yolox 目标检测模型来获取油菜叶的各个部位并提取一系列表型参数。

1 数据集制作

1.1 数据集获取

把油菜叶从整株油菜中摘下来并依次排列整齐，然后将油菜叶放在白纸上，使用手机拍摄获得油菜叶图像。拍摄设备为 iphone8 Plus 和 iphone13 Pro，拍摄像素均为 1200 万像素，图像尺寸为 3024×4032 或 4032×3024，图像格式为 JPG 格式。具体的拍摄时间、拍摄地点、当天天气状况以及拍摄所得图像数量如表 3-1 所示。

表 3-1 拍摄时间等信息表

Table 3-1 Table of shooting time and other information			
拍摄时间	拍摄地点	天气状况	拍摄数量
2022.1.4	江苏省溧水区 农业科学院	气温：2° ——11°	200 张
		风速：5m/s	
		气压：1024kpa	
		湿度：64%	
2022.1.6	江苏省溧水区 农业科学院	天气：多云转小雨	190 张
		气温：2° ——9°	
		风速：4m/s	
		气压：1033kpa	
2022.1.24	浙江省绍兴市 诸暨市	降雨：3mm	86 张
		天气：多云	
		气温：6° ——10°	
		风速：3m/s	
2022.2.05	湖北省荆州市 石首市	气压：1021kpa	152 张
		湿度：88%	
		天气：多云	
		气温：-1° ——10°	
		风速：2m/s	
		气压：1023kpa	
		天气：雨夹雪转晴	

其中，在农业科学院中使用灯箱拍摄，其余在露天下拍摄，因此拍摄高度不固定。灯箱灯管为白炽灯，拍摄方法如图 3-3 所示。



图 3-3 拍摄方法

Figure 3-3 Shooting method

最后共计获得油菜图像 618 张，经过后期整理和筛选后，得到有效油菜图像共 487 张。部分原始图像如图 3-4 图 3-4 所示。




图 3-4 部分油菜图像

Figure 3-4 Some rape images

1.2 图像标注

由于需要判别出油菜的裂叶数量，同时又需要测出油菜叶片的长宽以及叶柄的长，因此需对要标注的内容一共有三项，叶片、叶柄、裂叶进行标注。由于需要提取多个油菜叶的参数，所以还需要标注油菜叶本身，以实现一一对应的功能。因此，需要标注的内容一共有四项，叶、叶片、裂叶、叶柄四项内容。

标注软件使用 labelimg 进行标注，该软件是使用 Python 和 Qt 开发出来的可视化图形操作界面标定工具，标注结果如图 3-5 图 3-5 所示。




图 3-5 标注结果

Figure 3-5 Marking results

标注完成后，会在设定好的目录下自动生成 XML 文件。该文件包含了标注图像的一系列信息，同时，每个标注好的矩形框都对应一个<object>标签，记录了该矩形框框选物体的信息，具体形式如图 3-6 图 3-6 所示。

```
<object>
  <name>main_leaf</name>
  <pose>Unspecified</pose>
  <truncated>0</truncated>
  <difficult>0</difficult>
  <bndbox>
    <xmin>955</xmin>
    <ymin>1134</ymin>
    <xmax>2031</xmax>
    <ymax>2220</ymax>
  </bndbox>
</object>
```

图 3-6 XML 中的标签信息

Figure 3-6 Tag information in XML

1.3 数据增强

对已标注好的 487 张图像进行扩增，使用的扩展方法有水平翻转、垂直翻转、HSV 变换、强化边缘和修改亮度等方法进行增强。在实际应用中，挑选了使用上述方法扩增后的 151 张图像并入数据集，本研究还使用了旋转扩增的方法，从上述扩增后的数据集中随机挑选 200 张图像进行旋转扩增（旋转角度为 90、180、270 中的随机值）。为了减少人工标注的工作量，在图像扩增的同时，修改对应的 XML 标注文件然后单独保存。这里需要注意的是，旋转扩增后的各个边界框的坐标应该是相对于旋转后的图像，当图像旋转 90 或 270 之后，各个边界框的坐标使用旋转计算后还需要进行平移计算。

数据扩增后，数据集中图像的总数为 838 张，部分扩增图像如图 3-7 图 3-7 所示。

批注 [z5]: 这里一系列“扩增”好，还是“增强”好？




图 3-7 增强后的图像

Figure 3-7 Enhanced image

1.4 数据集的划分

数据扩增完成后，需要划分出训练验证集、训练集、验证集以及测试集的图像用于模型的训练和评估。数据集中图像数量为训练验证集图像数量与测试集图像数量之和，训练验证集数量为训练集和验证集之和。在本研究中，训练验证集的图像数量与测试集的图像数量比为 9:1，在训练验证集中，训练集和测试集的比例也为 9:1，因此最后训练验证集、训练集、验证集、测试集中图像数量比为 0.9: 0.81: 0.09: 0.1，即训练验证集 754 张，训练集 678 张，验证集 76 张，测试集 84 张。

划分完成后，将图像的文件名保存在四个 txt 文件，trainval.txt、train.txt、val.txt 和 test.txt。

1.5 数据集存放格式

要训练 YOLOX 模型，首先需要处理并制作数据集。本次实验仿照 PASCAL VOC 数据集的格式制作一个油菜叶数据集。在 PASCAL VOC 数据集中，根目录是 VOCdevkit，VOCdevkit 文件夹下存放 VOC2007 文件夹，VOC2007 文件夹下的数据的存放方法如表 3-2 所示。

用 labelimg 标注好所有图像后，将 XML 标注文件全部存放于 Annotations 文件夹，将原始文件全部存放于 JPEGImages 文件夹。有关数据集划分的 4 个 txt 文件存放于 Main 文件夹下。至此，仿照 PASCAL VOC 格式的油菜叶数据集制作完成。

表 3-2 VOC 数据集格式				
Table 3-2 Format of VOC dataset				
VOC2007	Annotations	存放图像的标注信息（XML 文件）		
	ImageSets	Main	trainval.txt	存放训练验证图像的路径名
			train.txt	存放训练的图像的路径名
			val.txt	存放验证的图像的路径名
			test.txt	存放测试的图像的路径名
	JPEGImages	存放原始图像（JPG 文件）		

2 模型的训练与测试

2.1 环境准备与配置

本实验使用 [PyTorch](#) 的深度学习框架是 [PyTorch](#)。[PyTorch](#) 它是 FAIR 提出的可续计算包，不仅能够实现强大的 GPU 加速，还支持动态神经网络。实验所用硬件配置如[表 3-3 表 3-3](#)所示。

表 3-3 硬件配置	
Table 3-3 Hardware configuration	
硬件配置	型号与参数
处理器	8 × Intel(R) Xeon(R) CPU E5-2686 v4 @ 2.30GHz
内存	60G
硬盘	200G
显卡	一张 NVIDIA RTX A4000（16G 显存）

实验所用相关的依赖配置和版本号如[表 3-4 表 3-4](#)所示，使用的软件环境搭建在 Ubuntu 操作系统上。

表 3-4 软件配置		
Table 3-4 Software configuration		
名称	版本	作用
Python	3.7	编程语言
CUDA	11.1	NVIDA 的统一计算架构
cuDNN	8.0.5	深度神经网络的 GPU 加速库
PyTorch	1.9.1	深度学习框架
Ubuntu	18.04	Linux 操作系统
NVCC	11.1	CUDA 开发环境下的 C 语言编译器

2.2 模型的训练

本次训练选择 YOLO 网络结构中的 YOLO-s 网络，网络的预训练权重来自作者在 COCO 数据集上训练的权重，该网络的输入为（640,640）。其他训练参数配置如表 3-5 所示。

表 3-5 训练参数表	
Table 3-5 Training parameters table	
参数	数值
batch_size	16
epoch	1000
mosaic_prob	1.0
mixup_prob	1.0
optimizer	SGD
momentum	0.9
weight_decay	0.0005
LRscheduler	yoloxwarmcos

学习率变化表如图 3-8 所示，在训练的第 1 个 epoch，对学习率进行预热，然后使用余弦衰减的学习率调度策略直至训练结束。




图 3-8 学习率变化曲线图
Figure 3-8 Curve of learning rate

YOLO 的置信度损失和分类损失均采用 BCE 损失，在实际应用中，首先对输出分类概率值使用 sigmoid 函数映射到 0 和 1 之间，再使用 BCE 损失计算分类损失，BCE 损失计算公式如下。

$$loss = \frac{1}{N} \sum_{n=1}^N l_n \tag{3-1}$$

$$ln = -\omega_n[y_n \times \log x_n + (1 - y_n) \times (1 - \log x_n)] \quad (3-2)$$

其中， ω 是一个可选的超参数， y_n 是第 n 个样本的标签值， x_n 是第 n 个样本的预测值。Yolox 的 IoU 损失 loss 计算公式如下。

$$loss = \alpha \times (1 - IoU^2) \quad (3-3)$$

其中， α 在程序中固定为 5， IoU 指预测框和真实边界框的 IoU 值。

Yolox 的 L1 损失是一个可选的损失，其计算公式为：

$$loss = \frac{1}{N} \sum_{n=1}^N l_n \quad (3-4)$$

$$l_n = |x_n - y_n| \quad (3-5)$$

其中， x_n 是第 n 个样本预测的 4 个边界框的回归参数， y_n 是第 n 个样本的真实边界框回归参数。

总损失 (total_loss) 的计算公式为：

$$L_{total} = L_{IoU} + L_{conf} + L_{cls} + L_{l1} \quad (3-6)$$

其中， L_{total} 表示总损失， L_{IoU} 表示 IoU 损失， L_{conf} 表示置信度损失， L_{cls} 表示分类损失， L_{l1} 表示 L1 损失。

训练集上总损失 (total_loss)、IoU 损失 (iou_loss)、L1 损失 (l1_loss)、置信度损失 (conf_loss)、类别损失 (cls_loss) 的变化如图 3-9 图 3-9 所示。




图 3-9 训练集上各项损失变化曲线

Figure 3-9 Variation curve of each loss on the training set

可以看到，模型在训练了 400 个 epoch 之后损失稳定，并且在最后关闭 mosaic 和 mixup 数据增强后，损失继续下降。

在测试集上得到的最高 AP 为 83.46，测试集上的 AP50 和 AP50_95 指标变化如图 3-10 图 3-10 (a) 和图 3-10 图 3-10 (b) 所示。




图 3-10 测试集上的 AP 指标
Figure 3-10 AP metrics on test set

四种类别在 IoU 阈值为 0.5 和 0.75 情况下 AP 值如表 3-6 所示，IoU 为 0.75 情况下的 P-R 曲线如图 3-11 所示。可以看到，rape（油菜叶）的 P-R 曲线处于上方的位置，与坐标轴围成的面积大，因此模型对这类的检测效果十分良好。由于油菜叶的叶柄可能会收到裂叶遮挡等因素，因此叶柄的检测稍差于油菜叶的检测。

表 3-6 四种类别分别在 IoU 为 0.5 和 0.75 下的 AP 值和 mAP 值

Table 3-6 AP and mAP values of four categories with IOU of 0.5 and 0.75 respectively

IoU	rape	main_leaf	leaf	petiole	mAP
0.5	1.000	0.989	0.901	0.995	0.971
0.75	0.998	0.895	0.894	0.877	0.916




图 3-11 四种类别的 P-R 曲线
Figure 3-11 Four categories of P-R curves

2.3 NMS 后处理

在目标检测的后处理阶段，通常会有利用 NMS 处理（Non-Maximum Suppression）来抑制一些冗余的预测边界框。NMS 会筛选出得分最高的边界框并进行保留，而其他框则相应地丢弃，图 3-12 ~~图 3-12~~是 NMS 算法处理后的效果。



图 3-12 NMS 处理后的预测结果

Figure 3-12 Prediction results after NMS processing

NMS 算法可以分为 Class-aware 和 Class-agnostic 两类，Class-aware nms 会对每一类别的目标边界框单独做一次 NMS 处理，然后循环处理其余类别的目标边界框，而 Class-agnostic 算法则直接对所有的边界框进行一次性的 NMS 处理。当前，大多数目标检测算法在进行模型预测阶段采用的是 Class-agnostic nms 后处理算法，包括 Yolox 模型，也是采用该算法进行 bbox 的后处理。

在本研究中，Class-agnostic nms 并不适用，因为 Yolox 网络会同时检测油菜叶和油菜叶的其他部位，这些部位包括叶柄、油菜叶片、裂叶，由于油菜叶片包含在油菜叶内部，很有可能会因为油菜叶片和油菜叶的重叠面积过大，导致 Class-agnostic nms 后处理算法舍弃油菜叶和油菜叶片中低置信度的目标。而事实上，应当完整地保留一片油菜叶的各个部位的预测框。为了各个类别间的 NMS 处理不受影响，应当使用 Class-aware nms 算法，即同一个类别单独做 nms 处理，该方法能够较好地同时保留油菜叶和油菜叶片。图 3-13 ~~图 3-13~~和 图 3-14 ~~图 3-14~~是分别使用 Class-agnostic nms 和 Class-aware nms 后处理算法的对比结果。




图 3-13 Class-agnostic nms 处理结果

Figure 3-13 Class-agnostic NMS processing results




图 3-14 Class-aware nms 处理结果

Figure 3-14 Class-aware NMS processing results

如上所示，在使用 Class-agnostic nms 算法处理后，0 号油菜叶的叶片以及 2 号油菜叶的预测框由于置信度较低并且与叶片和叶的 IoU 大于设定的阈值而被舍弃，而使用 Class-aware nms 算法可以很好的保留有效的预测框。

3 图像校正

3.1 油菜叶分割

用 YOLOX 模型识别出的部位可能会存在倾斜的状态，直接提取长宽并不准确，因此需要对各个部位进行校正后才能获取到正确的长宽。在图像校正的过程中，需要识别图像的主体部分，而图像分割在图像识别中起关键性作用，选择合理的分割方法能够加快图像的处理和识别速度。

为了探讨在本研究下最好的用于油菜叶分割的算法，使用了三种常用的绿色植物叶片分割算法进行试验，分别是基于阈值的超绿因子分割^[58]、Otsu 分割、K-means 分割。超绿因子的计算公式为：

$$ExG = 2 \times G - B - R \quad (3-7)$$

其中， G 、 B 、 R 分别对应图像的三个通道。

超绿因子分割的原理是计算出超绿因子后，在该基础上进行最大最小归一化后重新转换成整型数据的图像，再使用 Otsu 算法进行分割，其本质上仍然属于基于阈值的分割算法，该方法能够较好地分割出图像中的绿色叶片。K-means 在计算过程中的重复次数为 1，迭代次数为 5，终止条件为精度达到 1.0。K-means 算法处理图像后能够得到两组点集以及这两组点集的中心像素值，为了便于后续的轮廓提取，需要将油菜主体设置为白色，而背景设置为黑色，为此，需要识别出两组点集中哪一类属于油菜，由于本数据集中油菜主体呈现在图像中心，因此具体做法是：在进行 K-means 处理前，记录下原始图像中心的像素值，记为 $(b1, g1, r1)$ ，然后对 K-means 获得的两组中心像素值 $(b2, g2, r3)$ 、 $(b3, g3, r3)$ 与 $(b1, g1, r1)$ 分别计算其欧式距离 m ， n ，具体计算公式如下所示。

$$m = \sqrt{(b1 - b2)^2 + (g1 - g2)^2 + (r1 - r2)^2} \quad (3-8)$$

$$n = \sqrt{(b1 - b3)^2 + (g1 - g3)^2 + (r1 - r3)^2} \quad (3-9)$$

比较 m 和 n 的大小，较小者即对应油菜叶主体的像素点集，将其染成白色。

为了定量评价不同算法的分割性能，使用错分率^[59]作为评价指标，错分率的计算公式如下：

$$err = \frac{n_e}{n_s} \times 100\% \tag{3-10}$$

其中， n_e 表示分类错误的像素点数， n_s 表示所有的像素点数量。

使用 PhotoShop 软件对原始图像进行人工分割，将人工分割得到的黑白图像作为对照图像，根据其他算法运行后的结果，计算该算法的误差图像和错分率。

具体的对比结果如图 3-15 图 3-15 所示。




图 3-15 不同分割算法的比较结果

Figure 3-15 Comparison results of different segmentation algorithms

根据公式 3-10 计算得到的各个算法误差如表 3-7 表 3-7 所示。

表 3-7 不同算法的分割误差

Table 3-7 Segmentation errors of different algorithms

图像名称	K-means 误差	超绿指数误差	Otsu 误差
2022_01_04_13_03_IMG_9064.JPG	0.31%	18.3%	0.58%
2022_01_06_12_22_IMG_9282.JPG	0.002%	0.04%	0.05%
2022_01_06_12_00_IMG_9259.JPG	0.012%	0.15%	0.04%
2022_01_04_13_03_IMG_9066.JPG	0.09%	1.25%	0.20%

可以看出，当植物叶片足够“绿”或者背景和叶片差异足够大时，三种算法的分割效果差异不大；当叶片有泛黄或者背景和叶片差异较小时，使用 K-means 分割算法方法得到的分割图像效果较好。因此本研究使用 K-means 算法作为主要的图像分割方法。

3.2 基于矩的主轴方向计算

在获取各部位的长宽时，首先需要计算物体的主轴旋转角，将物体旋转摆正后再获取相对应的长和宽。主轴旋转角的计算主要用到矩，包括零阶矩、一阶矩、二阶矩^{[17][60]}。

零阶矩的计算公式为：

$$M(0,0) = \sum_{(i,j) \in S} f(i,j) \quad (3-11)$$

一阶矩的计算公式为：

$$M(1,0) = \sum_{(i,j) \in S} if(i,j) \quad (3-12)$$

$$M(0,1) = \sum_{(i,j) \in S} jf(i,j) \quad (3-13)$$

二阶矩的计算公式为：

$$M(2,0) = \sum_{(i,j) \in S} i^2 f(i,j) \quad (3-14)$$

$$M(2,0) = \sum_{(i,j) \in S} j^2 f(i,j) \quad (3-15)$$

$$M(1,1) = \sum_{(i,j) \in S} ijf(i,j) \quad (3-16)$$

其中， $f(i,j)$ 表示 i, j 处的像素值， S 表示像素区域。用上述公式分别计算出零阶矩、一阶矩和二阶矩后，可以得出质心的坐标，公式如下。

$$\begin{cases} x = \frac{M(1,0)}{M(0,0)} \\ y = \frac{M(0,1)}{M(0,0)} \end{cases} \quad (3-17)$$

将部位的主轴绘制在坐标轴上，如图 3-16 所示，校正的目的是将主轴与 y 轴重合。




图 3-16 主轴示意图

Figure 3-16 Schematic diagram of main shaft

上图中， α 的计算公式如下。

$$\tan 2\alpha = \frac{2M(1,1)}{M(2,0)-M(0,2)} \quad (3-18)$$

校正算法流程如下：

- ①加载图像，对图像进行一定量的边界补充，本次实验使用原图像对应长宽的六分之一，然后使用 K-means 方法对图像进行分割并得到黑白二值图像。
- ②使用 opencv 中的轮廓检测方法提取轮廓，计算该轮廓外接矩形的长宽作为对照。
- ③求出图像矩，并使用公式计算出 α ，将轮廓点全部旋转 $90 - \alpha$ 角度。
- ④旋转后的轮廓即为校正轮廓。

3.3 像素长宽测量

使用上述公式计算得到 α 后，对油菜叶轮廓进行旋转，由于需要将图像摆正，因此实际旋转角度为 $90 - \alpha$ ，求出旋转后轮廓的外接矩形长宽，该长宽即为所需长宽。对于油菜叶柄而言，由于只需要测得长度，而对于倾斜的油菜叶柄，使用勾股定理计算也是一种待考虑的方案。

随机选择并裁剪油菜叶部位，绘制其原始轮廓以及使用校正算法后的轮廓，结果如图 3-17 图 3-17 所示。




图 3-17 原始轮廓与校正轮廓

Figure 3-17 Original contour and corrected contour

使用 Photoshop 软件人工测量出各个部位图像的实际像素长宽，然后使用原始算法以及校正算法分别获取像素长宽，对于叶柄，额外使用勾股定理的方法计算长度，不需要获得其宽度。结果如表 3-8 表 3-8 所示。

表 3-8 不同方法测得的像素长宽

Table 3-8 Pixel length and width measured by different methods

图像	测量长(宽)	未校正长(宽)	校正长(宽)	勾股定理
图像 1	513	504	515	519
图像 2	813 689	783 690	822 693	\
图像 3	1449	1439	1457	1478

可以得出，使用校正算法校正图像后再获取长宽能够减少一定的误差，使获取得到的参数更加精准。

4 真实长宽提取

虽然使用 Yolox 模型获取到了各个部位的长宽，但是这些参数的单位都是像素，在实际应用中，需要将像素单位转变为常用的厘米或者毫米单位。对于一幅图像而言，最为可行的方法是单目测距法。

4.1 单目测距

单目测距是仅利用一个摄像机获得的图像来得出深度信息，摄像机的成像系统类似于针孔成像模型，如下图所示。




图 3-18 针孔成像模型示意图

Figure 3-18 Schematic diagram of pinhole imaging model

其中， H 表示物体的实际长度， d 为成像物体到摄像机的距离， f 为摄像机内部的焦距， h 为物体在摄像机内部的成像高度， O 为光轴与平面相交的点，根据相似三角形的原理， H 可由如下公式表示：

$$H = h \times \frac{d}{f} \quad (3-19)$$

若已知物体成像高度 h ，摄像机焦距 f ，物体到摄像机的距离 d 。

4.2 焦距标定


大部分场景下，无法获得焦距的准确数值，这时需要根据实际应用场景求出焦距。根据上节提到的成像模型，可以得到焦距公式如下。

$$f = h \times \frac{d}{H} \quad (3-20)$$

需要准备一个长度已知的物体，记长度为 H 。用摄像机定高为 d 拍摄该物体并获取该物体的图像，使用算法计算出该物体的像素长度为 h ，即可用上述公式计算出 f 。这里使用的算法与上一节用于油菜部位长宽的测量使用的算法一致。

准备一张用于标定的白纸图像，如图 3-19 图 3-19 (a) 所示，记录下白纸的实际长度为 21CM，相机拍摄高度为 25CM，使用 K-means 分割算法分割图像得到标注主体，然后使用轮廓检测获取主体的长度，如图 3-19 图 3-19 (b) 所示，计算得到白纸的像素长度为 3400pixel。

根据公式 3-20 可以计算出焦距为 4047.62。



(a) 用于标定的图像

(b) 标注出长度的图像

图 3-19 用于标定的图像和标注出长度的图像

Figure 3-19 Image for correction and image with marked length

4.3 长宽转换和误差分析

计算出焦距后，即可用公式 3-19 计算出各个部位的实际长度，对于上节的三个油菜部位图像，可以计算出真实长宽如所示。

表 3-9 真实长宽表

Table 3-9 True length width table

图像	校正长(宽)(像素)	真实长(宽)(CM)
图像 1	515	2.00CM
图像 2	822 693	5.077CM 4.28CM
图像 3	1457	9.00CM

应用上述算法至其他油菜叶中，将计算所得真实长宽与实际测量得到的长宽进行比较计算误差，使用的油菜叶图像如 (a) (b) (c) 所示，预测结果如图 3-20 图 3-20 (d)

(e) (f) 所示，图中的 0 表示在图中的 0 号油菜，计算误差结果如表 3-10 表 3-10 所示，其中真实值和计算值均以厘米作为单位。误差计算公式如下所示。裂叶数量误差为漏检和错检的数量。

$$err = \left| \frac{L_c - L_r}{L_r} \right| \times 100\% \quad (3-21)$$

其中， err 表示误差值， L_c 是计算所得值， L_r 是真实测量值。

$$\eta = \frac{err_a + err_b + err_c + err_d}{4} \quad (3-22)$$

其中， η 是平均误差， err_a 、 err_b 、 err_c 、 err_d 分别是叶长、叶宽、叶片长、叶片宽的误差。




图 3-20 原始油菜图像及其预测图
Figure 3-20 Original rape picture and its prediction map

表 3-10 计算误差表

Table 3-10 Calculation error table

图像名称	参数类型	真实值	计算值	误差	平均误差
P20328-185433.jpg	叶片长	10.2CM	9.18CM	10.00%	8.786%
	叶片宽	8.10CM	7.36CM	9.14%	
	叶柄长	4.60CM	5.06CM	12.00%	
	叶长	14.8CM	14.24CM	3.78%	
	叶宽	8.10CM	7.37CM	9.01%	
	裂叶数量	3 片	3 片	0	
P20328-190646.jpg	叶片长	10.5CM	9.52CM	9.33%	10.59%
	叶片宽	10.20CM	8.36CM	18.04%	
	叶柄长	7.60CM	6.54CM	13.95%	
	叶长	18.10CM	16.06CM	11.27%	
	叶宽	8.20CM	8.17CM	0.37%	
	裂叶数量	3 片	3 片	0	
P20328-194839.jpg	叶片长	10.20CM	9.34CM	8.43%	9.322%
	叶片宽	7.30CM	8.89CM	21.8%	
	叶柄长	7.10CM	7.33CM	3.23%	
	叶长	17.30CM	16.67CM	3.64%	
	叶宽	8.10CM	8.87CM	9.51%	
	裂叶数量	8 片	8 片	0	

从表可知，使用上述方法计算得到的各表型参数与测量得到的参数平均误差在 10%左右，提取得到的裂叶数量基本与实际数量相一致，能够满足实际测量需要。

第4章 油菜卷叶识别

油菜叶片是否处于卷曲的状态是油菜叶的重要参数之一。油菜卷曲程度的分类如图4-1图4-1所示。



图 4-1 卷叶分类标准

Figure 4-1 Classification standard of rolled leaf

由于油菜的卷曲程度不一，有时还会受裂叶以及遮盖重叠的影响，甚至主叶片也形状不一，难以用传统的图像处理算法来进行分类。因此，本研究拟使用深度卷积神经网络来实现卷叶的分类。

1 基于卷积神经网络的分类方法

1.1 数据集制作

对上述拍摄得到的数据集进行整理，将每幅油菜图像进行分类（如果一幅图像中有多个油菜叶则舍弃不进行分类）分成无、弱、强三类，最终得到3类油菜图像数量分别为237、85、5。可以发现，在收集的油菜图像中大部分为无卷油菜，只有很少部分是强卷油菜。由于数据集各类图像数量的限制以及分布上的严重不平衡，拟将油菜卷曲参数分为两类：无卷和卷。这两类油菜叶数量比为237:90。分类后的数据集部分图像如图4-2图4-2所示。

对原始数据集分类完成后，划分数据集即可开始训练。然而由于两类样本存在着不平衡的分布，即数量差过大，会影响神经网络的分类性能。因此在训练前首先进行数据增强。




图 4-2 卷叶分类数据集部分图像

Figure 4-2 Some pictures of leaf roll classification dataset

1.2 数据增强

为了解决数据不平衡的问题，采用数据增强的方式对数据集进行扩增。扩增方式有三种，分别是随机 HSV 增强、随机旋转平移增强、随机镜像增强，对卷叶数据集扩增 4 倍，对非卷叶数据集扩增 2 倍。最终两类图像的数量比为 711: 540。部分增强效果如 [图 4-3](#) 所示。




图 4-3 部分增强后的图像

Figure 4-3 Partially enhanced picture

1.3 模型训练与测试

在本次实验中，划分训练集和验证集比例为 8:2，软硬件配置与上节 YOLOx 中使用的配置一致。使用 Imagenet 上训练好的 EfficientNetV2-s 权重进行迁移学习，训练过程使用

的一些参数配置如表 4-1 所示：

表 4-1 训练参数配置表	
Table 4-1 Training parameter configuration table	
参数名	配置
batch_size	16
epoch	100
learning_rate	初始为 0.01，使用余弦 学习率衰减
optimizer	SGD 优化器 momentum: 0.9 weight_decay:0.001

在训练过程中，不冻结任何权重，共训练了 100 个 epoch，结果如图 4-4 和图 4-5 所示。




图 4-4 EfficientNetV2 训练集和验证集准确率变化表

Figure 4-4 Accuracy change table of efficientnetv2 training set and verification set




图 4-5 EfficientNetV2 训练集和验证集损失变化表

Figure 4-5 Loss change table of efficientnetv2 training set and verification set

由图可知，模型的整体损失是下降的，并且在训练集和验证集上的准确率都非常高。为了验证模型的泛化性，重新拍摄油菜叶获取到 28 幅新图像，其中，25 幅图像为非卷叶，3 幅图像为卷叶。将这 28 幅图像用于测试，结果显示，在 25 张非卷叶中，只有 10 幅图像被预测为非卷叶，其余均被预测为卷叶，而 3 幅卷叶均预测正确。

新拍摄的数据集如图 4-6 所示。




图 4-6 新拍摄的油菜叶图像
Figure 4-6 Newly photographed rape leaf image

模型泛化性能差，很有可能是模型学习到了其他的特征，对于一个二分类问题而言，这样的精度和泛化性能达不到要求。在训练过程中测试集的准确率比训练集的准确率高，对原始数据集中两类图像的数量分析可得，发生这种现象的原因很有可能是数据扩充过度，使得数据集的分布偏离了实际的分布，导致模型泛化性能不足，也有可能是数据集分类有问题，也就是在对卷叶和非卷叶进行分类时，有许多图像被错误的分类或者分类的界限不够清晰。

2 基于自监督的学习方法

受主观因素影响，部分油菜叶图像有被分类错误的可能。不同的研究人员在分类卷叶图像时，也会因为主观因素而得出不同的分类结论，因此，如果要使计算机得出一个客观的分类结论，需要对部分图像数据进行清洗以达到高的分类准确率。

另外，发生上述问题的主要因为原始数据集中的两类图像数量相差过大，数据分布不平衡，导致在数据增强的过程中扩充过度。现实世界中存在着大量的不平衡数据。如果按照数据从高到低的频率进行排序，会发现数据分布呈现出一个“长尾巴”，也就是长尾效应^[61]。Yuzhe Yang 等^[61]系统分析了长尾数据集之后，提出了半监督和自监督的训练方法，并用理论系统证明了无标签数据的价值。在自监督方面，作者提出了自监督预训练 SSP（self-supervised pretrain）模块，该模块旨在从不平衡的数据集中学到更好的、与标签无关的初始信息，预训练完成后，可以用标准的训练方法再去训练由 SSP 训练后的模型。实验证明，在不平衡数据集的分类问题上引入 SSP 模块会带来明显的性能提升。

2.1 数据处理

为了提升的分类模型的性能，对原始数据集进行数据清洗，剔除一些不清晰的、难以分辨的图像，对一幅图像中有多片油菜叶的图像进行裁剪得到多幅单个油菜叶图像，对这些图像分类后并入数据集。最后得到的非卷油菜叶数量和卷叶数量比为 295:33。对卷叶数据集单独进行数据增强，使用 HSV 色域增强和镜像增强等方法进行扩增，不使用旋转扩增，为了尽量使数据集贴近实际分布，减少了本次扩增的图像数量，扩增后卷叶的图像数量为 56 张。

油菜叶在送入网络训练前，通常会有预处理操作，该操作不仅可以加快模型的正向传播速度，也可以提升模型鲁棒性。上节使用的预处理方式如下：

①将给定图像随机裁剪为不同的尺寸和高宽比，然后缩放裁剪得到的图像为设定好的尺寸。

②随机水平翻转①得到的图像。

③将图像归一化并转为 Tensor 格式后再进行标准化处理。

上述预处理方式是 Cifar10 数据集的预处理，但是在后续的使用中发现该方式并不适用于卷叶分类数据集。因为本次油菜数据集中的油菜叶片主体在中心，并且长宽不固定，在标准预处理的第一步——随机裁剪的时候，很容易裁剪得到背景，而纯色的背景没有任何训练和测试的价值。另外在缩放的时候并不是等比例缩放，这会造成图像的扭曲，很容易丢失卷叶中“卷”这一特征或造成歧义信息。为了缩小图像大小，尽量减少参数计算量，同时又不丢失油菜叶的主要信息，根据目标检测标注得到的 XML 文件中包含的油菜信息，对卷叶分类数据集中的图像进行裁剪得到油菜叶图像，该图像去除了大量的背景，使用裁剪后的图像作为新的数据集，如图所示。




图 4-7 裁剪处理得到的数据集
Figure 4-7 DataSet obtained by clipping processing

设置了格式：突出显示

在模型训练前，使用新的预处理算法，具体流程为：

①设定预处理后需要得到的目标大小 $S \times S$

②加载图像后将图像等比例缩放至原图像的较长边为 S ，则原图像的较短边必定小于 S 。

③将缩放后的图像复制到新建的 $S \times S$ 方形矩阵的中心，矩阵的其余位置填充背景颜色。

④将图像归一化并转为 Tensor 格式后再进行标准化处理。

图 4-8 展示了新预处理方法与上节 Cifar10 预处理方法的效果差异，由于原始图像中背景占比很大，因此使用 Cifar10 预处理方法很容易得到一个没有油菜叶的纯色背景，如果有多张图像预处理成纯色的背景图像，那么会加大模型分类错误的概率。




图 4-8 Cifar10 预处理方法（右）与新的预处理方法（中）结果比对图

Figure 4-8 Comparison of results between Cifar10 pretreatment method (right) and new pretreatment method (middle)

使用新的预处理方法可以让输入进模型的数据更加有效，使模型更好地学习卷叶特征。

2.2 旋转自监督

在 Yuzhe Yang 提出的 SSP 模块中，作者使用了 Moco^[62]和 Rotation^[63]等自监督训练方法，Moco 方法在表示空间中使用对比损失来测量正负样本对的相似性，并使用动量来更新编码器，而 Rotation 方法是一种简单有效的方法，将图像旋转 90° 的随机倍数，然后构建一个四分类模型，训练该模型以确定输入图像的旋转角度。Yuzhe Yang 在 CIFAR-10-LT 和 CIFAR100-LT 使用不同的不平衡率做了大量实验后得出：Rotation 方法在小规模的数据集上效果更好，因此本研究采用 Rotation 方法作为自监督训练方法（这也说明了没有使用旋转的数据增强方式），在预处理时将图像数据处理成方阵的形式，便于进行旋转操作。具体流程如图 4-9 所示。




图 4-9 旋转自监督流程图

Figure 4-9 Rotating self-monitoring flow chart

在自监督训练上，采用 ResNet 模型进行训练，本次训练采用的预训练模型是 ResNet32 模型在不平衡率为 0.1 的 CIFAR-10-LT 上训练 200 个 epoch 后的模型，模型初始学习率为 0.01，采用余弦衰减的学习率调整方案，衰减率为 0.0002，损失函数选择二值交叉熵损失，共训练 100 个 epoch，训练结果如图 4-10 图 4-10 和图 4-11 图 4-11 所示。

在旋转自监督的训练过程中，模型预测的最高准确率能够达到 100%，说明模型能够准确提取出图像中的主体部分，对于接下来的标准训练具有极大的帮助。




图 4-10 旋转自监督准确率变化表

Figure 4-10 Rotation self-monitoring accuracy change table




图 4-11 旋转自监督损失变化表

Figure 4-11 Rotation self-monitoring loss change table

2.3 模型的标准训练与测试

在使用旋转自监督方法训练的基础上继续训练标准的卷叶分类模型，损失函数选择二值交叉熵损失函数，使用不同的初始学习率和迭代次数进行了实验，具体结果如表 4-2 表 4-2 所示。

表 4-2 使用不同训练配置得到的准确率表

Table 4-2 Accuracy table obtained by using different training configurations

实验序号	实验 1	实验 2	实验 3	实验 4
初始学习率	0.1	0.01	0.001	0.1
迭代次数	100	100	150	200
批数量	16	16	16	16
训练集准确率	99.24	98.1	1.0	1.0
验证集准确率	98.26	97.46	98.46	98.57

其中，实验 3 的有关数据的图表如图 4-12、图 4-12 和图 4-13、图 4-13 所示。




图 4-12 ResNet32 准确率变化曲线
Figure 4-12 Resnet32 accuracy change curve




图 4-13 ResNet32 损失变化曲线
Figure 4-13 Resnet32 loss change curve

用同样的方式对新拍摄得到的数据集进行预测，此次数据集中存放图像如[图 4-14](#) [图 4-14](#)所示。




图 4-14 用于预测的图像

Figure 4-14 Picture for prediction

经过模型预测后，25 张非卷叶全部预测正确，3 张卷叶也全部预测正确，相比较于直接使用模型去训练，采用旋转自监督学习的 ResNet32 模型有较高的精度，并且有良好的泛化性能，也说明该模型在卷叶分类上是十分有效的。两种方法的比较结果如表 4-3 表 4-3 所示。

表 4-3 两种方法的比较结果

Table 4-3 Comparison results of the two methods

方法	指标	值	精确率	召回率
EfficientNet V2	TP	10	100%	40%
	FN	15		
	FP	0		
	TN	3		
ResNet32+SSP	TP	25	100%	100%
	FN	0		
	FP	0		
	TN	3		

第5章 叶缘缺刻程度识别

油菜叶顶端的叶缘缺刻程度是油菜叶的又一重要表型参数，其评估标准如图 5-1 图 5-1 所示。



图 5-1 叶缘缺刻程度评估标准

Figure 5-1 Evaluation criteria of leaf margin notch

1 叶缘特征提取

叶片的叶缘特征有许多方法进行提取，郑小东^{[69][70]}等人使用凸包以及 SUSAN 算法提取叶缘特征，徐辉^[68]使用角点检测的方法提取叶缘，他们本质上这些方法都是使用 Harris 算子进行检测得出叶缘，但是并没有继续深入研究如何通过叶缘特征进行下一步的识别工作。事实上，由于油菜的叶缘特征比较明显，可以根据利用形态学的方法快速获取一些提前特征，然后再使用机器学习的方法对特征进行分类。

本次使用的特征提取算法步骤如下：

①载入图像，使用 k-means 算法分割图像，在对图像上色时，需要将油菜主体填充成白色，而背景填充成黑色，为此，需要判断 k-means 分割的两组像素点中哪一组是油菜叶。做法是，提取原图中最底下的中心点，将该中心点的颜色与 k-means 获取到的两个中心点颜色分别求欧氏距离，距离小的是油菜叶主体。之后进行上色获得黑白二值图像（油菜主体是白色）。

②对黑白二值图像进行轮廓检测，对得到的轮廓进行多边形拟合，精度为轮廓周长的 0.007 倍。

③对轮廓检测得到的一系列点集进行遍历，去除因曲线闭合而处于角落的点，对剩余点在 X 轴上进行排序，用反正切函数计算相邻两个点组成的连线与水平轴构成的角度，每计算一个，就加入列表中作为一个特征点。

④为了确保特征数量相同，对特征点大于 10 个以上的，取中间 10 个，不足 10 个的，在两边补 0 填充。

⑤最终获取到长度为 10 的特征向量。

图 5-2 图 5-2 和图 5-3 图 5-3 为使用该算法获得的特征点，黄点表示多边形顶点。



图 5-2 特征点 1

Figure 5-2 Feature point 1

得到的特征向量为：-1.23， -1.13， 0.35， -0.92， 0.51， 0.64， 0.97， -0.07， 1.11， -0.06。




图 5-3 特征点 2

Figure 5-3 Feature point 2

得到的特征向量为：-1.03， 0.20， -1.01， 0.79， -0.10， -0.84， 0.27， 0.84， -0.46， 1.17。

2 SVM 支持向量机

支持向量机的理论由前苏联的数学家提出，支持向量指的是距离超平面最近，在支撑平面上将两类类别划分开的样本点（向量）。支持向量机本质上是基于监督学习的二元广义分类器，它的目的是学习一个分类模型，使用该模型可以将输入的多维数据映射到某一类别中，进而实现预测的功能^[67]。

2.1 数据获取

对原始数据集进行了简单的分类，分为弱、中、强三类，然后将图像进行裁剪得到主叶的图像，以该图像作为数据集中的图像，每一类所含图像的数量为 20:34:14，部分叶缘缺刻程度为中等的油菜图像如图 5-4 所示。

使用上节的特征提取算法提取特征向量并写入文本文件中以构建数据集，每行数据由 10 个特征值和一个标签值组成，如图 5-5 图 5-5 所示。



图 5-4 部分叶缘缺刻程度为中等的油菜图像

Figure 5-4 Picture of rape with medium degree of leaf edge notch



图 5-5 记录的部分特征值

Figure 5-5 Partial eigenvalues recorded

2.2 SVM 训练与测试

在 SVM 中有 4 个常用的核函数，分别是 linear、poly、sigmoid、rbf。rbf 核函数，也叫作径向基核函数，是一种局部性强的核函数，可以将一个样本映射到一个更高维的空间内，无论是大样本还是小样本有能有较好的性能^[5]，而且相对于 poly 核函数而言，参数要更少，大多数情况下如果不知道使用哪一个核函数，可以优先使用 rbf 核函数。因此本次训练选择的核函数为 rbf。训练集和测试集的划分比例为 8:2，将正则化参数 C 固定为 2，使用不同的核系数 gamma 进行训练和测试，得到的准确率结果表 5-1 表 5-1 所示。最终选用核系数 gamma 为 0.3 的 SVM 模型进行后期的预测。

表 5-1 不同核系数下准确率变化表

Table 5-1 Table of accuracy change under different kernel coefficients

核系数 gamma	训练集准确率	测试集准确率
0.1	77.78%	78.57%
0.3	94.44%	85.71%
0.6	96.30%	78.57%
0.8	98.15%	78.57%

第6章 模型的部署与系统开发

1 ONNX 模型部署

Pytorch 提供了专门用于 ONNX 处理的包 onnx，使用 onnx 中的 export 方法可以快速导出 ONNX 模型。同时，ONNX 文件是可以在网站 <https://netron.app/> 进行可视化显示的，但是显示参数繁多，不简洁，使用 onnxsim 可以简化模型，让显示更加自然。对于 YOLOx 模型，导出模型的参数如表 6-1 表 6-1 所示。

表 6-1 导出 ONNX 模型的配置参数表

Table 6-1 Export the configuration parameter table of YOLOx model

参数	值
model	YOLOx-s
input	(640,640,3)的随机 numpy
opset_version	11
output_name	YOLOx.onnx

对于 ResNet32 模型，导出参数如表 6-2 表 6-2 所示。

表 6-2 导出 ResNet32 模型的配置参数表

Table 6-2 Export the configuration parameter table of ResNet32 model

参数	值
model	resnet32
input	(256,256,3)的随机 numpy
opset_version	10
output_name	resnet32.onnx

一般 ONNX 推理时不包括网络中的后处理部分，因此需要使用 numpy 等包重写一些后处理方法，例如 NMS。

使用 ONNX 进行推理可以大大加快推理速度，挑选了 5 张图片用于测试，未使用 ONNX 与使用 ONNX 推理所花费的时间如表 6-3 表 6-3 所示。

表 6-3 使用 ONNX 与不使用 ONNX 的推理速度的对比

Table 6-3 Comparison of reasoning speed between using onnx and not using onnx

图像名	未使用 ONNX 的推理速度	使用 ONNX 的推理速度	加速百分比
2022_01_04_10_27_IMG_8994.JPG	2.30s	0.50s	78.26%
2022_01_04_14_25_IMG_9127.JPG	1.78s	0.39s	78.09%
2022_01_06_11_41_IMG_9234.JPG	1.94s	0.56s	71.13%
2022_01_06_12_22_IMG_9282.JPG	2.08s	0.57s	72.60%

批注 [z6]: 一个表不要分页

2022_01_25_14_02_IMG_9479.JPG 2.33s 0.52s 77.68%

可以看到，使用 ONNX 推理模型可以极大的加快模型的推理速度，加速百分比维持在 70%以上。

2 前后端实现

2.1 前端实现

前端界面使用 html、css、javascript 等技术，使用 bootstrap 框架。bootstrap 框架是 Twitter 推出的一个用于前端开发的工具包，它由 Twitter 的设计师 Mark Otto 和 Jacob Thornton 合作开发，是一个 CSS/HTML 框架^[71]。数据请求方面，使用 Ajax 进行数据的请求和发送，Ajax 全称为 Asynchronous Java Script and XML（异步 Java Script 和 XML），是指一种结合了 JavaScript 和 XML 等编程技术，用于创建交互式网页应用的 Web 开发技术。Ajax 是使用客户端脚本与 Web 服务器异步交换数据的 Web 应用开发方法^[72]。

编写了一个简单的前端界面，如图 6-1 图 6-1 所示。界面中的控制面板部分主要用于单目测距的校正，用户可以选择上传单张图像或者整个文件夹进行批量处理，识别完成后，可以点击“导出表格数据按钮”将信息导出至 excel。

图 6-1 前端界面

Figure 6-1 Front end interface

2.2 Flask 后端

Flask 是一个轻量的、便捷的、使用 Python 编写的 Web 框架，Flask 框架较其他同类型框架更为灵活、轻便、安全且容易上手。它可以很好地结合 MVC 模式进行开发，开发人员分工合作，小型团队在短时间内就可以完成功能丰富的中小型网站或 Web 服务的实现^[72]。

本次研究使用 Flask 实现了四个路由，具体如下：

(1) /index

index 展示了前端操作界面，如图 6-1 图 6-1 所示。使用的网页模板为 Jin Jia2。

(2) /correct

correct 路由主要实现单目测距中的焦距校正功能，用户需要上传一张图像，并提供拍摄高度以及图像中物体的真实长，系统会自动开始计算焦距，并在原图标注图像中物体的像素值和长度，返回给前端，由用户进行确认是否计算正确。具体的参数说明和响应格式如表 6-4 表 6-4 和表 6-5 表 6-5 所示。

表 6-4 /correct 提交参数格式

Table 6-4 /correct submit parameter format

参数名称	参数类型	是否必选	参数说明
distance	String	是	拍摄距离
length	String	是	物体实际长度
img	String	是	以 base64 编码的图像

表 6-5 /correct 服务器响应格式

Table 6-5 /correct server response format

数据名称	数据类型	说明
img	String	以 base64 编码的处理后的图像 (标注有像素长度信息)
focus	String	焦距大小 (用于 Console 输出)

前端界面会同时显示提交的校正图像和标注出长度的图像，用户点击图像后可查看放大后的图像，如图 6-2 图 6-2 和图 6-3 图 6-3 所示。图中红色的直线表示系统识别出的长。



图 6-2 展示上传的图像以及服务器返回的图像

Figure 6-2 Display the uploaded image and the image returned by the server




图 6-3 放大标注长度的图像
Figure 6-3 Enlarge the picture with the marked length

(3) /param

param 路由主要处理前端的 POST 请求，用于对发送过来的油菜叶图像信息进行处理，得到本研究提到的所有已实现提取的油菜叶参数，并打包成 json 格式的数据返回给前端。具体的参数说明如表 6-6 所示。

表 6-6 /param 提交的参数格式
Table 6-6 /Param submitted parameter format

参数名称	参数类型	是否必选	参数说明
base64Img	String	是	以 base64 编码的图像
imgname	String	是	图像文件名

服务器会返回一个字典格式的 result，字典中的每一个值包含了图像中的一片油菜叶包含的信息，每个值也是一个字典，result 中的每一个值的 key 和 value 的对应关系如表 6-7 所示。

表 6-7 /param 服务器响应格式
Table 6-7 /Param server response format

键值	含义
class	表示是否是卷叶
leaf_margin	叶缘缺刻程度
length	油菜叶像素长度和真实长度
main_leaf	长度为 4 的数组，分别表示像素长宽和真实长宽
num_leaf	裂叶数量

图 6-4 所示为上传了一幅图像名为 2022_01_25_14_02_IMG_9479.JPG 的图像后，

前端表格的展示效果。



图 6-4 上传图像后前端展示效果

Figure 6-4 Front end display effect after uploading pictures

提取到油菜叶的参数后，研究员可以导出表格数据至 Excel 文件并对数据进行进一步的处理，如图 6-5 图 6-5 所示。

A	B	C	D	E	F	G	H
文件名	叶子标号	叶长宽及真实长宽	叶片长宽及真实长宽	叶柄长及真实长	裂叶数量	是否卷叶	叶缘缺刻程度
2022_01_25_14_02_IMG_9479.JPG	0	1164,691,7.19,4.27	813,691,5.02,4.27	351,2.17	1	非卷叶	中
2022_01_25_14_02_IMG_9479.JPG	1	1411,810,8.71,5	928,807,5.73,4.98	483,2.98	1	非卷叶	弱
2022_01_25_14_02_IMG_9479.JPG	2	1142,568,7.05,3.51	727,571,4.49,3.53	415,2.56	1	非卷叶	中

图 6-5 导出至 Excel 的数据

Figure 6-5 Data exported to excel

(4) /ret_img

ret_img 路由主要用于实现处理后图像的展示，一方面研究员可以了解各个部位的识别情况，另一方面用于确认图像中油菜叶的对应标号，系统可以在收到请求后回传对应图像的预测情况。具体的参数说明和响应格式如表 6-8 表 6-8 和表 6-9 表 6-9 所示。

表 6-8 /ret_img 提交的参数格式

Table 6-8 /ret_img format of submitted parameters

参数名称	参数类型	是否必选	参数说明
imgname	String	是	图像名

表 6-9 /ret_img 服务器响应格式

Table 6-9 /ret_img server response format

数据名称	数据类型	说明
img	String	以 base64 编码的处理后的图像 (标注有边界框和叶标号信息)

用户点击“查看解析图像”后，即可展示预测图像。图 6-6 图 6-6 展示了在前端界面

显示油菜图像的预测结果图。




图 6-6 预测结果图
Figure 6-6 Forecast result chart

第7章 总结与展望

1 总结

油菜叶表型参数的提取对筛选出优良的油菜基因、减少种植油菜成本上具有重要的作用。当前，图像处理、深度学习等已经广泛的应用于参数的自动化提取上。本文以图像处理为基础，研究了油菜叶的表型参数的提取，包括叶长宽、叶片长宽、叶柄长、叶缘缺刻程度、是否卷叶、裂叶数量等。

本研究以江苏省农科院内的拍摄的油菜作为主要数据集进行实验，使用 YOLOX 目标检测模型，运用 Class-aware NMS 后处理方法，对多个油菜叶进行叶柄、裂叶、叶片的提取，对提取到的各个部位使用矩求出主轴方向并得到校正后的像素长宽，使用单目测距的方法将像素单位的长宽转为实际应用中的厘米长宽。

在提取卷叶参数时，由于油菜叶的形状多样，难以用传统图像处理算法进行分类，因此使用深度学习的方法进行识别。由于数据集的分布不平衡，导致在预处理过程中数据增强过度，使得训练得到的 EfficientNetV2 网络预测效果不佳，在新数据集上的召回率仅有 40%，泛化性能较差。因此使用 ResNet32 模型采用旋转自监督的学习方法进行预训练，输入网络的图像使用方阵填充的形式进行预处理，自监督训练的最高准确率能够达到 100%，之后使用标准的 ResNet32 网络进行训练，最终在新数据集上的精确率和召回率均为 100%，能够准确提取油菜的卷叶参数。

在提取叶缘缺刻程度参数上，使用 k-means 分割图像后，获取轮廓的近似多边形顶点，对相邻的顶点求取连线与水平轴的角度，提取其中处于中间的 10 个角度作为特征值，使用内核为 rbf、C 为 2、gamma 的 0.3 的 SVM 分类器进行训练，最终训练集和测试集达到的准确率为 94.44%，85.71%。

最后，使用 ONNX 部署 YOLOX 和 ResNet32 模型以加速推理，使用 Flask 框架搭建后端，使用 bootstrap 框架开发前端界面，使用 Ajax 进行数据交互，供研究人员上传图像并进行油菜叶参数的自动化提取。

2 展望

虽然本文的研究工作有一定的进展，但仍存在较大的探索空间：

(1) 从技术路线可以看出，YOLOX 网络是全部的核心，YOLOX 网络部位提取的准确直接影响后续的处理，虽然训练 YOLOX 网络前进行了多样化的数据增强，并且 YOLOX 自带 Mosaic 和 Mixup 数据增强，最后的预测结果误差不会特别大。但是在使用 YOLOX 网络进行油菜叶各个部位的提取时，图像内各个油菜叶之间的重叠面积不宜过大，否则后处理部分可能会抑制一些有用的预测框，导致各个部位无法匹配，并且重叠面积过大会大大影响后续的图像分割和校正模块。因此，在重叠方面可以继续深入研究，探讨如何在油菜叶互相遮挡的情况下获取表型参数。

(2) 拍摄油菜叶时，如果叶顶端有阴影部分，可能会影响叶缘缺刻的识别，如果阴

批注 [z7]: 这两个 100%，太高了

设置了格式：突出显示

设置了格式：突出显示

影和油菜叶主体难以区分的话，会影响图像分割的效果，进而导致无法提取正确的轮廓线。因此，在拍摄时尽量避免叶顶端的阴影，或者研究新的算法来确保背景和主体的分割。

（3）单目测距算法需要保证拍摄的图像不扭曲，而相机一般会因为广角的问题会有所扭曲，因此工业上如果想要取得更高的精度的话，可以考虑使用双目测距。当然，单目测距因为其部署方便、计算简单，在一些精度要求不高的场合也有较大的应用前景。

（4）本研究使用的数据集样本较少，各个参数提取的精度并不十分精确，自监督学习的训练方法也是为了解决样本不平衡的问题，后续如果有更充分的数据集，可以以正常训练的方式获取更高的精度。

参考文献

- [1]何微,李俊,王晓梅,林巧,杨小微.全球油菜供需现状与我国油菜产业问题、对策[J/OL].中国油脂:1-8[2021-12-28].<http://kns.cnki.net/kcms/detail/61.1099.ts.20210929.1245.006.html>.
- [2]颜旭. 提升我国食用油数量和质量的重要保障[N]. 农民日报,2021-10-08(007).DOI:10.28603/n.cnki.nnmrb.2021.004450.
- [3]张敏,钟志堂,金梅,赵敏,吴崇友.江苏省油菜生产现状与问题分析[J].中国农机化学报,2021,42(08):209-213+236.DOI:10.13733/j.jcam.issn.2095-5553.2021.08.28.
- [4]李治中,谢菲,刘小梅,刘云云,邵剑文.2 种常用叶面积测量方法准确性的比较研究[J].中国农学通报,2013,29(19):193-197.
- [5]Zhang Wanhong.Digital image processing method for estimating leaf length and width tested using kiwifruit leaves (*Actinidia chinensis* Planch)[J].2020-07-06.
- [6]Schrader Julian, Shi Peijian, Royer Dana L, Peppe Daniel J, Gallagher Rachael V, Li Yirong, Wang Rong, Wright Ian J. TI Leaf size estimation based on leaf length, width and shape[J]. 2021-09-03.
- [7]Fiorani F, Schurr U. Future Scenarios for Plant Phenotyping[J]. Annual Review of Plant Biology, 2013,64(1):267.
- [8]胡鹏程. 基于无人机近感的高通量田间作物几何表型研究[D].中国农业大学,2018.
- [9]Furbank, R. T., Tester, M., 2011. Phenomics-technologies to relieve the phenotyping bottleneck. Trends Plant Sci. 16, 635-644. <https://doi.org/10.1016/j.tplants.2011.09.005>
- [10]Chen, Ai J. An Image-Based Method for Automatically Measuring Leaf Parameters with a Scanner[J]. Advanced Materials Research, 2011, 171-172:683-687.
- [11]Haiyun, Liu, Xu, et al. A Plant Leaf Geometric Parameter Measurement System Based on the Android Platform.[J]. Sensors, 2019.
- [12]Mora M, Avila F, Carrasco-Benavides M, et al. Automated computation of leaf area index from fruit trees using improved image processing algorithms applied to canopy cover digital photographs[J]. Computers & Electronics in Agriculture, 2016, 123:195-202.
- [13]李锦卫,管鹤卿,廖桂平. 基于计算机视觉的油菜叶面积计算方法研究[J]. 农业网络信息,2010(12):15-18,23. DOI:10.3969/j.issn.1672-6251.2010.12.005.
- [14]王静,李灿灿,王情伟,王宝,李丰果.树叶长宽比及边缘曲率的提取[J].华南师范大学学报(自然科学版),2013,45(01):38-41.
- [15]徐义鑫,李凤菊,王建春,花登峰,张雪飞,吕雄杰,钱春阳.基于 OpenCV 的 Android 手机植物叶片几何参数测量系统[J].中国农学通报,2015,31(35):236-244.
- [16]王键,梁春娇,郭俊先,马生健,刘金祥,吴志华.基于 OpenCV 确定植物叶片面积[J].分子植物育种,2020,18(06):2023-2027.DOI:10.13271/j.mpb.018.002023.
- [17]李瑞洋. 基于机器视觉的高精度植物叶片几何参数测量方法研究[D].西京学

- 院,2020.DOI:10.27831/d.cnki.gxjxy.2020.000074.
- [18]郑凯,李建胜.基于深度神经网络的图像语义分割综述[J].测绘与空间地理信息,2020,43(10):119-125.
- [19]Tsafaris S A, Minervini M, Scharr H. Machine Learning for Plant Phenotyping Needs Image Processing[J]. TRENDS IN PLANT SCIENCE, 2016,21(12):989-991.
- [20]Badrinarayanan V, Kendall A, Cipolla R. Segnet: A deep convolutional encoder-decoder architecture for image segmentation[J]. IEEE transactions on pattern analysis and machine intelligence, 2017, 39(12): 2481-2495.
- [21]Ronneberger O, Fischer P, Brox T. U-net: Convolutional networks for biomedical image segmentation[C]//International Conference on Medical image computing and computer-assisted intervention. Springer, Cham, 2015: 234-241.
- [22]Zhao H, Shi J, Qi X, et al. Pyramid scene parsing network[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2017: 2881-2890.
- [23]Slik J . Automated Extraction of Phenotypic Leaf Traits of Individual Intact Herbarium Leaves from Herbarium Specimen Images Using Deep Learning Based Semantic Segmentation[J]. Sensors, 2021, 21.
- [24]Kolhar S , Jagtap J . Convolutional neural network based encoder-decoder architectures for semantic segmentation of plants[J]. Ecological Informatics, 2021, 64:101373.
- [25]刘建. 基于深度学习的葡萄叶片病害诊断系统研究与开发[D].河北科技师范学院,2021.
- [26]王鹤树,曹丽英.基于全卷积神经网络的植物叶片自动分割及表型解析[J].中国农机化学报,2021,42(08):161-168.DOI:10.13733/j.jcam.issn.2095-5553.2021.08.22.
- [27]郭晓丽. 基于全卷积神经网络的植物图像分割算法研究与实现[D].内蒙古大学,2021.DOI:10.27224/d.cnki.gnmdu.2021.000727.
- [28]Long,J.,Shelhamer,E.,andDarrell,T.Fully Convolutional Networks for Semantic Segmentation.arXive-prints,2014.
- [29]Chen,L.C.,Papandreou,G.,Schroff,F.,andAdam,H.Rethinking AtrousConvolution forSemantic Image Segmentation.arXive-prints,2017.
- [30]安胜彪,娄慧儒,陈书旺,白宇.基于深度学习的旋转目标检测方法研究进展[J].电子测量技术,2021,44(21):168-178.DOI:10.19651/j.cnki.emt.2107833.
- [31]陶莎. 基于深度学习的拟南芥叶片和角果的表型参数获取[D].华中农业大学,2020.DOI:10.27158/d.cnki.ghznu.2020.000577.
- [32]Hasan M M, Chopin J P, Laga H, et al. Correction to: Detection and analysis of wheat spikes using Convolutional Neural Networks[J]. Plant Methods, 2019, 15(1).
- [33]高云鹏.基于深度神经网络的大田小麦麦穗检测方法研究[D].北京林业大学,2019.
- [34]Tu Y L , Lin W Y , Lin Y C . Toward automatic plant phenotyping: starting from leaf counting[J]. Multimedia Tools and Applications, 2022, 81(9):11865-11879.
- [35]Vishal M K , Banerjee B , Saluja R , et al. Leaf Counting in Rice (Oryza Sativa L.) Using Object

Detection: A Deep Learning Approach[C]// IGARSS 2020 - 2020 IEEE International Geoscience and Remote Sensing Symposium. IEEE, 2020.

[36]谢富,朱定局.深度学习目标检测方法综述[J].计算机系统应用,2022,31(02):1-12.DOI:10.15888/j.cnki.csa.008303.

[37]Girshick R, Donahue J, Darrell T, et al. Rich feature hierarchies for accurate object detection and semantic segmentation[C].Proceedings of the IEEE conference on computer vision and pattern recognition. 2014: 580-587.

[38]Ren S, He K, Girshick R, et al. Faster r-cnn: Towards real-time object detection with region proposal networks[J]. Advances in neural information processing systems, 2015, 28.

[39]He K, Zhang X, Ren S, et al. Spatial pyramid pooling in deep convolutional networks for visual recognition[J]. IEEE transactions on pattern analysis and machine intelligence, 2015, 37(9): 1904-1916.

[40]Liu W, Anguelov D, Erhan D, et al. Ssd: Single shot multibox detector[C]//European conference on computer vision. Springer, Cham, 2016: 21-37.

[41]Everingham M , van Gool L, Williams CK , et al. The PASCAL Visual Object Classes (VOC) challenge. International Journal of Computer Vision, 2010, 88(2): 303–338.

[42]Deng J, Dong W, Socher R, et al. ImageNet: A large-scale hierarchical image database. 2009 IEEE Conference on Computer Vision and Pattern Recognition. Miami: IEEE, 2009. 248–255.

[43]Lin TY, Maire M, Belongie S, et al. Microsoft coco: Common objects in context. Proceedings of the 13th European Conference on Computer Vision. Zurich: Springer, 2014. 740–755.

[44]Redmon J, Divvala S, Girshick R, et al. You only look once: Unified, real-time object detection. Proceedings of the 2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). Las Vegas: IEEE, 2016. 779–788.21

[45]Redmon J, Farhadi A. Yolo9000: Better, faster, stronger. Proceedings of the 2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). Honolulu: IEEE, 2017. 6517–6525

[46]Redmon J, Farhadi A. Yolo3: An incremental improvement. arXiv: 1804.02767, 2018

[47]Bochkovskiy A, Wang CY, Liao HYM. Yolo4: Optimal speed and accuracy of object detection. arXiv: 2004.10934, 2020.

[48]Ge Z, Liu S, Wang F, et al. YoloX: Exceeding Yolo series in 2021[J]. arXiv preprint arXiv:2107.08430, 2021.

[49]Zhang H, Cisse M, Dauphin Y N, et al. mixup: Beyond empirical risk minimization[J]. arXiv preprint arXiv:1710.09412, 2017.

[50]Zheng Ge, Songtao Liu, Zeming Li, Osamu Yoshie, Jian Sun; Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2021, pp. 303-312

[51]黄旭,张世义,李军.图像分割技术研究综述[J].装备机械,2021(02):6-9.

[52]黄鹏,郑淇,梁超.图像分割方法综述[J].武汉大学学报(理学版),2020,66(06):519-

- 531.DOI:10.14188/j.1671-8836.2019.0002.
- [53]Bieniek A, Moga A. An efficient watershed algorithm based on connected components[J]. Pattern Recognition, 2000,33(6):907-916.
- [54]Otsu N. A Threshold Selection Method from Gray-Level Histograms[J]. IEEE Transactions on Systems Man & Cybernetics, 2007,9(1):62-66.
- [55]唐闯. 基于边缘检测的图像分割算法研究[D]. 燕山大学, 2012.
- [56]黄旭,张世义,李军.图像分割技术研究综述[J].装备机械,2021(02):6-9.
- [57]张新野. 基于聚类分析的图像分割方法研究[D]. 大连海事大学, 2012.
- [58]吴兰兰,熊利荣,彭辉.基于 RGB 植被指数的大田油菜图像分割定量评价[J].华中农业大学学报,2019,38(02):109-113.DOI:10.13300/j.cnki.hnlkxb.2019.02.015.
- [59]邓晓政,焦李成,卢山.基于非负矩阵分解的谱聚类集成 SAR 图像分割[J].电子学报,2011,39(12):2905-2909.
- [60]苑玮琦,胡迪.利用矩实现植物叶片长宽的测量[J].计算机工程与应用,2013,49(16):188-191+231.
- [61]Muhammad Abdullah Jamal, Matthew Brown, Ming-Hsuan Yang, Liqiang Wang, and Boqing Gong. Rethinking class-balanced methods for long-tailed visual recognition from a domain adaptation perspective.arXiv preprint arXiv:2003.10780, 2020.
- [62]Kaiming He, Haoqi Fan, Yuxin Wu, Saining Xie, and Ross Girshick. Momentum contrast for unsupervised visual representation learning.arXiv preprint arXiv:1911.05722, 2019.
- [63]Spyros Gidaris, Praveer Singh, and Nikos Komodakis. Unsupervised representation learning by predicting image rotations.arXiv preprint arXiv:1803.07728, 2018.
- [64]He K,Zhang X,Ren S,et al.Deep residual learning for image recognition[A].IEEE,2016:770-778.
- [65]Tan M , Le Q V . EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks[J]. 2019.
- [66]Tan M , Le Q V . EfficientNetV2: Smaller Models and Faster Training[J]. 2021.
- [67]杨通. 基于投资者情绪的 SVM 量化择时策略[D].西安理工大
学,2021.DOI:10.27398/d.cnki.gxalu.2021.001368.
- [68]徐辉,王忠芝,黄心渊.基于角点检测的叶缘锯齿快速识别[J].北京林业大学学报,2010,32(06):85-89.DOI:10.13332/j.1000-1522.2010.06.028.
- [69]王晓洁,于浩杰,郑小东.凸包在植物叶锯齿与叶裂位置识别中的应用[J].农机化研究,2013,35(03):214-217.DOI:10.13427/j.cnki.njyi.2013.03.022.
- [70]郑小东,王晓洁,高洁.SUSAN 算法在植物叶缘特征提取中的应用[J].中国农学通报,2011,27(27):174-178.
- [71]赖佳星.基于 Bootstrap 和 JavaScript 技术设计与实现简易 Web 计算器[J].科技资讯,2022,20(01):13-16.DOI:10.16661/j.cnki.1672-3791.2110-5042-2874.
- [72]朱莹芳,吴莉.Ajax 技术在网上生鲜商城的设计与应用[J].安徽电子信息职业技术学院学报,2021,20(05):29-33.

[73]李相霏,韩珂.基于 Flask 框架的疫情数据可视化分析[J].计算机时代,2021(12):60-63+68.DOI:10.16644/j.cnki.cn33-1094/tp.2021.12.014.

致谢

行笔至此，不仅感慨时光飞逝，岁月荏苒。我还清晰地记得拿到录取通知书、踏入学校、进入宿舍的情形，那一幕幕的过往仿佛就发生在昨天。从陌生到熟悉，我见证了南农的变化，南农也一定看到了我的变化。在这一座富有活力的学校中，我遇见了不同的人 and 事，看到了校园中别样的风景，在这临别之际，无论是老师同学还是校园，心中都充满了感激和不舍。

由衷地感谢团委志工部和科协，在这两个部门，我认识到了乐于助人的学长们还有四年都在一起学习、一起奋斗的同学们，有他们的陪伴，让我始终认为大学的学习时光是最为快乐，即使这之中有挫折和困难，他们也会慷慨相助，一起共渡难关。感谢社委会组织，认识了陈仕为、赵益琪、郑金屿、申青青等等好朋友，和他们相处非常得快乐。十分感谢贺宁学长，在我初入图像处理领域时，他也和我探讨过许多相关的内容，在本文的一些细节上也给出了许多建议，让我能够更好地完成本文。感谢田幸源、叶开在科协学生组织上的帮助。感谢 202 宿舍的兄弟们。感谢在教学楼 D402 和 D403 一起学习、做实验的朋友和同学们，在这里不仅有学习上的谈笑风生，也有一起约饭局的拍手约定。

感谢熊迎军老师和朱淑鑫老师。自大二认识熊老师至今，他给了我许多建议和学习思路，熊老师爽快的性格以及对学生的支持让我在 SRT 上的研究和开发上十分顺利，不仅让我拿到了优秀结题证书，并且熊老师的诸多建议也都深深影响着我。感谢朱老师和农科院的老师，朱老师不仅在毕业论文的选题、开题方面都给出了莫大的帮助和指导，还积极地帮助我联系农科院的老师，这里也十分感谢农科院的老师在我拍摄油菜图像这段时间里的帮助和关照。在研究进展方面，朱老师也时时刻刻能够提出一些建议，让我的论文能够在不断地改进中越来越完善和严谨。

最后感谢父母，从拿到本科录取通知书到大四录取硕士研究生，我一直能够感受到他们对我的支持与帮助，是他们的包容和鼓励才能让我在求学的路上越走越远，也让我拥有了一颗敢于探索的勇气和决心。对父母的爱无以言表，希望我能够尽自己最大的努力好好地回报他们。

此致谢写于公寓，大学生活虽然十分充实，但也有不少遗憾。毕业季是大学最后时光，而我却因为疫情不得已远离南京，无法回到校园感受最后一段美好的时光，这也许也是四年之间最大的遗憾了吧。在国企实习的这段时间，也让我更加明白生活不易，一定要珍惜在学校学习的日子。

最后祝疫情早日散去，国家昌盛、国泰民安！

杨晟伟

2022 年 4 月于杭州