

数据仓库与数据挖掘

Data warehouse and data mining

丁钰

yuding@njau.edu.cn

南京农业大学人工智能学院

第一章：概论

参考书籍

- Jiawei Han, Micheline Kamber, and Jian Pei. *Data Mining: Concepts and Techniques*. Morgan Kaufmann, Third Edition, 2011.
(The English reprint edition can be bought through [China-Pub](#).)
- Christopher M. Bishop. *Pattern Recognition and Machine Learning*. Springer, 2006.

Course Topics

- 1、引言
- 2、认识数据
- 3、数据预处理
- 4、数据仓库与联机分析处理
- 5、数据立方体技术
- 6、挖掘频繁模式和关联规则
- 7、高级频繁模式挖掘
- 8、分类：基本概念
- 9、分类：高级方法
- 10、聚类分析：基本概念和方法
- 11、高级聚类分析
- 12、离群点检测

数据挖掘技术不断进步、新方法不断涌现，本课程注重**基本概念**和**基本方法**

预备知识

- 高等数学
- 线性代数
- 概率论
- 数据结构
- 数据库原理
- Python程序设计

成绩构成

- 平时(40%)
 - 出勤、编程作业、课程小测试
- 期末(60%)
 - 知识点考核、综合计算分析

开课必要性：国家战略

- 《“十四五”大数据产业发展规划》（以下简称《规划》），在延续“十三五”规划关于大数据产业定义和内涵的基础上，进一步强调数据要素价值。
- 一是顺应新形势。“十四五”时期，我国进入由工业经济向数字经济大踏步迈进的关键时期，经济社会数字化转型成为大势所趋，**数据上升为新的生产要素，数据要素价值释放成为重要命题**，贯穿《规划》始终。
- 二是明确新方向。立足推动大数据产业从培育期进入高质量发展期，在“十三五”规划提出的产业规模1万亿元目标基础上，提出**“到2025年底，大数据产业测算规模突破3万亿元”**的增长目标，以及数据要素价值体系、现代化大数据产业体系建设等方面的新目标。
- 三是提出新路径。为推动大数据产业高质量发展，《规划》提出了**“以释放数据要素价值为导向，以做大做强产业本身为核心，以强化产业支撑为保障”**的路径设计，增加了培育数据要素市场、发挥大数据特性优势等新内容，将“新基建”、技术创新和标准引领作为产业基础能力提升的着力点，将产品链、服务链、价值链作为产业链构建的主要构成，实现数字产业化和产业数字化的有机统一，并进一步明确和强化了数据安全保障。

开课必要性：工业界的角度

www.51job.com 前程无忧 好工作尽在前程无忧

首页 职位搜索 地区频道 无忧学园 职场资讯 校园招聘 无忧精英

搜全文 搜公司 5G 工作职能 行业领域 搜索

工作地点: 全国 全部城市 >

月薪范围: 所有 自定义 > 2千以下 2-3千 3-4.5千 4.5-6千 6-8千 0.8-1万 1-1.5万 1.5-2万 2-3万 3-4万 4-5万 5万以上 多选 +

展开选项 (公司性质、公司规模、工作年限等) >

☐ 全选 ☒ 智能排序 ☐ 最新发布 ☆ 收藏 批量申请 < 1 / 143 >

☐ 5G通信技术支持+住宿五险 02-18发布 山西恒业博远通信技术有限公司
5-5.5千/月 太原 | 无需经验 | 大专 | 招1人
五险一金 交通补贴 通讯补贴 弹性工作
民营企业 | 500-1000人
通信/电信/网络设备

☐ 社招职位-网络架构研发岗 (5G网络... 02-18发布 上海飞机制造有限公司
2.2-5万/月 上海 | 1年经验 | 本科 | 招2人
国企

好工作为你优选

开课必要性：学术的角度

☰ Scholar Search

data mining

🔍

📖 文章

找到约 3,810,000 条结果 (用时0.06秒)

时间不限

2022以来

2021以来

2018以来

自定义范围...

按相关性排序

按日期排序

不限语言

中文网页

简体中文网页

类型不限

评论性文章

☐ 包括专利

☒ 包含引用

📧 创建快讯

[图书] Data mining

[P Adriaans](#), [D Zantinge](#) - 1997 - [dl.acm.org](#)
... process applies artificial intelligence concepts to [data mining](#)... Chapter 1 outlines the concepts of KDD and the [data mining](#) ... to the basics of [data mining](#) and [data](#) warehousing in chapter 3...

☆ 保存 90 引用 被引用次数: 1385 相关文章 所有 2 个版本 00

[PDF] Practical machine learning tools and techniques

[JH Witten](#), [E Frank](#), [MA Hall](#), [CJ Pal](#), M DATA - DATA MINING, 2005 - [doc1.bibliothek.li](#)
[Data Mining](#) ... 375 9.1 Applying [Data Mining](#) ... 378 9.3 [Data Stream Learning](#) ...

☆ 保存 90 引用 被引用次数: 1223 相关文章 所有 2 个版本 00

[PDF] Data mining for education

[R Baker](#) - [International encyclopedia of education](#), 2010 - [Citeseer](#)
... Educational [data mining](#) methods often differ from methods from the broader [data mining](#) literature, in explicitly exploiting the multiple levels of meaningful hierarchy in educational [data](#), ...

☆ 保存 90 引用 被引用次数: 770 相关文章 所有 8 个版本 00

[图书] Data preparation for data mining

[D Pyle](#) - 1999 - [books.google.com](#)
... savvy analyst or modeler who works with [data](#) on a daily basis and who wants to use [data mining](#) to get the most out of [data](#). The type of [data](#) the analyst works with is not important. It ...

☆ 保存 90 引用 被引用次数: 2320 相关文章 所有 4 个版本 00

[一键下载]sci-hub

[PDF] bibliothek.li
View it @ CTU

[PDF] psu.edu

[PDF] temida.si

相关搜索

data mining techniques

data mining clustering

data mining algorithms

data mining knowledge discovery

data mining concepts and techniques

privacy preserving data mining

weka data mining

data mining decision tree

大纲

- 为什么需要数据挖掘
- 什么是数据挖掘
- 可以挖掘什么类型的数据
- 可以挖掘出什么样的模式
- 在数据挖掘中应用了哪些技术
- 数据挖掘带来了哪些应用
- 数据挖掘面临的问题
- 数据挖掘的发展
- 总结




为什么需要数据挖掘

图1：全球数据量增长预测



单位: 亿GB
移动互联网接入流量



数据的价值迎来了悄无声息却影响深远的革新。在十年前, 大众对于数据的价值描绘得头头是道, 如同发掘到金矿的淘金客一般, 而如今, 围绕数据的话题逐渐回归理性。再某种意义上, 数据的价值正在向更深层次演进, 和石油相比, 数据更像与我们日常生活息息相关的水和空气。

为什么需要数据挖掘

- 数据量急剧膨胀
 - 数据采集与数据可用性
 - 自动化采集工具，数据库，云计算，算力提升...
 - 数据源的增加
 - 商业：互联网、物联网、移动互联网、工业4.0、电子商务、交易、证券...
 - 科学：遥感技术、生物信息、计算模拟...
 - 其他：新闻、电影、电视剧...
- 数据丰富，但信息贫乏（人的理解能力受限）！
- “Necessity is the mother of invention”——柏拉图
- 数据挖掘——从海量数据中挖掘有用信息

大纲

- 为什么需要数据挖掘
- 什么是数据挖掘 
- 可以挖掘什么类型的数据
- 可以挖掘出什么样的模式
- 在数据挖掘中应用了哪些技术
- 数据挖掘带来了哪些应用
- 数据挖掘面临的问题
- 数据挖掘的发展
- 总结

什么是数据挖掘




- 数据挖掘(Data mining, knowledge discovery from data)
 - 从大量的数据中提取有趣的 (非平凡的, 蕴涵的, 先前未知的 并且是 潜在有用的) 信息或模式
 - 挖掘-从大量的、未加工的材料中发现少量宝贵金块
- Watch out: Is everything “data mining”?
 - Simple search and query processing
 - (Deductive) expert systems




数据挖掘与KDD(Knowledge discovery in databases)

- KDD是一个以知识使用者为中心，人机交互的探索过程，包括了在指定的数据库中使用数据挖掘计算提取模型，以及围绕数据挖掘所进行的预处理和结果表达等一系列的步骤。
- 尽管数据挖掘是整个过程的中心，但它通常只占KDD过程15%~25%的工作量



商业智能中的数据挖掘



大纲

- 为什么需要数据挖掘
- 什么是数据挖掘
- 可以挖掘什么类型的数据
- 可以挖掘出什么样的模式
- 在数据挖掘中应用了哪些技术
- 数据挖掘带来了那些应用
- 数据挖掘面临的问题
- 数据挖掘的发展
- 总结



可以挖掘什么类型的数据


- 数据库数据

- 关系型数据库(Relational database)
- 某品牌销售关系数据库：

<i>customer</i>	(cust_ID, name, address, age, occupation, annual_income, credit_information, category, ...)
<i>item</i>	(item_ID, brand, category, type, price, place_made, supplier, cost, ...)
<i>employee</i>	(empl_ID, name, category, group, salary, commission, ...)
<i>branch</i>	(branch_ID, name, address, ...)
<i>purchases</i>	(trans_ID, cust_ID, empl_ID, date, time, method_paid, amount)
<i>items_sold</i>	(trans_ID, item_ID, qty)
<i>works_at</i>	(empl_ID, branch_ID)

可以挖掘什么类型的数据

- 数据仓库(Data warehouse)
- 数据仓库是一个从多个数据源收集的信息存储库，存放在一致的模式下，并且通常驻留在单个站点上。
- 数据仓库是面向主题的、集成的、相对稳定的、反映历史变化的数据集合。



可以挖掘什么类型的数据

■ 事务数据

■ 事务数据库的每个记录代表一个事务

- 在网页中每一个点击
- APP中的每一个动作
- 超市的每一笔购物

<i>trans_ID</i>	<i>list of item_IDs</i>
T100	I1, I3, I8, I16
T200	I2, I8
...	...

- 购物篮数据分析：哪些商品一起销售得很好？

可以挖掘什么类型的数据

■ 其他类型

- 时间序列数据
 - 股票交易数据、服务器运行日志、历史记录、生物学序列数据...
- 数据流
 - 视频流、监控流、传感器流...
- 空间数据
 - 基于地图的数据...
- 工程设计数据
 - 建筑数据、集成电路...
- 超文本和多媒体数据
 - 文本、视频、音频、图像...
- 图和网状数据
 - 社会网络、信息网络...

大纲

- 为什么需要数据挖掘
- 什么是数据挖掘
- 可以挖掘什么类型的数据
- 可以挖掘出什么样的模式
- 在数据挖掘中应用了哪些技术
- 数据挖掘带来了那些应用
- 数据挖掘面临的问题
- 数据挖掘的发展
- 总结



挖掘频繁模式、关联和相关性

- 频繁模式:数据中频繁出现的模式
- 频繁项集: 频繁在事务数据集中一起出现的商品集合
 - 在购物的时候哪些商品会经常被一起购买?
- 关联与相关性

例如: 典型的关联规则

尿不湿 $\rightarrow$ 啤酒

□ 多维和单维关联

□ $age(X, "20..29") \wedge income(X, "20..29K") \Rightarrow buys(X, "PC")$

$[support = 2\%, confidence = 60\%]$

□ $contains(T, "computer") \Rightarrow contains(T, "software")$

$[support = 1\%, confidence = 75\%]$


分类和回归

- 找出描述和区分类或概念的模型(函数), 用于标号未知的对象的标号预测

Predict some unknown class labels

- Ex. 1. 根据(气候)区分国家
- Ex. 2. 根据(油耗)区分汽车


- 模型表示:
 - 判定树, 朴素贝叶斯分类, 支持向量机, 神经网络, 分类规则..
- 典型应用:
 - 风险用户预测, 用户画像分类, ...



- 分类预测类别（离散的、无序的）标号，回归建立连续值函数模型，也就是用来预测缺失的或难以获得的数值数据值。



聚类分析

- 无监督学习-类标号(Class label)未知
- 对数据分组，形成新的类。例如，对房屋分类，找出分布模式
- 聚类原则：最大化类内的相似性，最小化类间的相似性




孤立点分析

- 孤立点: 一个数据对象, 它与数据的一般行为不一致
- 大部分数据挖掘方法都将孤立点视为噪声或异常而丢弃
- 对于欺骗检测和罕见事件分析, 它是相当有用的




孤立点分析

- 方法: 可以使用聚类或分类等方法来发现孤立点




时间和顺序：序列模式、趋势和演化分析

- 序列、趋势和演化分析
 - 趋势, 时间序列, 偏差分析
 - e.g., 回归和数值预测
 - 序列模式
 - e.g., 买了手机, 然后要买充电器
 - 周期性分析



图结构分析

- 图结构数据挖掘
 - 寻找频繁子图(e.g., 化合物), 树(XML), substructures (web fragments)
- 信息网络分析
 - 关系网络: actors (objects, nodes) and relationships (edges)
 - e.g., author networks in CS, terrorist networks
 - 多源异构网络
 - A person could be multiple information networks: friends, family, classmates, ...
 - 网络的连接承载了语义信息: 链接挖掘
- 网络挖掘
 - 互联网信息网络: from PageRank to Google
 - Web社区发现, 意见挖掘, 用户访问模式挖掘, ...



挖掘出的所有模式都是有趣的吗？

- 一个数据挖掘系统/查询可以挖掘出数以千计的模式, 并非所有的模式都是有趣的
 - 建议的方法: 以人为中心, 基于查询的, 聚焦的挖掘
- 兴趣度度量: 一个模式是 **有趣的** 如果它是 易于被人理解的, 在某种程度上在新的或测试数据上是有效的, 潜在有用的, 新颖的, 或验证了用户希望证实的某种假设
- 客观与主观的兴趣度度量:
 - 客观: 基于模式的统计和结构, 如, 支持度, 置信度, 等.
 - 主观: 基于用户对数据的确信, 如, 出乎意料, 新颖性, 可行动性(actionability), 等.


能够只发现有趣的模式吗？

- 发现所有有趣的模式：完全性
 - 数据挖掘系统能够发现所有有趣的模式吗？
 - 关联 vs. 分类 vs. 聚类
- 仅搜索有趣的模式：优化
 - 数据挖掘系统能够仅发现有趣的模式吗？
 - 方法
 - 首先找出所有模式，然后过滤掉不是有趣的那些.
 - 仅产生有趣的模式— 挖掘查询优化

大纲

- 为什么需要数据挖掘
- 什么是数据挖掘
- 可以挖掘什么类型的数据
- 可以挖掘出什么样的模式
- 在数据挖掘中应用了哪些技术 
- 数据挖掘带来了哪些应用
- 数据挖掘面临的问题
- 数据挖掘的发展
- 总结

数据挖掘: 多学科交叉



1. 统计学方法

- **统计学**是通过对数据进行收集、整理、分析和描述，来达到对研究对象本质的理解和表示。
- 在实际生活中，通常有一些过程无法通过理论分析直接获得模型，但可以通过直接或间接测量的方法获得描述目标对象的相关变量的具体数据，用来刻画这些变量之间关系的数学函数称为**统计模型**。

2. 机器学习


- **机器学习**主要研究计算机如何像人类学习知识那样自主地分析和处理数据，并作出智能的判断，并通过获得的新的知识对自身进行发展和完善。



MNIST数据集示例

- **机器学习方法**：包括监督学习、无监督学习、半监督学习等。
- **监督学习**需要在有标记的数据集上进行。

2. 机器学习




监督学习流程

2. 机器学习

- **无监督学习**：可以在没有标记的数据集上进行学习，实质上无监督学习是一个聚类过程。

2. 机器学习

- **半监督学习：**半监督学习主要考虑如何利用少量有标记的数据和大量未标记的数据来进行学习，其中标记的数据用来学习模型，而未标记的数据用来进一步改进类的边界。



半监督学习示例

3. 数据库与数据仓库


- **数据库系统**是为了解决数据处理方面的问题而建立起来的数据处理系统，注重于为用户创建、维护和使用数据库。
- **数据仓库**汇集了来自多个不同数据源的数据，通过数据仓库，可以在不同的维度合并数据，形成数据立方体，便于从不同的角度对数据进行分析 and 挖掘。

4. 模式识别

- **模式识别**的本质就是抽象出不同事物中的模式，并根据这些模式对事物进行分类或聚类的过程。
- **研究内容**：文字识别、语音识别、图像识别、医学诊断以及指纹识别等。

5. 高性能计算

- **高性能计算**是指突破单个计算机资源不足的限制，使用多个处理器或多台计算机共同完成同一项任务的计算环境。



大纲

- 为什么需要数据挖掘
- 什么是数据挖掘
- 可以挖掘什么类型的数据
- 可以挖掘出什么样的模式
- 在数据挖掘中应用了哪些技术
- 数据挖掘带来了哪些应用
- 数据挖掘面临的问题
- 数据挖掘的发展
- 总结



面向什么类型的应用—可能的应用

- 数据库分析和决策支持
 - 市场分析和管理的
 - 针对销售(**target marketing**), 顾客关系管理, 购物篮分析, 交叉销售(**cross selling**), 市场分割(**market segmentation**)
 - 风险分析与管理
 - 预测, 顾客关系, 改进保险, 质量控制, 竞争能力分析
 - 欺骗检测与管理
- 其它应用
 - 文本挖掘 (新闻组, **email**, 文档资料)
 - 流数据挖掘(**Stream data mining**)
 - **Web**挖掘
 - 生物信息学/生物 数据分析

市场分析与管理(1)

- 用于分析的数据源在哪？
 - 信用卡交易, 会员卡, 打折优惠券, 顾客投诉电话, (公共) 生活时尚研究
- 针对销售(**Target marketing**)
 - 找出顾客群, 他们具有相同特征: 兴趣, 收入水平, 消费习惯, 等.
- 确定顾客随时间变化的购买模式
 - 个人帐号到联合帐号的转变: 结婚, 等.
- 交叉销售分析(**Cross-market analysis**)
 - 产品销售之间的关联/相关
 - 基于关联信息的预测

市场分析与管理(2)

- 顾客分类(**Customer profiling**)
 - 数据挖掘能够告诉我们什么样的顾客买什么产品(聚类或分类)
- 识别顾客需求
 - 对不同的顾客识别最好的产品
 - 使用预测发现什么因素影响新顾客
- 提供汇总信息
 - 各种多维汇总报告
 - 统计的汇总信息 (数据的中心趋势和方差)

法人分析和风险管理

- 财经规划和资产评估
 - 现金流分析和预测
 - 临时提出的资产评估
 - 交叉组合(cross-sectional) 和时间序列分析 (金融比率(financial-ratio), 趋势分析, 等.)
- 资源规划：
 - 资源与开销的汇总与比较
- 竞争：
 - 管理竞争者和市场指导
 - 对顾客分类和基于类的定价
 - 在高度竞争的市场调整价格策略

欺骗检测和管理(1)

- 应用
 - 广泛用于健康照料，零售，信用卡服务，电讯（电话卡欺骗），等.
- 方法
 - 使用历史数据建立欺骗行为模型，使用数据挖掘帮助识别类似的实例
- 例
 - 汽车保险：检测这样的人，他/她假造事故骗取保险赔偿
 - 洗钱：检测可疑的金钱交易（US Treasury's Financial Crimes Enforcement Network）
 - 医疗保险：检测职业病患者，医生和介绍人圈

欺骗检测和管理(2)

- 检测不适当的医疗处置

- 澳大利亚健康保险会(Australian Health Insurance Commission) 发现许多全面的检查是请求做的, 而不是实际需要的 (每年节省100万澳元).

- 检测电话欺骗

- 电话呼叫模式: 通话距离, 通话时间, 每天或每周通话次数. 分析偏离期望的模式.
- 英国电讯(British Telecom) 识别频繁内部通话的呼叫者的离散群, 特别是移动电话, 超过数百万美元的欺骗.

- 零售

- 分析家估计, 38%的零售业萎缩是由于不忠诚的雇员造成的.

其它应用

- 运动
 - **IBM Advanced Scout**分析NBA的统计数据 (阻挡投篮, 助攻, 和犯规) 获得了对纽约小牛队(**New York Knicks**)和迈阿密热火队(**Miami Heat**)的竞争优势
- 天文
 - 借助于数据挖掘的帮助,**JPL** 和 **Palomar Observatory** 发现了**22** 颗类星体 (quasars)
- **Internet Web Surf-Aid**
 - **IBM Surf-Aid** 将数据挖掘算法用于有关交易的页面的**Web**访问日志, 以发现顾客喜爱的页面, 分析**Web** 销售的效果, 改进**Web** 站点的组织, 等.
- **Web:** 页面的分类、聚类、推荐/用户的访问模式

大纲

- 为什么需要数据挖掘
- 什么是数据挖掘
- 可以挖掘什么类型的数据
- 可以挖掘出什么样的模式
- 在数据挖掘中应用了哪些技术
- 数据挖掘带来了哪些应用
- 数据挖掘面临的问题
- 数据挖掘的发展
- 总结



数据挖掘的主要问题(1)

- 挖掘方法和用户交互
 - 在数据库中挖掘不同类型的知识
 - 结合背景知识
 - 数据挖掘结果的表示和可视化
 - 处理噪音和不完全数据
 - 模式评估：兴趣度问题
- 性能和可伸缩性 (scalability)
 - 数据挖掘算法的性能和可伸缩性
 - 并行，分布和增量的挖掘方法

数据挖掘的主要问题(2)

- 数据类型的多样性问题

- 处理关系的和复杂类型的数据
- 从异种数据库和全球信息系统 (WWW) 挖掘信息

- 应用和社会效果问题

- 发现知识的应用
 - 特定领域的数据挖掘工具
 - 智能查询回答
 - 过程控制和决策制定
- 发现知识与已有知识的集成：知识融合问题
- 数据安全，完整和私有的保护

大纲

- 为什么需要数据挖掘
- 什么是数据挖掘
- 可以挖掘什么类型的数据
- 可以挖掘出什么样的模式
- 在数据挖掘中应用了哪些技术
- 数据挖掘带来了哪些应用
- 数据挖掘面临的问题
- 数据挖掘的发展
- 总结



会议和期刊

- KDD Conferences

- ACM SIGKDD Int. Conf. on Knowledge Discovery in Databases and Data Mining (**KDD**)
- SIAM Data Mining Conf. (**SDM**)
- (IEEE) Int. Conf. on Data Mining (**ICDM**)
- European Conf. on Machine Learning and Principles and practices of Knowledge Discovery and Data Mining (**ECML-PKDD**)
- Pacific-Asia Conf. on Knowledge Discovery and Data Mining (**PAKDD**)
- Int. Conf. on Web Search and Data Mining (**WSDM**)

- Other related conferences

- DB conferences: ACM SIGMOD, VLDB, ICDE, EDBT, ICDT, ...
- Web and IR conferences: WWW, SIGIR, WSDM
- ML conferences: ICML, NIPS
- PR conferences: CVPR,

- Journals

- Data Mining and Knowledge Discovery (DAMI or DMKD)
- IEEE Trans. On Knowledge and Data Eng. (TKDE)
- KDD Explorations
- ACM Trans. on KDD

Where to Find References? DBLP, CiteSeer, Google

- Data mining and KDD (SIGKDD)
 - Conferences: ACM-SIGKDD, IEEE-ICDM, SIAM-DM, PKDD, PAKDD, etc.
 - Journal: Data Mining and Knowledge Discovery, KDD Explorations, ACM TKDD
- Database systems (SIGMOD)
 - Conferences: ACM-SIGMOD, ACM-PODS, VLDB, IEEE-ICDE, EDBT, ICDT, DASFAA
 - Journals: IEEE-TKDE, ACM-TODS/TOIS, JIIS, J. ACM, VLDB J., Info. Sys., etc.
- AI & Machine Learning
 - Conferences: Machine learning (ML), AAAI, IJCAI, COLT (Learning Theory), CVPR, NIPS, etc.
 - Journals: Machine Learning, Artificial Intelligence, Knowledge and Information Systems, IEEE-PAMI, etc.
- Web and IR
 - Conferences: SIGIR, WWW, CIKM, etc.
 - Journals: WWW: Internet and Web Information Systems,
- Statistics
 - Conferences: Joint Stat. Meeting, etc.
 - Journals: Annals of statistics, etc.
- Visualization
 - Conference proceedings: CHI, ACM-SIGGraph, etc.
 - Journals: IEEE Trans. visualization and computer graphics, etc.

大纲

- 为什么需要数据挖掘
- 什么是数据挖掘
- 可以挖掘什么类型的数据
- 可以挖掘出什么样的模式
- 在数据挖掘中应用了哪些技术
- 数据挖掘带来了哪些应用
- 数据挖掘面临的问题
- 数据挖掘的发展
- 总结



Summary

- 数据挖掘: 从大量数据中发现有趣的模式
- 数据库技术的自然进化, 具有巨大需求和广泛应用
- **KDD** 过程包括数据清理, 数据集成, 数据选择, 变换, 数据挖掘, 模式评估, 和知识表示
- 挖掘可以在各种数据存储上进行
- 数据挖掘功能: 特征, 区分, 关联, 分类, 聚类, 孤立点 和趋势分析, 等.
- 数据挖掘的应用
- 数据挖掘的主要问题

Recommended Reference Books

- Charu C. Aggarwal, *Data Mining: The Textbook*, Springer, 2015
- E. Alpaydin. *Introduction to Machine Learning*, 2nd ed., MIT Press, 2011
- R. O. Duda, P. E. Hart, and D. G. Stork, *Pattern Classification*, 2ed., Wiley-Interscience, 2000
- U. Fayyad, G. Grinstein, and A. Wierse, *Information Visualization in Data Mining and Knowledge Discovery*, Morgan Kaufmann, 2001
- J. Han, M. Kamber, and J. Pei, *Data Mining: Concepts and Techniques*. Morgan Kaufmann, 3rd ed. , 2011
- T. Hastie, R. Tibshirani, and J. Friedman, *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*, 2nd ed., Springer, 2009
- T. M. Mitchell, *Machine Learning*, McGraw Hill, 1997
- P.-N. Tan, M. Steinbach and V. Kumar, *Introduction to Data Mining*, Wiley, 2005 (2nd ed. 2016)
- I. H. Witten and E. Frank, *Data Mining: Practical Machine Learning Tools and Techniques with Java Implementations*, Morgan Kaufmann, 2nd ed. 2005
- Mohammed J. Zaki and Wagner Meira Jr., *Data Mining and Analysis: Fundamental Concepts and Algorithms* 2014