

数据仓库与数据挖掘

Data warehouse and data mining


丁钰

yuding@njau.edu.cn

南京农业大学人工智能学院

第二章：了解数据

Chapter 2: 了解数据

- 数据对象和属性类型 
- 数据的基本统计描述
- 数据可视化
- 测量数据相似性和相异性
- 总结

数据集的类型: (1) 记录数据

- 关系记录
 - Relational tables, highly structured
- 数据矩阵, e.g., 数值矩阵, 交叉表


	China	England	France	Japan	USA	Total
Active Outdoors Crochet Glove		12.00	4.00	1.00	240.00	257.00
Active Outdoors Lycra Glove		10.00	6.00		323.00	339.00
InFlux Crochet Glove	3.00	6.00	8.00		132.00	149.00
InFlux Lycra Glove		2.00			143.00	145.00
Triumph Pro Helmet	3.00	1.00	7.00		333.00	344.00
Triumph Vertigo Helmet		3.00	22.00		474.00	499.00
Xtreme Adult Helmet	8.00	8.00	7.00	2.00	251.00	276.00
Xtreme Youth Helmet		1.00			76.00	77.00
Total	14.00	43.00	54.00	3.00	1,972.00	2,086.00

Person:

Pers_ID	Surname	First_Name	City
0	Miller	Paul	London
1	Ortega	Alvaro	Valencia
2	Huber	Urs	Zurich
3	Blanc	Gaston	Paris
4	Bertolini	Fabrizio	Rom

Car:

Car_ID	Model	Year	Value	Pers_ID
101	Bentley	1973	100000	0
102	Rolls Royce	1965	330000	0
103	Peugeot	1993	500	3
104	Ferrari	2005	150000	4
105	Renault	1998	2000	3
106	Renault	2001	7000	3
107	Smart	1999	2000	2



- 事务数据


TID	Items
1	Bread, Coke, Milk
2	Beer, Bread
3	Beer, Coke, Diaper, Milk
4	Beer, Bread, Diaper, Milk
5	Coke, Diaper, Milk

	team	coach	ply	ball	score	game	n	lost	timeout	season
Document 1	3	0	5	0	2	6	0	2	0	2
Document 2	0	7	0	2	1	0	0	3	0	0
Document 3	0	1	0	0	1	2	2	0	3	0



- 文档数据: 文本文档:词频向量term-frequency vector

数据集合的类型: (2) Graphs and Networks

- 传输网络
- 广域互联网




- 分子结构
- 社交网络、信息网络



数据集合的类型: (3) Ordered Data

- 视频: 图片的序列
- 时间数据: 时间序列



- 序列数据: 交易序列
- 遗传序列数据



Start

Human	GT TTTGAGG -- ATG T T C A A C A A A T G C T C C T T T C A T T C C T C T A T T T A C A G A C C T G C C G C A
Chimpanzee	GT TTTGAGG -- ATG T T C A A T A A A T G C T G C T T T C A C T C C T C T A T T T A C A G A C C T G C C G C A
Macaque	GT TTTGAGG -- ATG C T C A A T A A A T G C T C C T T T C A T T C C C A T T T A C A A A C T T G C C G C A
Human	G A C A A T T C T G C T A G C A G C C T T T G T G C T A T T A T C T G T T T T C T A A A C T T A G T A A T T G A G T G T
Chimpanzee	G A C A A T T C T G C T A G C A G C C T T T G T G C T A T T A T C T G T T T T C T A A A C T T A G T A A T T G A G T G T
Macaque	G A C A A T T C T G C T A G C A G C C T T T G T G C T A T T A T C T G T T T T C T A A A C T T A G T A A T T G A G T G T
Human	G A T C T G G A G A C T A A - C T C T G A A A T A A A T A A G C T G A T T A T T T A T T T T C T C A A A A C A A
Chimpanzee	G A T C T G G A G A C T A A A C T C T G A A A T A A A T A A G C T G A T T A T T T A T T T T C T C A A A A C A A
Macaque	T A T C T G G A G A C T A A A C T C T G A A A T A A A T A A G C T G A T T A T T T A T T T T C T C A A A A C A A
Human	C A G A A T A C G A T T T A G C A A A T T A C T T C T T A A G A T A T T A T T T T A C A T T T C T A T A T T C T C C T A
Chimpanzee	C A G A A T A C G A T T T A G C A A A T T A C T T C T T A A G A T A C T A T T T T A C A T T T C T A T A T T C T C C T A
Macaque	C A G A A T A T G A T T T A G C A A A T T A C C T C T T A A G A T A T T A T T T T G C A C T T C T A T A T T C T C C T A
Human	C C C T G A G T T G A T G T G T G A G C A A T A T G T C A C T T T C A T A A A G C C A G G T A T A C A - - - - T T A T G
Chimpanzee	C C C T G A G T T G A T G T G T G A G C G T A T G T C A C T T T C A T A A A G C C A G G T A T A C A - - - - T T A T G
Macaque	C C C T G A G T T G A T G T G T G A G C A A T A T G T C A C T T C C A C A A A G C C A G G T A T A T A T A C A T T A C G
Human	G A C A G G T A A G T A A A A A A C A T A T T A T T T A T T C T A C G T T T T T G T C C A A A A A A T T T T A A A T T T C
Chimpanzee	G A C A G G T A A G T A A A A A A C A T A T T A T T T A T T C T A C G T T T T T G T C C A A A A A A T T T T A A A T T T C
Macaque	G A C A G G T A A G T A A A A A - C A T A T T A T T T A T T C T A G G T T T T T G T C C A A A G A G T T T T A A A T T T C
Human	A A C T G T T G C G C G T G T G T T G G T A A - - - - T G T A A A A C A A A C T C A G T A C A
Chimpanzee	A A C T G T T G C G C G T G T G T T G G T A A - - - - T G T A A A A C A A A C T C A G T A C A
Macaque	A A C T G T T G T G C A T G T G T T G G T A A - - - - C B T A A A A C A A A T T C A G T A C G


数据集的类型: (4) 空间, 图像与多媒体数据

- 空间数据: 地图



- 图像数据:

- 视频数据:



数据对象

- 数据集由数据对象构成
- 一个数据对象代表一个实体
- 例子:
 - 销售数据库sales database:客户/顾客,商店物品, sales
 - 医学数据库: patients, treatments
 - 大学数据库: students, professors, courses
- 又称为 样本, 事例, 实例, 数据点, 对象, 元组*tuples*.
- 数据对象由属性来描述
- Database rows -> data objects; columns -> attributes.

属性

- 属性Attribute (or维度, 特征, 变量): 一个数据字段, 表示一个数据对象的某个特征.
 - *E.g., customer_ID, name, address*
- 类型(由该属性可能具有的值的集合决定):
 - 标称的(e.g., red, blue)
 - 二元的(e.g., {true, false})
 - 序数的(e.g., {freshman, sophomore, junior, senior})
 - 数值的
 - 区间标度属性: 100°C is interval scales
 - 比率标度属性: 100°K is ratio scaled since it is twice as high as 50°K

属性类型

- 标称:类别,状态, or “名目” 一些符号或事物的名称, 不必具有有意义的序。(枚举)
 - 每个值代表某种类别、编码或状态, 没有数学计算的意义
 - *Hair_color* = {auburn, black, blond, brown, grey, red, white}
 - 婚姻状态, 职业occupation, ID numbers, zip codes
- 二元: 一种特殊的标称属性
 - 只有2个状态的标称属性 (0 and 1)
 - 对称二元: 同样重要的两相
 - e.g., 性别
 - 非对称: 非同等重要
 - e.g., 医疗检查 (positive vs. negative)
 - 惯例Convention: assign 1 to most important outcome (e.g., COVID-19 positive)
- 序数的 Ordinal
 - 值有一个有意义的顺序(排序) 但连续值之间的大小未知.
 - *Size* = {small, medium, large}, 等级, 军阶
- 标称、二元和序数属性都是定性的
 - 代表类别的计算机编码, 而不是可测量的值

数值属性的类型


- 数量Quantity：可度量的量(integer or real-valued) 定量的，用整数或实数值表示
- 区间标度属性
 - 相等的单位尺度度量
 - 值有序 可以为正、零、负，可以评估值之间的差，不能评估倍数。
 - E.g., *temperature in C° or F°, calendar dates*
 - 没有真正的零点
- 比率标度属性
 - 具有固有零点的数值属性
 - 可以评估值之间的差，可以讲一个值是另一个值倍数(10 K° is twice as high as 5 K°).
 - e.g. 长度, 计数, 货币的数量

离散 vs. 连续属性

- 离散属性
 - 一个有限的或可数无限集值
 - E.g., zip codes, the set of words in a collection of documents
 - 可以用或不用整数表示
 - 注: 二元属性是离散属性的一个特殊情况
- 连续属性
 - 属性值为实数
 - E.g., temperature, height, or weight
 - 实际上, 实值只能使用有限的数字进行测量和表示
 - 连续属性通常表示为浮点变量

Chapter 2: 了解数据

- 数据对象和属性类型
- 数据的基本统计描述
- 数据可视化
- 测量数据相似性和相异性
- 总结



度量数据的中心趋势: (1) 均值

- 均值 (代数度量) (样本 vs. 总体):

Note: n 样本大小, N 总体大小.


$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$


$$\mu = \frac{\sum x}{N}$$

- 加权算术均值:


$$\bar{x} = \frac{\sum_{i=1}^n w_i x_i}{\sum_{i=1}^n w_i}$$

- 截断均值:

- 去掉高低极端值(e.g., 奥运会体操得分计算)

度量数据的中心趋势: (2)中位数

- 中位数:
 - 奇数则为有序集的中间值, 否则为中间两个数的平均
- (基于分组数据)可以插值估计:

	<i>age</i>	<i>frequency</i>
	1-5	200
	6-15	450
	16-20	300
Median interval →	21-50	1500
	51-80	700
	81-110	44

近似中位数

整个数据集中值的个数

低于中位数区间的所有区间的频率和

中位数区间的下界

中位数区间的宽度($L_2 - L_1$)

$$median = L_1 + \left(\frac{n/2 - (\sum freq)_l}{freq_{median}} \right) width$$


度量数据的中心趋势: (3) 众数 (Mode)

- 出现频率最高的值(不惟一/每个值出现一次则没有)

- 单峰的 (Unimodal)


- 经验关系:

$$mean - mode = 3 \times (mean - median)$$





- 多峰的

- 双峰的





- 三峰的



对称/偏斜数据


- 中位数, 均值, 众数: 对称, 正倾斜和负倾斜数据



正态分布曲线的性质

- 正态分布曲线

- $[\mu - \sigma, \mu + \sigma]$: 含有约68%的测量(μ : 均值, σ : 标准差)
- $[\mu - 2\sigma, \mu + 2\sigma]$: contains about 95% of it
- $[\mu - 3\sigma, \mu + 3\sigma]$: contains about 99.7% of it



数据分散度量: 方差和标准差

- 方差/标准差 (样本: s , 总体: σ)
 - 方差 **Variance**: (代数度量, 可伸缩计算)

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2 = \frac{1}{n-1} \left[\sum_{i=1}^n x_i^2 - \frac{1}{n} \left(\sum_{i=1}^n x_i \right)^2 \right]$$

$$\sigma^2 = \frac{1}{N} \sum_{i=1}^n (x_i - \mu)^2 = \frac{1}{N} \sum_{i=1}^n x_i^2 - \mu^2$$

- 标准差 **Standard deviation** s (or σ) 方差的平方根 s^2 (or σ^2)

数据分散度量：方差和标准差


例：有学生考试成绩的值：60, 45, 33, 77, 80, 100, 100, 90, 70, 65。

$$\sigma^2 = \frac{1}{10} \times (60^2 + 45^2 + 33^2 + 77^2 + 80^2 + 100^2 + 100^2 + 90^2 + 70^2 + 65^2) - 72^2 = 442.8$$

标准差: $\sigma = \sqrt{442.8} \approx 21.04$

数据分散度量：分位数

- **分位数 (Quantile)**：取自数据分布的每隔一定间隔上的点，把数据划分成基本上大小相等的连贯集合。




某变量X的数据统计描述显示

- 给定数据分布的第 k 个 q -分位数的值为 x ，使得小于 x 的数据值最多为 k/q ，而大于 x 的数据值最多为 $(q-k)/q$ ，其中 k 是整数，使得 $0 < k < q$ 。这里有 $q-1$ 个 q -分位数。

数据分散度量：四分位数

- **四分位数 (Quantile)**：把数据分布划分成4个相等的部分，使得每部分表示数据分布的四分之一。这3个数据点称为四分位数。



某变量X的数据统计描述显示

- Q_1 ：“下四分位数”； Q_2 ：“中位数”； Q_3 ：“上四分位数”。

数据分散度量：四分位数极差

– 四分位数极差（InterQuartile Range, IQR）：Q1和Q3之间的距离。

$$IQR = Q_3 - Q_1 \quad (2)$$


确定四分位数的位置：

$$Q1 \text{ 的位置} = (n+1)/4 = (n+1) \times 0.25$$

$$Q2 \text{ 的位置} = 2 \times (n+1)/4 = (n+1) \times 0.5$$

$$Q3 \text{ 的位置} = 3 \times (n+1)/4 = (n+1) \times 0.75$$

n表示项数



某变量X的数据统计描述显示

数据分散度量：四分位数极差

– 四分位数极差 (InterQuartile Range, IQR) : Q1和Q3之间的距离。

$$IQR = Q_3 - Q_1 \quad (2)$$

例：由8人组成的旅游小团队年龄分别为：17, 19, 22, 24, 25, 28, 34, 37, 求其年龄的四分位差。

①计算Q1与Q3的位置：

Q1的位置 $= (n+1)/4 = (8+1)/4 = 2.25$ ； Q3的位置 $= 3*(n+1)/4 = 3*(8+1)/4 = 6.75$

②确定Q1与Q3的数值：


Q1 $= 19 + (22-19) * 0.25 = 19.75$ ； Q3 $= 28 + (34-28) * 0.75 = 32.5$

③计算四分位差：

IQR $= Q3 - Q1 = 32.5 - 19.75 = 12.75$


盒图（又称箱线图，Box-plot）

- 盒图（又称箱线图，Box-plot），是一种用来描述数据分布的统计图形，可以表现观测数据的中位数、四分位数和极值等描述性统计量。
 - 用盒子表示数据
 - 盒子的端点在四分位数上，使得盒子长度为四分位数极差IQR
 - 中位数用盒内线标记
 - 盒子外线延伸到最小和最大的观测值
 - 离群点：绘制在离群阈值范围外的点




盒图（又称箱线图，Box-plot）

- 盒图（又称箱线图，Box-plot），是一种用来描述数据分布的统计图形，可以表现观测数据的中位数、四分位数和极值等描述性统计量。
- 五数概括：min, Q1, median, Q3, max
- 盒图：分布直观表示，体现五数概括
- 离群点：第三个四分位数之上或者第一个四分位数之下至少 $1.5 \times \text{IQR}$ 的值



可视化数据的离散度: 3-D Boxplots




基本统计说明的图形显示

- **Boxplot** : 五数概括的图形
- **Histogram**直方图: 值x-axis, y-axis表示频率
- **Quantile plot**分位数图: 值 x_i 与 f_i (表明近似百分之 f_i 的数据 $\leq x_i$)成对
- **Quantile-quantile (q-q) plot** : 对着另一个分位数, 绘制一个单变量分布的分位数
- **Scatter plot**散布图: 每个值对 为一个坐标点绘于平面上

直方图分析

- **Histogram:** 图形显示每个列值的频率，表示频率分布
- x-axis 表示数值大小, y-axis 表示频率

例：使用直方图表示学生数学成绩的分布




学生成绩数据频率直方图

学生数学成绩

学号	成绩
701	60
702	71
703	56
704	99
705	66
706	90
707	100
708	66
709	77
710	60
711	88
712	79
713	83
714	55


Histograms Often Tell More than Boxplots



- 直方图中包含了boxplot能表示的信息
 - 上图的五数概括是一样的: **min, Q1, median, Q3, max**
- 直方图还能表现数据的分布情况


分位数图Quantile Plot

- 显示所有数据 (允许用户评估全部行为和不寻常的事件)
- Plots **quantile** information
 - 对于升序中的值点(x_i, f_i)表明近似百分之 f_i 的数据 $\leq x_i$; 成对绘制(x_i, f_i)





分位数-分位数图 (Q-Q图)

- 对着另一个分位数，绘制一个单变量分布的分位数
- 观察:正从一种分布到另一种是否有偏移?
- 例子表示分店1出售的物品单价 **vs.** 分店 2 的每个分位数.分店 1 出售的物品单价 倾向于低于分店2.






散布图Scatter plot



- 提供双变量数据的第一印象：点聚集，离群点，等
- 每个值对作为一个坐标点绘于平面上



正/负 相关数据




不相关的数据



Chapter 2: 了解数据

- 数据对象和属性类型
- 数据的基本统计描述
- 数据可视化
- 测量数据相似性和相异性
- 总结




数据可视化


- **Why data visualization?**（用图形清晰有效的表示数据）
 - 把数据映射到图形信息空间中获取视角
 - 提供定性的概述(大数据集的)
 - 在数据中搜寻 模式, 趋势, 结构, 不规则, 关联
 - 为进一步的量化分析发现有意义的区域及合时的参数
 - 为衍生的计算机表示提供一个视觉证据
- 可视化方法的分类:
 - 基于像素的可视化技术
 - 几何投影可视化技术
 - 基于图符的可视化技术
 - 层次可视化技术
 - 可视化复杂对象数据和关系

基于像素的可视化技术


- 对一个维度 m 的数据，在屏幕上产生 m 个窗口,每个维度一个。
- 一个记录的 m 维度值被匹配到窗口中对应位置的 m 个像素上
- 像素的颜色值反映了相应的值




(a) Income



(b) 信用限额




(c) 交易额




(d) age

安排像素于圆弧片断

- 为节省空间并显示多个维度间的联系,往往是以一个弧形片段填充空间




Representing about 265,000 50-dimensional Data Items
with the 'Circle Segments' Technique



(b) Laying out pixels in circle segment


像素图的例子



几何投影可视化技术


- 可视化数据的几何变换和投影
- 方法
 - 直接可视化
 - 散点图和散点图矩阵
 - 投影捕获技术: 帮助用户发现有意义的投影（多维数据上）
 - 解剖视角
 - **sections, i.e., intersections of subspaces with a highdimensional object, can easily display structure of only low codimension**
 - 平行坐标

散点图矩阵



- 散点图矩阵是散点图的一种有用扩充。对于n维数据集，散点图矩阵是二维散点图的 $n \times n$ 网格，提供每个维与所有其他维的可视化。
- 鸢尾花数据集由450个样本组成，取自三种鸢尾花，该数据集有5个维：萼片长度和宽度、花瓣长度和宽度，以及种属

地形/景观




- Visualization of the data as perspective landscape
- The data needs to be transformed into a (possibly artificial) 2D spatial representation which preserves the characteristics of the data


news articles visualized as a landscape

平行坐标

- 对应于属性的 n 个等距、相互平行的轴
- 这些轴缩放到[最小值, 最大值]: 相应的属性范围
- 每个数据项对应于一折线, 属性轴的对应取值点处相交



一个数据集的平行坐标



- 不能有效地显示具有很多记录的数据集，视觉上的簇和重叠常常降低可视化的可读性，使得很难发现模式。


基于图符的可视化技术

- 以图标特征可视化数据值
- 典型的可视化方法
 - 切尔诺夫脸谱
 - 人物线条画
- 常用技术
 - **形状编码 Shape coding:** 使用形状来表示特定信息的编码
 - **颜色图标 Color icons:** 使用颜色图标编码更多的信息
 - **瓦片条形图 Tile bars:** 在文档检索中使用小图标代表相关特征向量


切尔诺夫脸谱图

- 一种在二维空间显示变量的方法,如设 X 眉倾斜, Y 是眼睛大小, Z 是鼻子长度等
- 图中的面孔使用**10**个特点产生-头离心率, 眼睛大小, 眼间距, 眼离心率, 瞳孔大小, 斜眉, 鼻大小, 嘴形, 嘴的大小, 张口程度: **Each assigned one of 10 possible values, generated using [Mathematica](#) (S. Dickson)**

- REFERENCE: Gonick, L. and Smith, W. [The Cartoon Guide to Statistics](#). New York: Harper Perennial, p. 212, 1993
- Weisstein, Eric W. "Chernoff Face." From *MathWorld*--A Wolfram Web Resource. mathworld.wolfram.com/ChernoffFace.html




人物线条画



人口普查数据
图显示年龄、
收入、性别、
教育、等


一个**5-piece**棍
棒图(身体和四
肢)，两个属性
映射到轴，其余
的属性映射到角
度或肢体长度

维数堆叠 Dimensional Stacking



- 把n维属性空间剖分为2-D子空间，互相堆叠与一起
- 属性值的范围划分为等级，重要的属性分布在外层.
- 适合次序属性较少的数据
- 超过9个维度时显示困难
- 重要的是匹配维度适当


维数堆叠 Dimensional Stacking



可视化石油勘探数据，经度和纬度映射到外x-, y轴，油质和深度映射到内部x-, y-轴


Worlds-within-Worlds

- 分配功能f和两个重要参数给内部世界
- 固定其他参数 - draw other (1 or 2 or 3 世界选择他们为坐标轴)
- 使用这种模式的软件
- N-vision:通过数据手套和立体显示以动态互动，包括旋转，缩放（内部）和转换（内/外）
- 自动视觉：经查询手段静态互动




树状图Tree-Map

- 屏幕填充方法：依赖于属性值把 屏幕层次划分为区域
- 根据属性值（类）屏幕的x-y-维交替剖分




MSR Netscan Image



Tree-Map of a File System



InfoCube

- **3-D可视化技术**: 层次信息被显示成嵌套的半透明立方体
- 最外层的立方体对应顶层数据, 子节点**or**低层数据作为稍小的立方体显示于外层立方体中, 以此类推



3d锥树 Three-D Cone Trees

- **3D cone tree** 可用于数千个节点
- 先构造 **2D 环形树**，安排节点于根节点为中心的同心圆环
- 投影到2维时将不可避免重叠
- **G. Robertson, J. Mackinlay, S. Card. "Cone Trees: Animated 3D Visualizations of Hierarchical Information", ACM SIGCHI'91**
- **Graph from Nadeau Software Consulting website:** 可视化社会网络数据：模型感染从一个人到下一个扩散的方式



- Visualizing non-numerical data: text and social networks
- Tag cloud: visualizing user-generated tags

- The importance of tag is represented by font size/color
- Popularly used to visualize word/phrase distributions




KDD 2013 Research Paper Title Tag Cloud




Newsmap: Google News Stories in 2005

可视化复杂数据和关系：社交网络


- Visualizing non-numerical data: **social and information networks**



A typical network structure




A social network



Chapter 2: 了解数据

- 数据对象和属性类型
- 数据的基本统计描述
- 数据可视化
- 测量数据相似性和相异性
- 总结



相似性和相异性

- 相似性
 - 数值测量两个数据对象类似程度
 - 目标越相似时值越大
 - 通常介于 $[0,1]$: 0: 不相似; 1: 完全相似
- 相异性(e.g., 距离distance)
 - 数值测量两个数据对象差异程度
 - 对象越相近值越小
 - 最小相异性值通常为 0(i.e., completely similar)
 - 上界可变Range $[0, 1]$ or $[0, \infty)$
- 相似性和相异性都称为邻近性

数据矩阵和相异度矩阵

■ 数据矩阵

- n 个对象对 p 个属性
- 行代表对象，列代表属性
- 二模（行-代表对象、列-代表属性）

$$\begin{bmatrix} x_{11} & \cdots & x_{1f} & \cdots & x_{1p} \\ \vdots & \vdots & \vdots & \vdots & \vdots \\ x_{i1} & \cdots & x_{if} & \cdots & x_{ip} \\ \vdots & \vdots & \vdots & \vdots & \vdots \\ x_{n1} & \cdots & x_{nf} & \cdots & x_{np} \end{bmatrix}$$

Handwritten red annotations: An arrow points from the text '列代表属性' to the matrix columns. A red 'X' is written to the right of the matrix.


■ 相异性矩阵

- n 个对象之间的距离
- 三角矩阵
- 单模

$$\begin{bmatrix} 0 & d(1,2) & \cdots & \cdots & \cdots \\ d(2,1) & 0 & \cdots & \cdots & \cdots \\ d(3,1) & d(3,2) & 0 & \cdots & \cdots \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ d(n,1) & d(n,2) & \cdots & \cdots & 0 \end{bmatrix}$$

Handwritten red annotations: 'd(1,2)' is written above the matrix. 'd(2,1)' is underlined in the second row. A double slash is written between the first two rows.

Example: Data Matrix and Dissimilarity Matrix



Data Matrix

point	attribute1	attribute2
<u>$x1$</u>	1	2
$x2$	3	5
$x3$	2	0
$x4$	4	5

Dissimilarity Matrix (by 欧氏距离 Euclidean Distance)

	$x1$	$x2$	$x3$	$x4$
$x1$	0			
$x2$	3.61	0		
$x3$	2.24	5.1	0	
$x4$	4.24	1	5.39	0

标称属性的邻近度量

- 2个或多个状态, e.g., red, yellow, blue, green (二元属性的推广)

- Method 1: 简单匹配

- m : p 个变量中匹配的个数, p : 全部变量的个数

$$\underline{d(i, j) = \frac{p - m}{p}}$$

- Method 2: 使用一系列的二进制属性

- 为M个名义状态的每一个产生一个新的二进制/二元属性

Method 1: 简单匹配

$$\frac{p-m}{p} = 1 - \frac{m}{p}$$

例：计算标称属性的相异性矩阵

标称属性数据

对象标识符	Test
1	A
2	B
3	C
4	A

相异性计算：

$$d(2,1) = 1 - \frac{0}{1} = 1$$

$$d(3,1) = 1 - \frac{0}{1} = 1$$

$$d(3,2) = 1 - \frac{0}{1} = 1$$

$$d(4,1) = 1 - \frac{1}{1} = 0$$

$$d(4,2) = 1 - \frac{0}{1} = 1$$

$$d(4,3) = 1 - \frac{0}{1} = 1$$

相异性矩阵：

$$\begin{bmatrix} 0 & & & \\ 1 & 0 & & \\ 1 & 1 & 0 & \\ 0 & 1 & 1 & 0 \end{bmatrix}$$

二元属性的邻近度量

- 二元数据的列联表:

		Object j		
		1	0	sum
Object i	1	q	r	$q + r$
	0	s	t	$s + t$
sum		$q + s$	$r + t$	p

- 对称二元变量的距离测度:

$$d(i, j) = \frac{r + s}{q + r + s + t}$$

- 不对称二元变量的距离测度:

$$d(i, j) = \frac{r + s}{q + r + s}$$

- Jaccard系数（不对称二元变量的相似性测度）:

$$\text{sim}_{\text{Jaccard}}(i, j) = \frac{q}{q + r + s}$$

- 注: Jaccard 系数与相干系数一致

$$\text{coherence}(i, j) = \frac{\text{sup}(i, j)}{\text{sup}(i) + \text{sup}(j) - \text{sup}(i, j)} = \frac{q}{(q + r) + (q + s) - q}$$

二元属性的相异度量

Example

Name	Gender	Fever	Cough	Test-1	Test-2	Test-3	Test-4
Jack	M	Y	N	P	N	N	N
Mary	F	Y	N	P	N	P	N
Jim	M	Y	P	N	N	N	N

- 性别是对称属性
- 其余的属性是非对称属性
- 令Y和P值为1, 且N值为0
- 距离:

$$d(i, j) = \frac{r + s}{q + r + s}$$

$$d(\text{jack}, \text{mary}) = \frac{0 + 1}{2 + 0 + 1} = 0.33$$

$$d(\text{jack}, \text{jim}) = \frac{1 + 1}{1 + 1 + 1} = 0.67$$

$$d(\text{jim}, \text{mary}) = \frac{1 + 2}{1 + 1 + 2} = 0.75$$

Mary

	1	0	Σ_{row}
1	2	0	2
0	1	3	4
Σ_{col}	3	3	6

Jack

Jim

	1	0	Σ_{row}
1	1	1	2
0	1	3	4
Σ_{col}	2	4	6

Jack

Mary

	1	0	Σ_{row}
1	1	1	2
0	2	2	4
Σ_{col}	3	3	6

Jim

数值数据的距离: 闵可夫斯基距离

- 闵可夫斯基 (*Minkowski*) 距离: 一种流行的距离测度

$$d(i, j) = \sqrt[h]{|x_{i1} - x_{j1}|^h + |x_{i2} - x_{j2}|^h + \cdots + |x_{ip} - x_{jp}|^h}$$

其中 $i = (x_{i1}, x_{i2}, \dots, x_{ip})$ 、 $j = (x_{j1}, x_{j2}, \dots, x_{jp})$ 为两个 p -维数据点;

h 是阶数 (定义的距离又称为 L_h 范数)

- 特性
 - 非负性: $d(i, j) \geq 0$ if $i \neq j$,
 - 同一性: $d(i, i) = 0$ (正定 Positive definiteness)
 - 对称性: $d(i, j) = d(j, i)$ (Symmetry)
 - 三角不等式: $d(i, j) \leq d(i, k) + d(k, j)$
- 满足上述属性的称为度量 (metric)

闵可夫斯基距离特殊形式

- $h = 1$: 曼哈顿 (**Manhattan**) 距离 (L1范数) 又称城市块距离。

- E.g., 汉明距离: 两个向量中不同的bit数

$$d(i, j) = |x_{i_1} - x_{j_1}| + |x_{i_2} - x_{j_2}| + \dots + |x_{i_p} - x_{j_p}|$$

- $h = 2$: 欧式 (**Euclidean**) 距离 (L₂ 范数) 又称直线距离。

$$d(i, j) = \sqrt{(|x_{i_1} - x_{j_1}|^2 + |x_{i_2} - x_{j_2}|^2 + \dots + |x_{i_p} - x_{j_p}|^2)}$$


- $h \rightarrow \infty$: 上确界 (**Supremum**) 距离 (L_{max} 范数或L_∞范数) 切比雪夫距离

- 两个向量属性差绝对值的最大值

$$d(i, j) = \lim_{h \rightarrow \infty} \left(\sum_{f=1}^p |x_{if} - x_{jf}|^h \right)^{\frac{1}{h}} = \max_f^p |x_{if} - x_{jf}|$$

Example: Minkowski Distance

point	attribute 1	attribute 2
x1	1	2
x2	3	5
x3	2	0
x4	4	5



Manhattan (L_1)

Dissimilarity Matrices

L	x1	x2	x3	x4
x1	0			
x2	5	0		
x3	3	6	0	
x4	6	1	7	0

Euclidean (L_2)

L2	x1	x2	x3	x4
x1	0			
x2	3.61	0		
x3	2.24	5.1	0	
x4	4.24	1	5.39	0

Supremum

L_∞	x1	x2	x3	x4
x1	0			
x2	3	0		
x3	2	5	0	
x4	3	1	5	0

有序变量 Ordinal Variables

- 一个序数属性可以是离散的或连续的
- 序数属性的顺序是有用信息, e.g., 排序 (freshman, sophomore, junior, senior)
 - 类似于连续数值的离散化结果

0 1/3 2/3 1
1 2 3 4

- 用它们的序代替 x_{if} $r_{if} \in \{1, \dots, M_f\}$
- 映射每一个变量的范围于 [0,1], 用如下支代替第 f -th 变量的 i -th 对象

$$z_{if} = \frac{r_{if} - 1}{M_f - 1}$$

$\frac{1-1}{4-1} = 0$

- Example: freshman: 0; sophomore: 1/3; junior: 2/3; senior 1
 - Then distance: $d(\text{freshman}, \text{senior}) = 1$, $d(\text{junior}, \text{senior}) = 1/3$
- 距离计算方法与数值属性一致

混合型属性

- 实际处理的数据集可能会包含所有类型的属性
 - 标称属性, 对称二元属性, 非对称二元属性, 数值属性, 序数属性

- 可以用加权法计算合并的影响 $d(i, j) = \frac{\sum_{f=1}^p \delta_{ij}^{(f)} d_{ij}^{(f)}}{\sum_{f=1}^p \delta_{ij}^{(f)}}$

- f 是二进制或标称:

$$d_{ij}^{(f)} = 0 \text{ if } x_{if} = x_{jf}, \text{ or } d_{ij}^{(f)} = 1 \text{ otherwise}$$

- f 是数值: 使用归一化的距离

- f 序数属性

- 计算序号 r_{if}
- 把 z_{if} 作为数值属性对待

$$z_{if} = \frac{r_{if} - 1}{M_f - 1}$$

余弦相似性 Cosine Similarity

- 余弦相似性 (又称余弦相似度, Cosine Similarity) : 是基于向量的, 它利用向量空间中两个向量夹角的余弦值作为衡量两个个体间差异的大小。
- 余弦相似性: 若 d_1 和 d_2 是两个向量 (e.g., 词频向量), 那么余弦属性定义为:

$$\cos(d_1, d_2) = (d_1 \bullet d_2) / (\|d_1\| \|d_2\|)$$


其中 “ $\bullet$ ” 表示向量点乘, $\|d\|$: 向量的长度 d

$\|x\|$ 是向量 $x = (x_1, x_2, \dots, x_p)$ 的欧几里得范数,

定义为
$$\sqrt{x_1^2 + x_2^2 + \dots + x_p^2}$$

$$\cos(x, y) = \frac{\sum_{i=1}^p x_i y_i}{\sqrt{\sum_{i=1}^p x_i^2 \cdot \sum_{i=1}^p y_i^2}}$$

Example: Cosine Similarity



- 余弦相似度: $\cos(d_1, d_2) = (d_1 \bullet d_2) / (\|d_1\| \|d_2\|)$
- 其中 “ $\bullet$ ” 表示向量点乘, $\|d\|$: 向量的长度 d
- Ex: 文档可以用很多属性进行描述, 每个属性代表某一词在文档中出现的次数。

Document	team	coach	hockey	baseball	soccer	penalty	score	win	loss	season
Document1	5	0	3	0	2	0	0	2	0	0
Document2	3	0	2	0	1	1	0	1	0	1
Document3	0	7	0	2	1	0	0	3	0	0
Document4	0	1	0	0	1	2	2	0	3	0

计算下述两个向量的相似性:

$$\underline{d_1 = (5, 0, 3, 0, 2, 0, 0, 2, 0, 0)}$$

$$\underline{d_2 = (3, 0, 2, 0, 1, 1, 0, 1, 0, 1)}$$

$$\underline{d_1 \bullet d_2 = 5*3 + 0*0 + 3*2 + 0*0 + 2*1 + 0*1 + 0*1 + 2*1 + 0*0 + 0*1 = 25}$$

$$\|d_1\| = \sqrt{5 \times 5 + 0 \times 0 + 3 \times 3 + 0 \times 0 + 2 \times 2 + 0 \times 0 + 0 \times 0 + 2 \times 2 + 0 \times 0 + 0 \times 0} = \underline{6.481}$$

$$\|d_2\| = \sqrt{3 \times 3 + 0 \times 0 + 2 \times 2 + 0 \times 0 + 1 \times 1 + 1 \times 1 + 0 \times 0 + 1 \times 1 + 0 \times 0 + 1 \times 1} = \underline{4.12}$$

$$\cos(d_1, d_2) = \underline{0.94}$$

Chapter 2: 了解数据

- 数据对象和属性类型
- 数据的基本统计描述
- 数据可视化
- 测量数据相似性和相异性
- 总结



Summary

- **Data attribute types: nominal, binary, ordinal, interval-scaled, ratio-scaled**
- **Many types of data sets, e.g., numerical, text, graph, Web, image.**
- **Gain insight into the data by:**
 - **Basic statistical data description: central tendency, dispersion, graphical displays**
 - **Data visualization: map data onto graphical primitives**
 - **Measure data similarity**
- **Above steps are the beginning of data preprocessing.**
- **Many methods have been developed but still an active area of research.**

References

- W. Cleveland, Visualizing Data, Hobart Press, 1993
- T. Dasu and T. Johnson. Exploratory Data Mining and Data Cleaning. John Wiley, 2003
- U. Fayyad, G. Grinstein, and A. Wierse. Information Visualization in Data Mining and Knowledge Discovery, Morgan Kaufmann, 2001
- L. Kaufman and P. J. Rousseeuw. Finding Groups in Data: an Introduction to Cluster Analysis. John Wiley & Sons, 1990.
- H. V. Jagadish, et al., Special Issue on Data Reduction Techniques. Bulletin of the Tech. Committee on Data Eng., 20(4), Dec. 1997
- D. A. Keim. Information visualization and visual data mining, IEEE trans. on Visualization and Computer Graphics, 8(1), 2002
- D. Pyle. Data Preparation for Data Mining. Morgan Kaufmann, 1999
- S. Santini and R. Jain, "Similarity measures", IEEE Trans. on Pattern Analysis and Machine Intelligence, 21(9), 1999
- E. R. Tufte. The Visual Display of Quantitative Information, 2nd ed., Graphics Press, 2001
- C. Yu , et al, Visual data mining of multimedia data for social and behavioral studies, Information Visualization, 8(1), 2009